4. ניתוח שונות חד-כיווני

ניתוח נתונים סטטיסטי · הרצאה 4 (One-way ANOVA)

ד״ר עדי שריד

2026-11-08

על מה נדבר היום

- **מרגרסיה לניתוח שונות:** פקטור אחד, כמה רמות, ושאלה אחת: האם יש הבדל?
- **ניסויים:** פקטורים, רמות, תגובה, ולמה מגרילים
- **המודל:** $y_{ij} = \mu + \tau_i + \varepsilon_{ij}$ וההשערות
- **פירוק השונות:** $SS_T = SS_{Tr} + SS_E$, מבחן F וטבלת ANOVA
- **חישוב ידני ופלט R**, אמידה ורווחי סמך
- **ניסוי לא מאוזן**
- **בדיקת ההנחות**, ומה עושים כשהן לא מתקיימות
- **אפקטים אקראיים**
- **מה יכול להשתבש**

מרגרסיה לניתוח שונות

כבר ראינו את זה, בלי לקרוא לזה בשם

בהרצאה על רגרסיה שאלנו: **האם גודל מודל השפה משפיע על זמן התגובה?** הוספנו משתני דמה לפקטור עם שלוש רמות, ובדקנו את כולם יחד במבחן F חלקי.

ניתוח שונות (Analysis of Variance, ANOVA) הוא בדיוק המקרה הזה, כשאין משתנים רציפים בכלל:

- **משתנה מוסבר** רציף Y: זמן, תפוקה, ציון, חוזק
- **פקטור** (factor) קטגורי אחד עם a **רמות** (levels), שנקראות גם **טיפולים** (treatments)
- **השאלה:** האם התוחלת של Y זהה בכל הרמות?

רגרסיה	ניתוח שונות
מתמקדת ב**חיזוי** Y	מתמקדת ב**מקורות הפיזור** של Y
משתנים מסבירים רציפים (בעיקר)	פקטורים קטגוריים
`lm()`	`aov()`, שקוראת ל-`lm()` מאחורי הקלעים

ניסויים (Experiments)

מה זה ניסוי

רכיב	מה זה
קלט	מה שנכנס לתהליך: חומר גלם, פנייה של לקוח, בקשה לשרת
פקטורים מבוקרים $x_1, x_2, \ldots$	משתנים שאנחנו קובעים בניסוי
פקטורים לא מבוקרים $z_1, z_2, \ldots$	משתנים שמשפיעים, אבל לא בשליטתנו (רעש)
תגובת המערכת y	מה שמודדים

השאלות שניסוי עונה עליהן:

- אילו פקטורים משפיעים על y הכי הרבה?
- לאילו ערכים לכוון את x כדי לקבל y רצוי? כדי שהשונות של y תהיה קטנה?
- איך לכוון את x כך שהרעש z ישפיע כמה שפחות?

דוגמה: מוקד שירות עם עוזר AI

מוקד תמיכה טכנית הכניס עוזר AI שמציע למוקדנים תשובות בזמן השיחה.

פקטורים מבוקרים	מספר המוקדנים במשמרת · גרסת העוזר · נוסח ההודעה ללקוחות בתור
פקטורים לא מבוקרים	השעה ביום · הניסיון של המוקדן · סוג התקלה
משתני תגובה	אחוז הפניות שנסגרות בשיחה הראשונה (FCR) · משך הטיפול · שביעות רצון הלקוח

- **ניסוי חד-כיווני:** משנים פקטור **אחד** (למשל, מודל השפה שמפעיל את העוזר) ומודדים את התגובה
- את הפקטורים הלא מבוקרים מנטרלים בעזרת **הגרלה**: כל פנייה מנותבת למודל באקראי
- **נמשיך עם הדוגמה הזו לאורך כל ההרצאה**

שלבי הניסוי

1. זיהוי הבעיה והגדרתה
2. בחירת הפקטורים (factors) והרמות (levels)
3. בחירת משתני התגובה (response)
4. **תכנון:** כמה חזרות (replicates) בכל רמה, ובאיזה סדר מריצים
5. ביצוע הניסוי
6. ניתוח הנתונים ← **ההרצאה הזו**
7. מסקנות והמלצות

למה מגרילים? (Randomisation)

- הפקטורים הלא מבוקרים (z) **תמיד** קיימים. אם הם מתואמים עם הפקטור שבודקים, ההבדל שנראה בנתונים הוא שלהם, לא שלו
- **דוגמה:** אם מודל אחד רץ רק במשמרות בוקר, ומודל אחר רק בלילה, אי אפשר לדעת אם ההבדל בא מהמודל או מהשעה
- **הגרלה** שוברת את הקשר: בממוצע, כל רמה מקבלת "תערובת" דומה של כל הגורמים הלא מבוקרים
- הגרלה הופכת את הרעש z לחלק מהשגיאה האקראית ε, ולא להטיה

מונחים

מונח	משמעות	בדוגמה של היום
פקטור (factor)	המשתנה הקטגורי שבודקים	המודל שמפעיל את העוזר
רמה / טיפול (level / treatment)	ערך אפשרי של הפקטור	M1, …, M5
a	מספר הרמות	5
חזרה (replicate)	תצפית אחת ברמה מסוימת	יום עבודה אחד של מודל
n	מספר החזרות בכל רמה (ניסוי מאוזן)	9
$N = an$	מספר התצפיות הכולל	45
תגובה (response)	המשתנה המוסבר Y	משך הטיפול הממוצע בפנייה (דקות)

אפקטים קבועים או אקראיים?

- **קבועים** (fixed effects): הרמות שבדקנו הן **בדיוק** הרמות שמעניינות אותנו (חמשת המודלים שהמוקד שקל)
- **אקראיים** (random effects): הרמות הן **מדגם** מתוך הרבה רמות אפשריות, והמסקנה צריכה לחול על כולן. נגיע לזה בסוף ההרצאה

השאלה והנתונים

השאלה: איזה מודל להפעיל בעוזר?

המוקד מהדוגמה הקודמת צריך לבחור את מודל השפה שיפעיל את העוזר. חמישה מודלים בתחרות: שני מודלים קטנים וזולים (M1, M2), מודל בינוני (M3) ושני מודלים גדולים ויקרים (M4, M5).

השאלות:

- האם יש בכלל הבדל בין המודלים במשך הטיפול בפנייה?
- אם כן, איזה מהם מקצר את הטיפול הכי הרבה? ובכמה?

הנתונים: במשך 9 ימי עבודה, כל פנייה נכנסת נותבה באקראי לאחד מחמשת המודלים. לכל מודל בכל יום נמדד משך הטיפול הממוצע בפנייה, בדקות.

```
calls <- read_csv(file.path(data_dir, "support_ai.csv"), show_col_types = FALSE) |>
  mutate(model = factor(model))
calls |> pivot_wider(names_from = model, values_from = aht) |> head(4)
```

```
# A tibble: 4 × 6
    day    M1    M2    M3    M4    M5
  <dbl> <dbl> <dbl> <dbl> <dbl> <dbl>
1     1  4.98  5.29  4.51  3.51  5.08
2     2  6.1   6.21  4.82  4.38  4.17
3     3  6.5   6.17  5.18  4.47  4.67
4     4  5.56  5.84  4.14  3.97  3.71
```

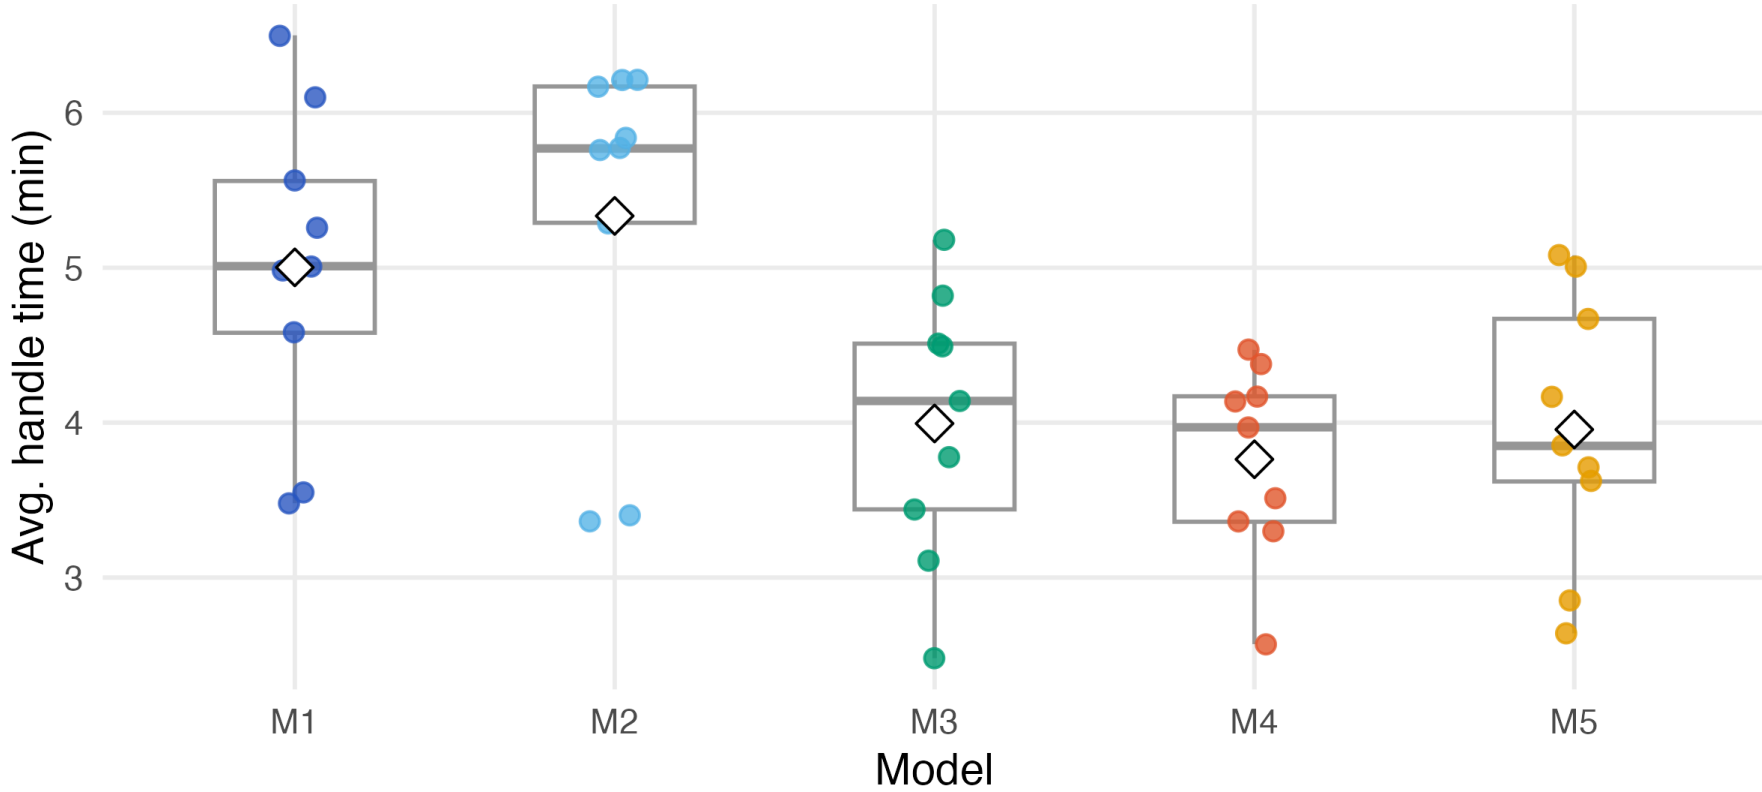
הנתונים בתרשים

```
ggplot(calls, aes(model, aht, colour = model)) +
  geom_boxplot(width = 0.5, outlier.shape = NA, colour = "grey60") +
  geom_point(size = 2.5, alpha = 0.8, position = position_jitter(width = 0.08, seed = 1),
             show.legend = FALSE) +
  stat_summary(fun = mean, geom = "point", shape = 23, size = 4, fill = "white",
               colour = "black") +
  scale_colour_manual(values = model_cols) +
  labs(title = "עם M1 ו־M2 הטיפול נראה ארוך יותר. האם זה אמיתי?",
       subtitle = "9 הממוצע: מעוין · ימים לכל מודל",
       x = "Model", y = "Avg. handle time (min)")
```

הנתונים בתרשים

עם M1 ו-M2 הטיפול נראה ארוך יותר. האם זה אמיתי?

9 ימים לכל מודל · מעוין: הממוצע



למה לא פשוט מבחני t?

עם 5 מודלים יש $\binom{5}{2} = 10$ זוגות. אפשר להריץ 10 מבחני t לשני מדגמים, כל אחד ברמת מובהקות 5%.

הבעיה: אם אין שום הבדל בין המודלים, ומבחנים בלתי תלויים (בקירוב),

$$P(\text{לפחות דחייה שגויה אחת}) = 0.40 = 0.95^{10} - 1$$

- ב-40% מהניסויים "נגלה" הבדל שלא קיים
- ניתוח שונות בודק **השערה אחת** על כל הרמות יחד, ברמת מובהקות α
- אם היא נדחית, **אז** שואלים אילו רמות שונות זו מזו. על כך בהרצאה הבאה (השוואות מרובות)

המודל

סימונים

רמה	תצפיות	סכום	ממוצע
1	$y_{11}, y_{12}, \ldots, y_{1n}$	$y_{1\cdot}$	$\bar{y}_{1\cdot}$
2	$y_{21}, y_{22}, \ldots, y_{2n}$	$y_{2\cdot}$	$\bar{y}_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$	$\vdots$
a	$y_{a1}, y_{a2}, \ldots, y_{an}$	$y_{a\cdot}$	$\bar{y}_{a\cdot}$
		$y_{\cdot\cdot}$	$\bar{y}_{\cdot\cdot}$

$$y_{i\cdot} = \sum_{j=1}^{n} y_{ij} \qquad \bar{y}_{i\cdot} = \frac{y_{i\cdot}}{n} \qquad y_{\cdot\cdot} = \sum_{i=1}^{a}\sum_{j=1}^{n} y_{ij} \qquad \bar{y}_{\cdot\cdot} = \frac{y_{\cdot\cdot}}{N}$$

הנקודה במקום אינדקס פירושה "סכום על האינדקס הזה". y_{ij} היא התצפית ה-j ברמה ה-i.

מודל האפקטים הקבועים

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij} \qquad i = 1, \ldots, a \qquad j = 1, \ldots, n$$

- μ: **התוחלת הכללית** של התגובה
- τ_i: **האפקט** של רמה i, התוספת שלה מעל התוחלת הכללית. מתקיים $\sum_{i=1}^{a} \tau_i = 0$
- $\mu_i = \mu + \tau_i$: התוחלת ברמה i
- ε_{ij}: **השגיאה** האקראית

ההנחות על השגיאות:

$$\varepsilon_{ij} \overset{iid}{\sim} N(0, \sigma^2)$$

1. **נורמליות**
2. **אי-תלות**
3. **שונות שווה** בכל הרמות: אותה σ^2

ההשערות

$H_0 : \tau_1 = \tau_2 = \cdots = \tau_a = 0$ $\qquad$ $H_1 : \tau_i \neq 0$ כלשהו i עבור

ובמילים אחרות, $H_0 : \mu_1 = \mu_2 = \cdots = \mu_a$.

- תחת H_0 ותחת ההנחות, **ההתפלגות** של התגובה זהה בכל הרמות
- H_1 לא אומרת שכל הרמות שונות. מספיק שאחת שונה

פירוק השונות

הרעיון: אות מול רעש

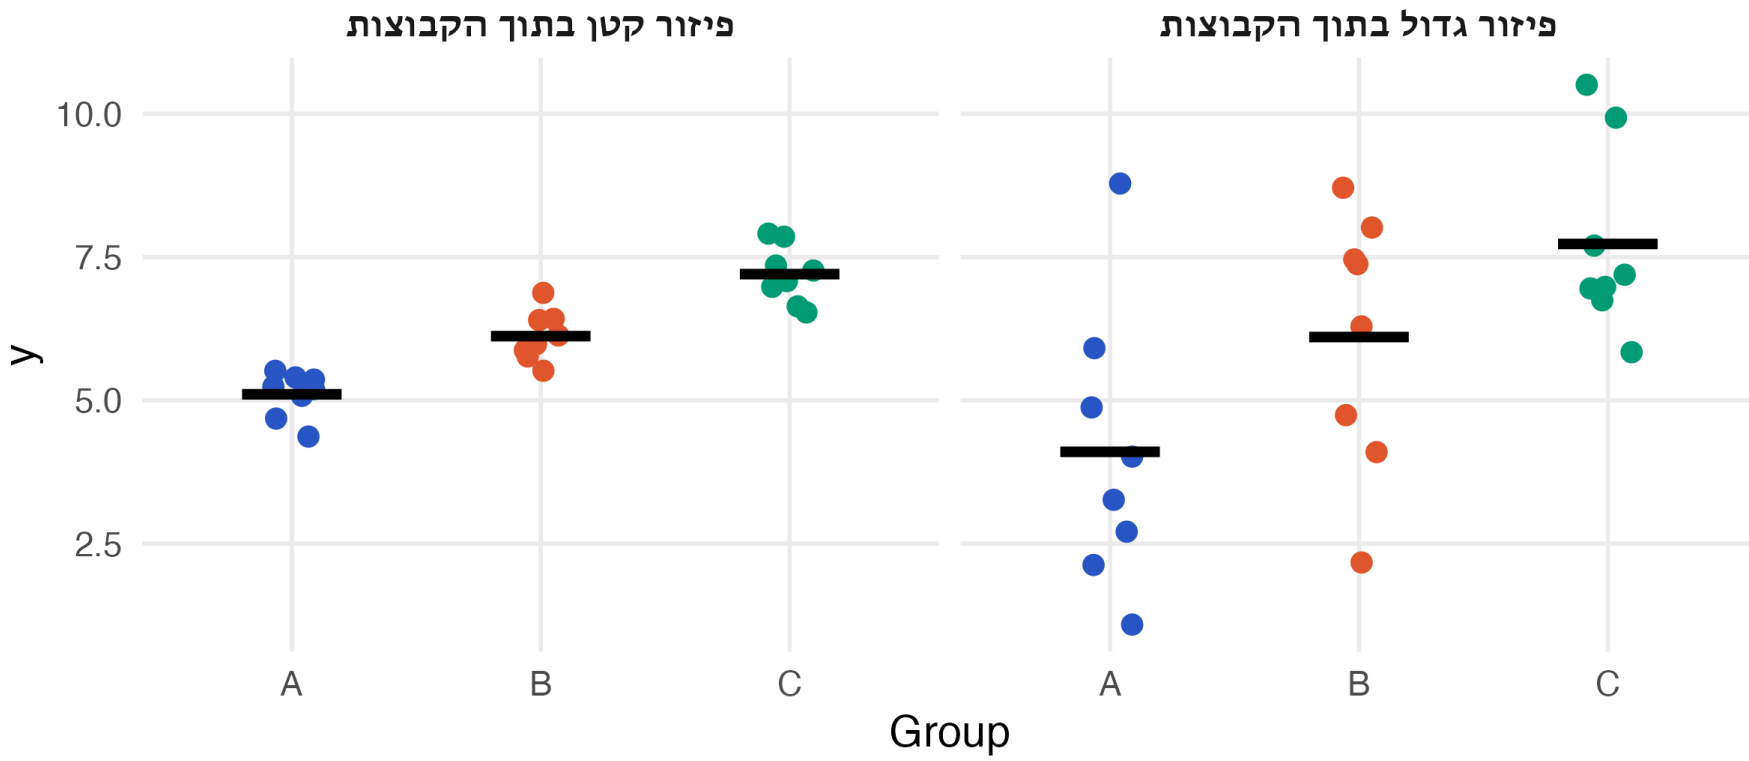
```
set.seed(41)
demo <- expand_grid(scenario = c("פיזור גדול בתוך הקבוצות" ,"פיזור קטן בתוך הקבוצות"),
                    group = c("A", "B", "C"), j = 1:8) |>
  mutate(sd = if_else(scenario == "2.2 ,0.4 ,"פיזור קטן בתוך הקבוצות),
         y = c(A = 5, B = 6, C = 7)[group] + rnorm(n(), 0, sd),
         scenario = fct_rev(scenario))

ggplot(demo, aes(group, y, colour = group)) +
  geom_point(position = position_jitter(width = 0.1, seed = 2), size = 2.5, show.legend = FALSE) +
  stat_summary(fun = mean, geom = "crossbar", width = 0.4, colour = "black") +
  facet_wrap(~ scenario) +
  labs(title = "אותם הבדלים בין הממוצעים ,מסקנה שונה",
       subtitle = "השאלה היא לא אם הממוצעים שונים ,אלא אם הם שונים יותר ממה שהרעש מסביר",
       x = "Group", y = "y")
```

הרעיון: אות מול רעש

אותם הבדלים בין הממוצעים, מסקנה שונה

השאלה היא לא אם הממוצעים שונים, אלא אם הם שונים יותר ממה שהרעש מסביר



פירוק לסכומי ריבועים

כל סטייה מהממוצע הכללי מתפרקת לשני חלקים:

$$\underbrace{y_{ij} - \bar{y}_{..}}_{\text{סטייה כוללת}} = \underbrace{(\bar{y}_{i.} - \bar{y}_{..})}_{\text{בין הרמות}} + \underbrace{(y_{ij} - \bar{y}_{i.})}_{\text{בתוך הרמה}}$$

מעלים בריבוע וסוכמים על כל התצפיות. האיבר המעורב מתאפס, ונשאר:

$$\underbrace{\sum_{i=1}^{a}\sum_{j=1}^{n}(y_{ij} - \bar{y}_{..})^2}_{SS_T} = \underbrace{n\sum_{i=1}^{a}(\bar{y}_{i.} - \bar{y}_{..})^2}_{SS_{Tr}} + \underbrace{\sum_{i=1}^{a}\sum_{j=1}^{n}(y_{ij} - \bar{y}_{i.})^2}_{SS_E}$$

- SS_{Tr} (treatments): הפיזור **בין** ממוצעי הרמות
- SS_E (error): הפיזור **בתוך** הרמות, סביב הממוצע של כל רמה

דרגות חופש

$$\underbrace{N-1}_{SS_T} = \underbrace{a-1}_{SS_{Tr}} + \underbrace{N-a}_{SS_E}$$

- SS_T: N סטיות, עם אילוץ אחד (סכומן אפס)
- SS_{Tr}: a ממוצעים, עם אילוץ אחד
- SS_E: N סטיות, עם a אילוצים (בכל רמה, סכום הסטיות אפס)

ממוצעי ריבועים (mean squares): מחלקים כל סכום בדרגות החופש שלו.

$$MS_{Tr} = \frac{SS_{Tr}}{a-1} \qquad MS_E = \frac{SS_E}{N-a}$$

מה אומדים ממוצעי הריבועים?

הרעיון: יש לנו **שתי דרכים** לאמוד את שונות הרעש σ^2. רק אחת מהן מושפעת מההבדלים בין הרמות.

	MS_E: **הפיזור בתוך הרמות**	MS_{Tr}: **הפיזור של הממוצעים**
ממה הוא בנוי	$y_{ij} - \bar{y}_{i\cdot} = \varepsilon_{ij} - \bar{\varepsilon}_{i\cdot}$	$\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot} = \tau_i + (\bar{\varepsilon}_{i\cdot} - \bar{\varepsilon}_{\cdot\cdot})$
מה יש בו	רעש בלבד: τ_i מתבטל	רעש **ועוד** אות (τ_i)
התוחלת	$E(MS_E) = \sigma^2$	$E(MS_{Tr}) = \sigma^2 + \dfrac{n\sum_{i=1}^{a}\tau_i^2}{a-1}$

- MS_E **אומד את** σ^2 **תמיד**, בין אם H_0 נכונה ובין אם לא
- MS_{Tr} **אומד את** σ^2 **רק תחת** H_0, כי אז כל $\tau_i = 0$ והאיבר השני נעלם. כשיש הבדל בין הרמות, הוא גדול יותר
- **במוקד:** $MS_E = 0.854$, ו-$MS_{Tr} = 4.51$. אילו לא היה הבדל בין המודלים, היינו מצפים ש-MS_{Tr} יהיה בסביבות 0.85

מבחן F

$$F_0 = \frac{MS_{Tr}}{MS_E}$$

- **תחת** H_0: $SS_{Tr}/\sigma^2 \sim \chi^2_{a-1}$ ו-$SS_E/\sigma^2 \sim \chi^2_{N-a}$, והם בלתי תלויים. לכן

$$F_0 = \frac{\left(SS_{Tr}/\sigma^2\right)/(a-1)}{\left(SS_E/\sigma^2\right)/(N-a)} \sim F_{a-1,\ N-a}$$

- **תחת** H_0 $F_0 \approx 1$. **תחת** H_1 F_0 גדל
- **כלל ההכרעה:** דוחים את H_0 אם $F_0 > F_{1-\alpha;\ a-1,\ N-a}$. המבחן חד-צדדי מימין
- σ^2 מצטמצם, בדיוק כמו ברגרסיה

טבלת ANOVA

מקור השונות	סכום ריבועים	דרגות חופש	ממוצע ריבועים	F_0
בין הרמות (treatments)	SS_{Tr}	$a-1$	$MS_{Tr}=\dfrac{SS_{Tr}}{a-1}$	$\dfrac{MS_{Tr}}{MS_E}$
בתוך הרמות (error)	SS_E	$N-a$	$MS_E=\dfrac{SS_E}{N-a}$	
סך הכול	SS_T	$N-1$		

נוסחאות חישוב (נוחות לחישוב ידני ממחשבון):

$$SS_T=\sum_{i=1}^{a}\sum_{j=1}^{n}y_{ij}^2-\frac{y_{\cdot\cdot}^2}{N} \qquad SS_{Tr}=\frac{1}{n}\sum_{i=1}^{a}y_{i\cdot}^2-\frac{y_{\cdot\cdot}^2}{N} \qquad SS_E=SS_T-SS_{Tr}$$

חישוב ידני ופלט R

המודלים: מה צריך לחישוב

```
calls |>
  group_by(model) |>
  summarise(n = n(), total = sum(aht), mean = mean(aht), sd = sd(aht))
```

```
# A tibble: 5 × 5
  model     n total  mean    sd
  <fct> <int> <dbl> <dbl> <dbl>
1 M1        9  45.0  5.00 1.03
2 M2        9  48.0  5.33 1.15
3 M3        9  36.0  3.99 0.870
4 M4        9  33.9  3.76 0.622
5 M5        9  35.6  3.96 0.871
```

```
c(y_dotdot = sum(calls$aht), sum_y2 = sum(calls$aht^2), N = nrow(calls))
```

```
y_dotdot   sum_y2        N
   198.5    927.3     45.0
```

המודלים: החישוב

$$\frac{y_{\cdot\cdot}^2}{N} = \frac{198.45^2}{45} = 875.16$$

$$SS_T = 927.33 - 875.16 = 52.17$$

$$SS_{Tr} = \frac{45.02^2 + 48.01^2 + 35.95^2 + 33.87^2 + 35.60^2}{9} - 875.16 = 893.19 - 875.16 = 18.02$$

$$SS_E = 52.17 - 18.02 = 34.15$$

מקור	סכום ריבועים	דרגות חופש	ממוצע ריבועים	F_0
מודלים	18.02	4	4.506	**5.28**
שגיאה	34.15	40	0.854	
סך הכול	52.17	44		

$F_0 = 5.28 > F_{0.95;\,4,\,40} = 2.61$, ולכן **דוחים** את H_0: יש הבדל בין המודלים.

אותו חישוב ב-R

```r
fit_ai <- aov(aht ~ model, data = calls)
summary(fit_ai)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
model        4   18.0    4.51    5.28 0.0016 **
Residuals   40   34.1    0.85
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
qf(0.95, df1 = 4, df2 = 40)   # critical value
```

```
[1] 2.606
```

איך קוראים את הפלט

- **model**: שורת הטיפולים. `Df = 4` הוא $a-1$, `Sum Sq` הוא SS_{Tr}, `Mean Sq` הוא MS_{Tr}
- **Residuals**: שורת השגיאה. `Df = 40` הוא $N-a$, ו-`Mean Sq = 0.854` הוא $MS_E = \hat{\sigma}^2$
- **F value = 5.28**: היחס MS_{Tr}/MS_E
- **Pr(>F) = 0.0017**: ה-p-value, $P(F_{4,40} > 5.28)$. קטן מ-0.05, ולכן דוחים
- **שורת סך הכול לא מופיעה.** מחשבים אותה לבד: $SS_T = 18.02 + 34.14$, $df = 44$

אותו מודל עם `lm()`

`aov()` היא עטיפה ל-`lm()`. הפקטור הופך ל-4 משתני דמה, ו-H_0 היא שכל המקדמים שלהם אפס:

```
fit_ai_lm <- lm(aht ~ model, data = calls)
coef(fit_ai_lm)
```

```
(Intercept)     modelM2     modelM3     modelM4     modelM5
     5.0022      0.3322     -1.0078     -1.2389     -1.0467
```

```
anova(fit_ai_lm)
```

```
Analysis of Variance Table

Response: aht
          Df Sum Sq Mean Sq F value Pr(>F)
model      4   18.0    4.51    5.28 0.0016 **
Residuals 40   34.1    0.85
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- `(Intercept)` הוא הממוצע של M1, רמת הבסיס. `modelM2` הוא $\bar{y}_{2\cdot} - \bar{y}_{1\cdot}$, וכן הלאה
- מבחן ה-F לכל המודל ברגרסיה **הוא** מבחן ה-F של ניתוח השונות

אמידה

אומדים לפרמטרים של המודל:

$$\hat{\mu} = \bar{y}_{..} \qquad \hat{\tau}_i = \bar{y}_{i.} - \bar{y}_{..} \qquad \hat{\mu}_i = \bar{y}_{i.} \qquad \hat{\sigma}^2 = MS_E$$

רווח סמך לתוחלת של רמה (עם $N-a$ דרגות חופש, כי σ^2 נאמד מ-MS_E):

$$\bar{y}_{i.} \pm t_{1-\alpha/2,\ N-a}\sqrt{\frac{MS_E}{n}}$$

רווח סמך להפרש בין שתי רמות:

$$(\bar{y}_{i.} - \bar{y}_{k.}) \pm t_{1-\alpha/2,\ N-a}\sqrt{\frac{2\,MS_E}{n}}$$

האומדים למודלים

```r
mse   <- sum(resid(fit_ai)^2) / fit_ai$df.residual
t_crt <- qt(0.975, df = fit_ai$df.residual)

ai_est <- calls |>
  group_by(model) |>
  summarise(mean = mean(aht)) |>
  mutate(tau_hat = mean - mean(calls$aht),
         lwr = mean - t_crt * sqrt(mse / 9),
         upr = mean + t_crt * sqrt(mse / 9))
ai_est
```

```
# A tibble: 5 × 5
  model  mean tau_hat   lwr   upr
  <fct> <dbl>   <dbl> <dbl> <dbl>
1 M1     5.00   0.592  4.38  5.62
2 M2     5.33   0.924  4.71  5.96
3 M3     3.99  -0.416  3.37  4.62
4 M4     3.76  -0.647  3.14  4.39
5 M5     3.96  -0.454  3.33  4.58
```

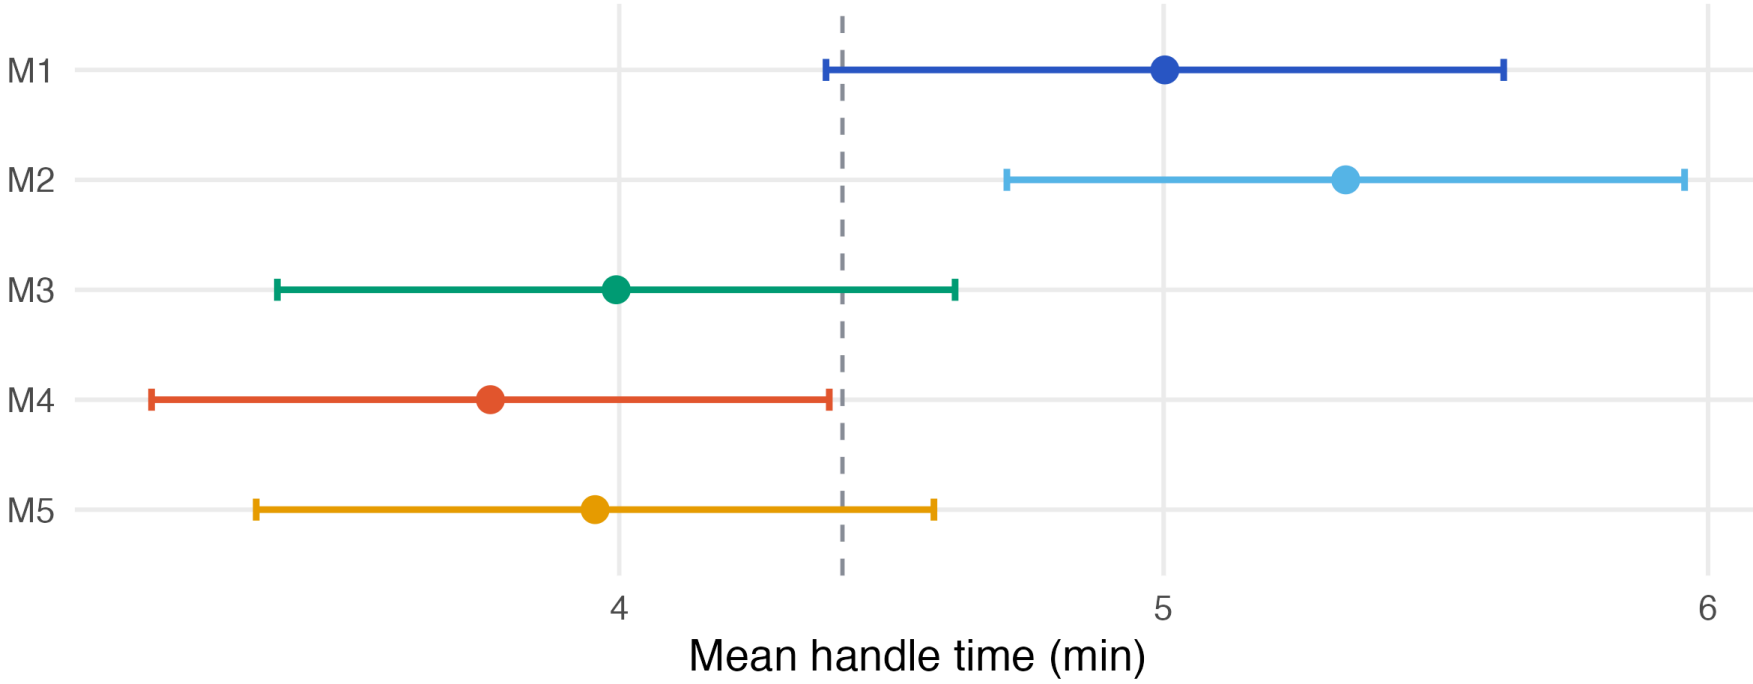
רווחי סמך בתרשים

```
ggplot(ai_est, aes(mean, fct_rev(model), colour = model)) +
  geom_vline(xintercept = mean(calls$aht), colour = nanas_pal[["grey"]], linetype = "dashed") +
  geom_errorbar(aes(xmin = lwr, xmax = upr), width = 0.2, linewidth = 1, orientation = "y") +
  geom_point(size = 3.5) +
  scale_colour_manual(values = model_cols, guide = "none") +
  labs(title = "עם M3, M4 ו־M5 הטיפול קצר יותר מאשר עם M1 ו־M2",
       subtitle = "רווחי סמך 95% לתוחלת של כל מודל · הקו המקווקו: הממוצע הכללי",
       x = "Mean handle time (min)", y = NULL)
```

רווחי סמך בתרשים

עם M3, M4 ו-M5 הטיפול קצר יותר מאשר עם M1 ו-M2

רווחי סמך 95% לתוחלת של כל מודל · הקו המקווקו: הממוצע הכללי



אז איזה מודל להפעיל?

- M4 עם הממוצע הנמוך ביותר: 3.76 דקות. אבל M3 ו-M5 ממש קרובים אליו
- הרווחים של M3, M4 ו-M5 חופפים כמעט לגמרי. ייתכן שאין ביניהם הבדל אמיתי
- **מבחן ה-F אמר רק שיש הבדל איפשהו.** כדי לדעת **בין מי למי**, צריך השוואות מרובות, עם תיקון לכך שבודקים הרבה זוגות
- **ההחלטה העסקית** לא תלויה רק בסטטיסטיקה: אם M3, M4 ו-M5 שקולים, אפשר לבחור ביניהם לפי שיקולים אחרים. M3, המודל הבינוני, זול בהרבה מהגדולים
- וגם לא רק במשך הטיפול: טיפול קצר שווה משהו רק אם אחוז הפניות שנסגרות בשיחה הראשונה (FCR) לא ירד

תרגיל: השלימו את הטבלה

ניסוי עם $a = 4$ גרסאות של דף נחיתה, ו-$n = 6$ משתמשים בכל גרסה. התגובה: זמן עד ההרשמה (שניות). חלק מהערכים נמחקו:

מקור	סכום ריבועים	דרגות חופש	ממוצע ריבועים	F_0
גרסאות	(א)	(ב)	40	(ג)
שגיאה	(ד)	(ה)	(ו)	
סך הכול	320	(ז)		

1. השלימו את הטבלה. האם יש הבדל בין הגרסאות ב-$\alpha = 0.05$? ($F_{0.95;\,3,\,20} = 3.10$)
2. מהו $\hat{\sigma}$?
3. מהו רווח הסמך (95%) להפרש בין שתי גרסאות שהממוצעים שלהן 31 ו-27? ($t_{0.975;\,20} = 2.086$)

פתרון התרגיל

מקור	סכום ריבועים	דרגות חופש	ממוצע ריבועים	F_0
גרסאות	**(א) 120**	**(ב) 3**	40	**(ג) 4**
שגיאה	**(ד) 200**	**(ה) 20**	**(ו) 10**	
סך הכול	320	**(ז) 23**		

- (ב) $a - 1 = 3$ (א) $\cdot$ $N - 1 = 24 - 1 = 23$ (ז) $\cdot$ $SS_{Tr} = 40 \cdot 3 = 120$ (ד) $\cdot$ $N - a = 20$ (ה) $\cdot$ $40/10 = 4$ (ג) $\cdot$ $200/20 = 10$ (ו) $\cdot$ $320 - 120 = 200$
- $F_0 = 4 > 3.10$, ולכן **דוחים** את H_0: יש הבדל בין הגרסאות
- שניות $\hat{\sigma} = \sqrt{MS_E} = \sqrt{10} = 3.16$
- $(31 - 27) \pm 2.086\sqrt{2 \cdot 10/6} = 4 \pm 3.81 = [0.19,\ 7.81]$. הרווח לא כולל את 0

```
c(F_crit = qf(0.95, 3, 20), p_value = pf(4, 3, 20, lower.tail = FALSE),
  half_width = qt(0.975, 20) * sqrt(2 * 10 / 6))
```

```
   F_crit    p_value half_width
  3.09839    0.02208    3.80843
```

ניסוי לא מאוזן
(Unbalanced design)

כשמספר החזרות שונה בין הרמות

	מספר חזרות זהה (מאוזן)	מספר חזרות שונה בין הרמות (לא מאוזן)
N	an	$\sum_{i=1}^{a} n_i$
האילוץ	$\sum_{i=1}^{a} \tau_i = 0$	$\sum_{i=1}^{a} n_i \tau_i = 0$
SS_T	$\sum_{i=1}^{a}\sum_{j=1}^{n} y_{ij}^2 - \frac{y_{\cdot\cdot}^2}{N}$	$\sum_{i=1}^{a}\sum_{j=1}^{n_i} y_{ij}^2 - \frac{y_{\cdot\cdot}^2}{N}$
SS_{Tr}	$\sum_{i=1}^{a} \frac{y_{i\cdot}^2}{n} - \frac{y_{\cdot\cdot}^2}{N}$	$\sum_{i=1}^{a} \frac{y_{i\cdot}^2}{n_i} - \frac{y_{\cdot\cdot}^2}{N}$
SS_E	$SS_T - SS_{Tr}$	$SS_T - SS_{Tr}$
דרגות חופש	$a-1$ ו-$N-a$	$a-1$ ו-$N-a$
רווח סמך להפרש	$(\bar{y}_{i\cdot} - \bar{y}_{k\cdot}) \pm t_{1-\alpha/2,\, N-a}\sqrt{\frac{2\,MS_E}{n}}$	$(\bar{y}_{i\cdot} - \bar{y}_{k\cdot}) \pm t_{1-\alpha/2,\, N-a}\sqrt{MS_E\left(\frac{1}{n_i}+\frac{1}{n_k}\right)}$

- בניסוי לא מאוזן, כל ממוצע מקבל משקל לפי מספר התצפיות שלו: $SS_{Tr} = \sum_i n_i(\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot})^2$

למה בכל זאת מעדיפים ניסוי מאוזן?

- המבחן **עמיד יותר** לשונויות לא שוות כש-n_i שווים (נראה בהמשך)
- לסך תצפיות נתון, העוצמה (power) גבוהה ביותר כשהחלוקה שווה

דוגמה: מבחן בשלוש כיתות

מבחן התקיים בשלוש כיתות בו-זמנית: 40 סטודנטים בכיתה 1, ו-30 בכל אחת מכיתות 2 ו-3. **כיתה 3 סמוכה לאתר בנייה**, והיו בה רעשים לאורך כל המבחן. הסטודנטים מכיתה 3 מבקשים פקטור.

השאלה: האם יש הבדל בציונים בין הכיתות?

```
rooms <- read_csv(file.path(data_dir, "exam_rooms.csv"), show_col_types = FALSE)
rooms |> group_by(room) |> summarise(n = n(), total = sum(grade), mean = mean(grade), sd = sd(grade))
```

```
# A tibble: 3 × 5
  room      n total  mean    sd
  <chr> <int> <dbl> <dbl> <dbl>
1 room1    40  3014  75.4  12.9
2 room2    30  2258  75.3  10.3
3 room3    30  2015  67.2  15.5
```

```
summary(aov(grade ~ room, data = rooms))
```

```
             Df Sum Sq Mean Sq F value Pr(>F)
room          2   1394     697    4.08   0.02 *
Residuals    97  16573     171
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

בדיקת ההנחות

השאריות (Residuals)

$$e_{ij} = y_{ij} - \hat{y}_{ij} = y_{ij} - \bar{y}_{i\cdot}$$

השאריות הן האומדים לשגיאות ε_{ij}. כל ההנחות נבדקות דרכן:

ההנחה	בדיקה גרפית	בדיקה במבחן
נורמליות	גרף Q-Q	Shapiro–Wilk, KS
אי-תלות	שאריות לפי סדר האיסוף	
שונות שווה	boxplot, שאריות מול ממוצעי הרמות	Bartlett, Levene

```
calls <- calls |> mutate(fitted = fitted(fit_ai), resid = resid(fit_ai))
calls |> select(day, model, aht, fitted, resid) |> head(3)
```

```
# A tibble: 3 × 5
    day model   aht fitted   resid
  <dbl> <fct> <dbl>  <dbl>   <dbl>
1     1 M1     4.98   5.00 -0.0222
2     1 M2     5.29   5.33 -0.0444
3     1 M3     4.51   3.99  0.516
```

גרף Q-Q: איך בונים אותו

1. ממיינים את N השאריות מהקטנה לגדולה: $e_{(1)} \le e_{(2)} \le \cdots \le e_{(N)}$
2. לשארית ה-k בסדר מתאימים את **האחוזון** $p_k = \dfrac{k - 0.5}{N}$
3. מחשבים את **הערך התיאורטי** של $N(0,1)$ באחוזון הזה: $z_k = \Phi^{-1}(p_k)$
4. משרטטים את $e_{(k)}$ (ציר אנכי) מול z_k (ציר אופקי)

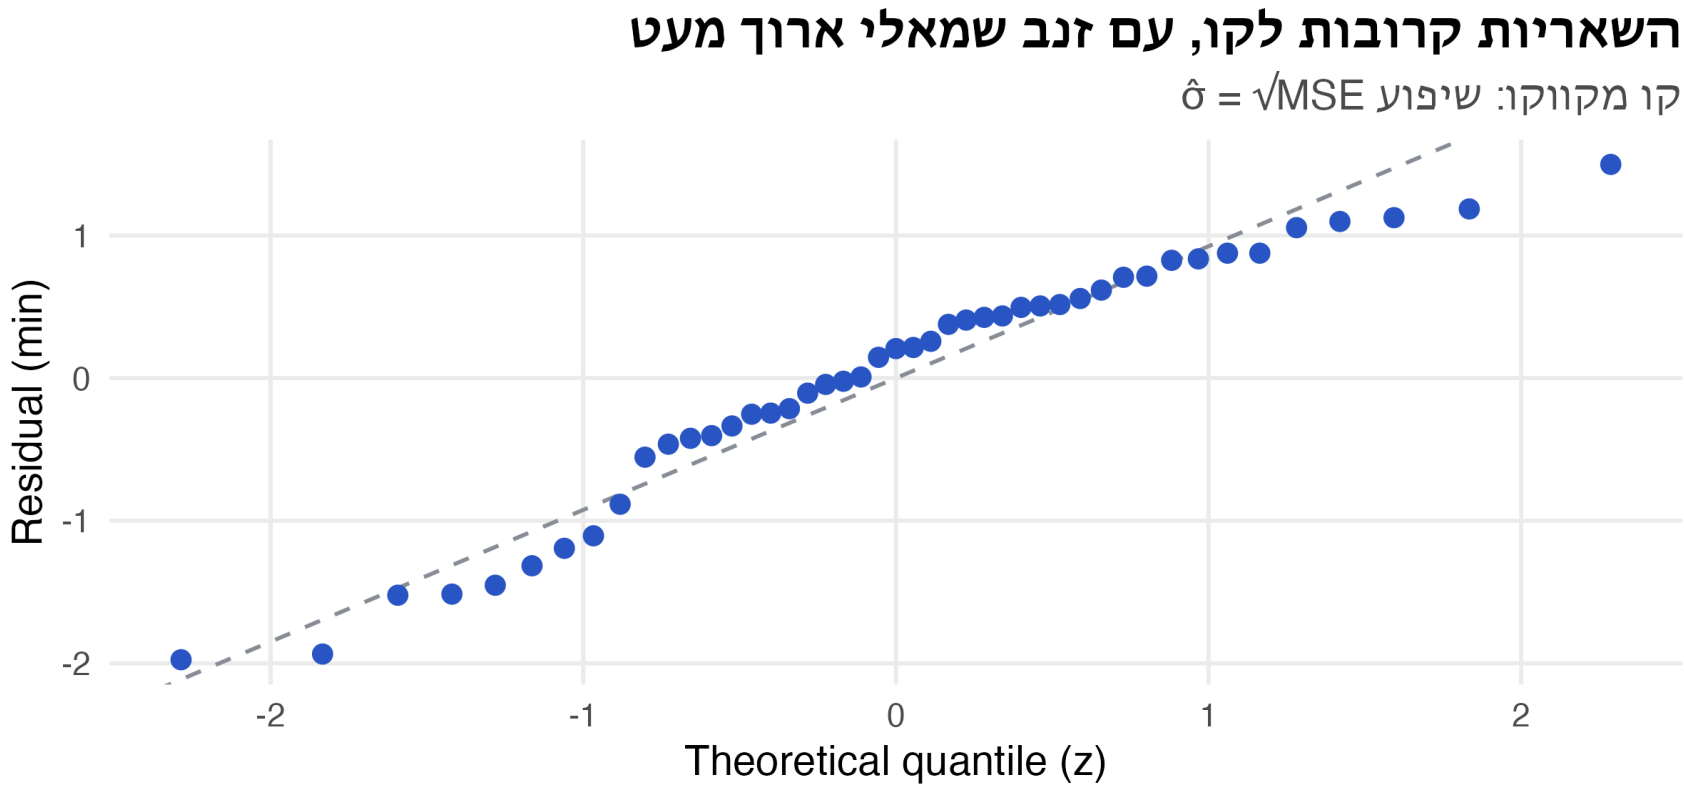
אם השאריות נורמליות, הנקודות על קו ישר (השיפוע הוא בערך $\hat{\sigma}$).

```
qq <- calls |>
  arrange(resid) |>
  mutate(k = row_number(), p = (k - 0.5) / n(), z = qnorm(p))
qq |> select(resid, k, p, z) |> slice(c(1, 2, 45))
```

```
# A tibble: 3 × 4
  resid     k      p     z
  <dbl> <int>  <dbl> <dbl>
1 -1.97     1 0.0111 -2.29
2 -1.93     2 0.0333 -1.83
3  1.50    45 0.989   2.29
```

גרף Q-Q למודלים

```
ggplot(qq, aes(z, resid)) +
  geom_abline(intercept = 0, slope = sqrt(mse), colour = nanas_pal[["grey"]], linetype = "dashed") +
  geom_point(size = 2.5) +
  labs(title = "השאריות קרובות לקו, עם זנב שמאלי ארוך מעט",
       subtitle = "קו מקווקו: שיפוע σ̂ = √MSE",
       x = "Theoretical quantile (z)", y = "Residual (min)")
```



שונות שווה

```
bartlett.test(aht ~ model, data = calls)
```

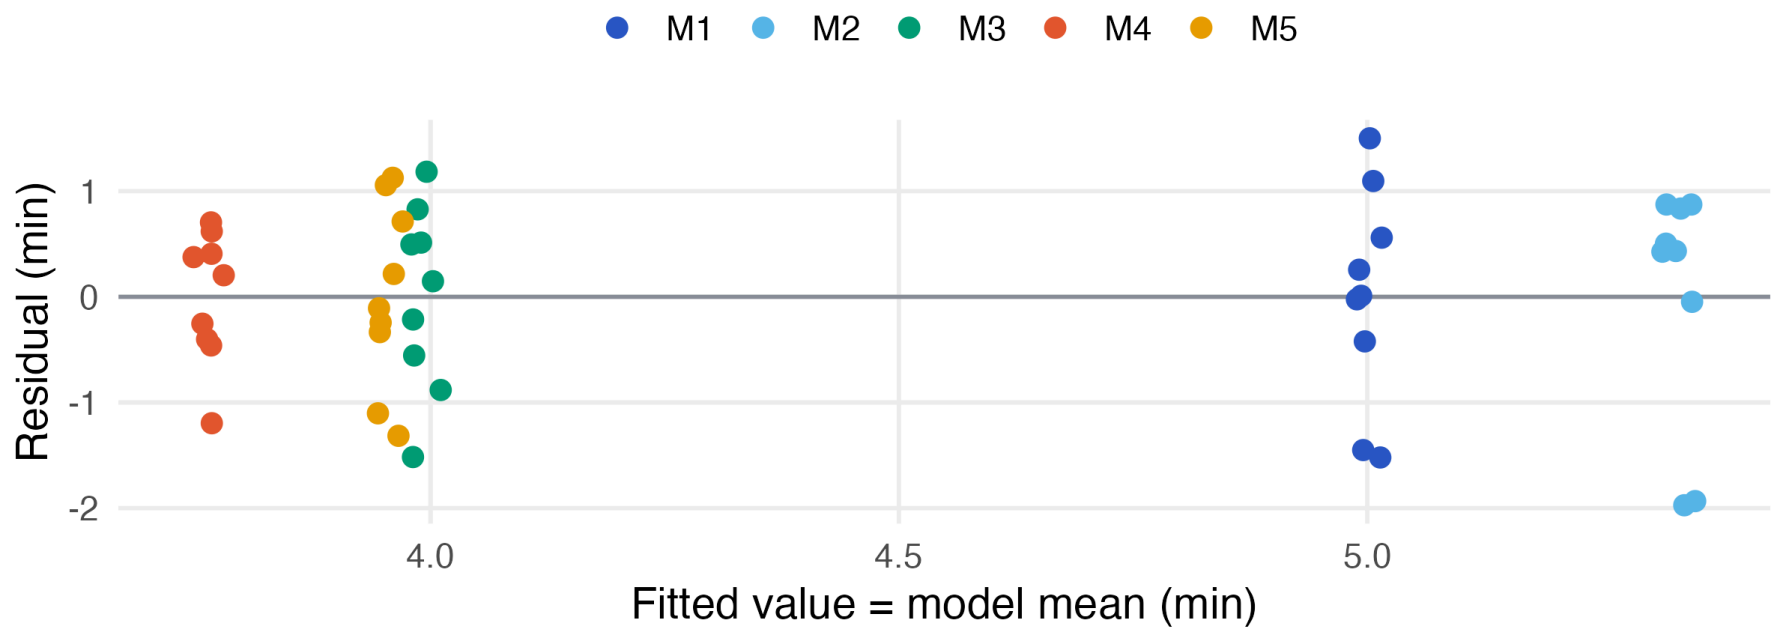
```
    Bartlett test of homogeneity of variances

data:  aht by model
Bartlett's K-squared = 3, df = 4, p-value = 0.6
```

```
ggplot(calls, aes(fitted, resid, colour = model)) +
  geom_hline(yintercept = 0, colour = nanas_pal[["grey"]]) +
  geom_point(size = 2.5, position = position_jitter(width = 0.02, seed = 3)) +
  scale_colour_manual(values = model_cols) +
  labs(title = "הפיזור דומה בכל הרמות",
       x = "Fitted value = model mean (min)", y = "Residual (min)", colour = NULL)
```

שונות שווה

הפיזור דומה בכל הרמות



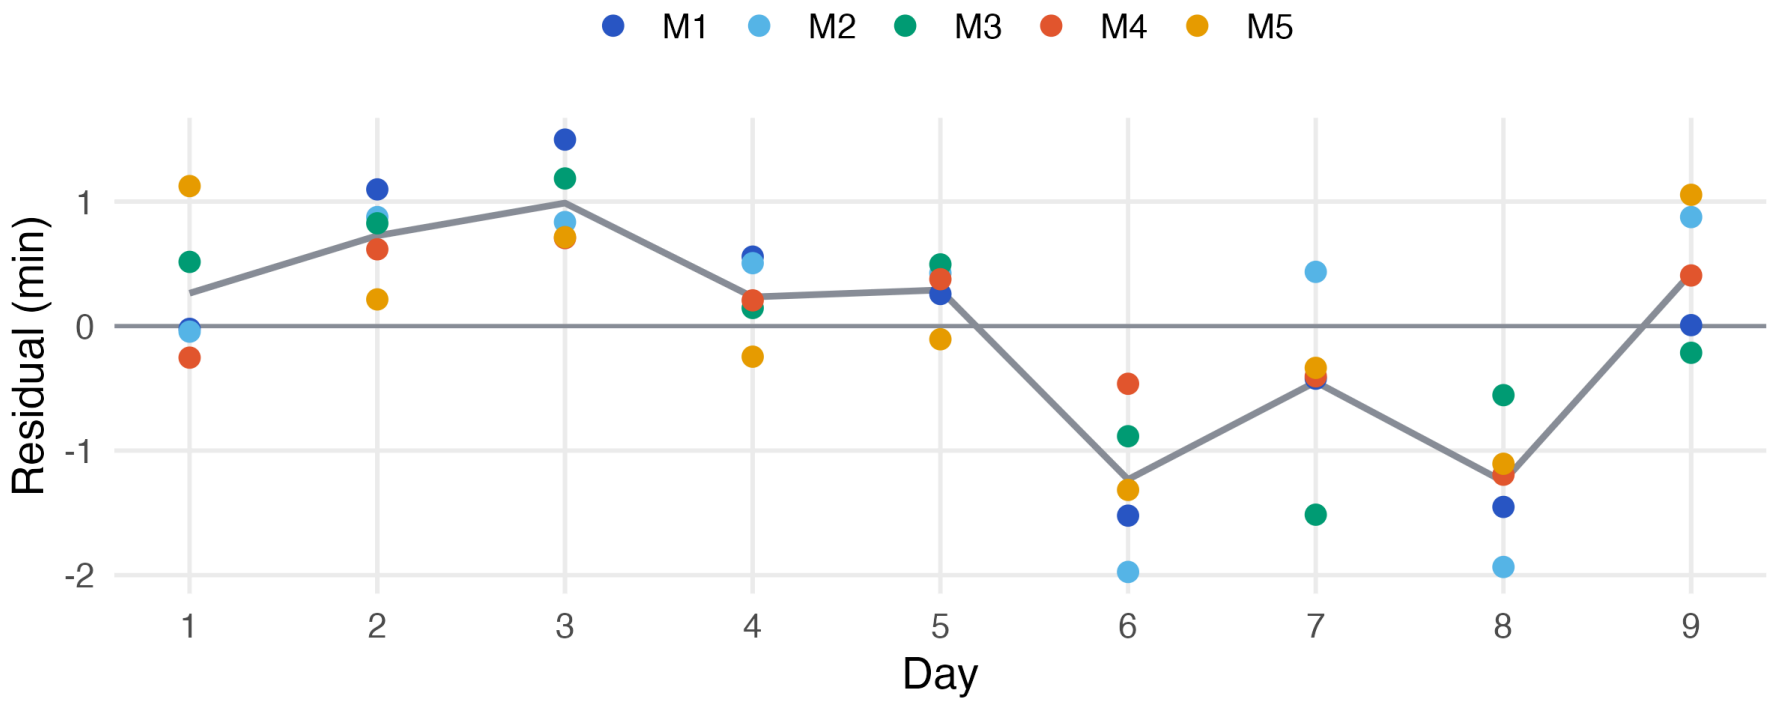
אי-תלות: שאריות לפי היום

```
ggplot(calls, aes(day, resid)) +
  geom_hline(yintercept = 0, colour = nanas_pal[["grey"]]) +
  stat_summary(fun = mean, geom = "line", colour = nanas_pal[["grey"]], linewidth = 1) +
  geom_point(aes(colour = model), size = 2.5) +
  scale_colour_manual(values = model_cols) +
  scale_x_continuous(breaks = 1:9) +
  labs(title = "בימים 6 ו־8 הטיפול היה קצר מהממוצע בכל המודלים",
       subtitle = "השאריות לא בלתי תלויות: יש אפקט של היום (עומס, סוג התקלות)",
       x = "Day", y = "Residual (min)", colour = NULL)
```

אי-תלות: שאריות לפי היום

בימים 6 ו-8 הטיפול היה קצר מהממוצע בכל המודלים

השאריות לא בלתי תלויות: יש אפקט של היום (עומס, סוג התקלות)



מה עושים עם אפקט של היום?

- כל המודלים עבדו **באותם** ימים. ביום עמוס, או ביום של תקלה רחבה, הטיפול ארוך יותר בכולם. השאריות של אותו יום מתואמות
- **מה זה עושה למבחן?** ההבדלים בין הימים "נכנסים" ל-SS_E ומנפחים את MS_E. המבחן מאבד עוצמה
- **הפתרון:** להכניס את היום למודל כ**בלוק** (block). זה מודל עם שני פקטורים (הרצאה 6), והתכנון שלו נקרא בלוקים אקראיים (הרצאה על תכנון ניסויים)

```
summary(aov(aht ~ model + factor(day), data = calls))
```

```
             Df Sum Sq Mean Sq F value  Pr(>F)
model         4   18.0    4.51    17.4 1.1e-07 ***
factor(day)   8   25.9    3.23    12.5 6.6e-08 ***
Residuals    32    8.3    0.26
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- MS_E ירד מ-0.854 ל-0.259, ו-F של המודלים עלה מ-5.3 ל-17.4

מה עושים כשההנחות לא מתקיימות?

מה רואים	עד כמה זה חמור	מה עושים
סטייה קלה מנורמליות	לא חמור, במיוחד עם n גדול (משפט הגבול המרכזי על הממוצעים)	ממשיכים
התפלגות מוטה מאוד, ערכים חריגים	חמור: הממוצעים והשונויות רגישים לחריגים	טרנספורמציה ($\log y$), או Kruskal–Wallis (הרצאה הבאה)
שונויות לא שוות, ניסוי מאוזן	בינוני	ממשיכים בזהירות, או Welch
שונויות לא שוות, ניסוי **לא** מאוזן	**חמור**: רמת המובהקות האמיתית רחוקה מ-α	Welch ANOVA: `oneway.test()`
תלות בין התצפיות	**חמור**	משנים את המודל: בלוקים, מדידות חוזרות

סימולציה: כשהשונויות לא שוות

שלוש קבוצות עם **אותה תוחלת** (H_0 נכונה). בכמה מהניסויים מבחן F דוחה ב-$\alpha = 0.05$?

```
sim_reject <- function(n, sd, reps = 4000) {
  g <- factor(rep(seq_along(n), n))
  rejected <- replicate(reps, {
    y <- rnorm(sum(n), 0, rep(sd, n))
    c(oneway.test(y ~ g, var.equal = TRUE)$p.value, oneway.test(y ~ g)$p.value) < 0.05
  })
  rowMeans(rejected)   # rejection rate: classic F, Welch
}
set.seed(77)
tibble(design = c("balanced, equal sd", "balanced, unequal sd",
                  "small group has large sd", "large group has large sd"),
       n  = list(c(10, 10, 10), c(10, 10, 10), c(5, 10, 20), c(5, 10, 20)),
       sd = list(c(1, 1, 1),    c(3, 1, 1),    c(3, 1, 1),    c(1, 1, 3))) |>
  mutate(rate = map2(n, sd, sim_reject),
         F = map_dbl(rate, 1), Welch = map_dbl(rate, 2)) |>
  select(design, F, Welch)
```

```
# A tibble: 4 × 3
  design                          F  Welch
  <chr>                       <dbl>  <dbl>
1 balanced, equal sd         0.0472  0.0452
2 balanced, unequal sd       0.0788  0.0492
3 small group has large sd   0.241   0.0592
4 large group has large sd   0.00875 0.0475
```

Welch ANOVA ב-R

```r
oneway.test(aht ~ model, data = calls)                    # Welch: no equal variances
```

```
    One-way analysis of means (not assuming equal variances)

data:  aht and model
F = 4.5, num df = 4, denom df = 20, p-value = 0.009
```

```r
oneway.test(aht ~ model, data = calls, var.equal = TRUE)  # = the classic F test
```

```
    One-way analysis of means

data:  aht and model
F = 5.3, num df = 4, denom df = 40, p-value = 0.002
```

- כאן השונויות דומות, ושני המבחנים מסכימים

כמה תצפיות צריך? (Power)

עוצמה וגודל מדגם

עוצמה (power): ההסתברות לדחות את H_0 כשיש באמת הבדל. היא גדלה עם:

- גודל ההבדלים בין התוחלות (האות)
- מספר החזרות n
- ירידה ב-σ^2 (הרעש). למשל, בעזרת בלוקים

שאלה: בעוד חצי שנה המוקד ירצה לבדוק דור חדש של מודלים. אם ההבדלים בין המודלים דומים למה שראינו (שונות הממוצעים כ-0.5) ו-$\sigma^2 \approx 0.85$, כמה ימים צריך לכל מודל כדי לזהות הבדל בעוצמה של 90%?

```
power.anova.test(groups = 5, between.var = var(ai_est$mean), within.var = mse, power = 0.9)
```

```
     Balanced one-way analysis of variance power calculation

         groups = 5
              n = 7.584
    between.var = 0.5007
     within.var = 0.8536
      sig.level = 0.05
          power = 0.9

NOTE: n is number in each group
```

אפקטים אקראיים
(Random effects)

השאלה: האם השרתים שונים זה מזה?

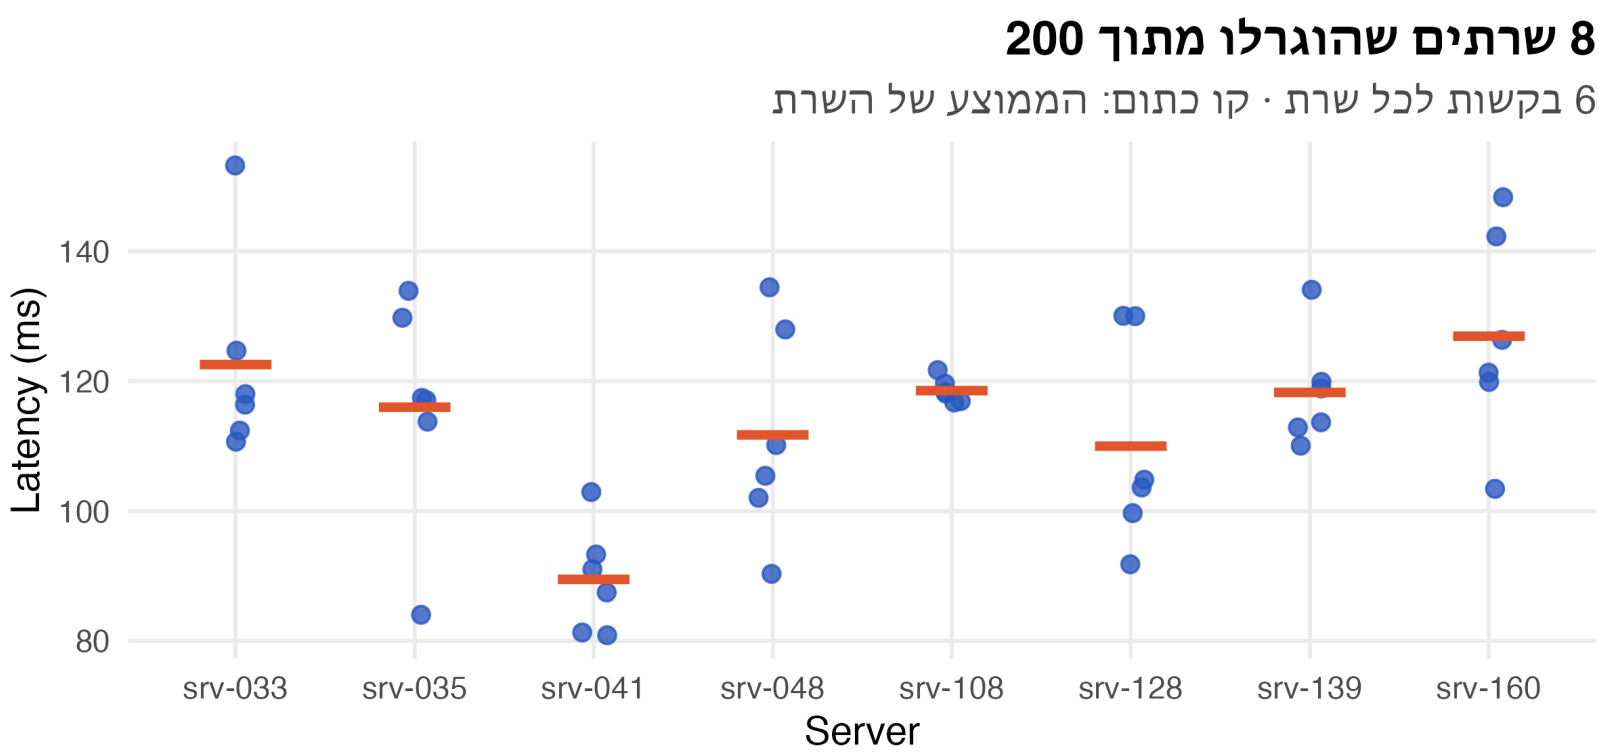
לשירות יש **200 שרתים** זהים, לכאורה. צוות התשתיות חושד שיש שרתים "איטיים" (חומרה ישנה, שכן רועש באותו מחשב פיזי).

- אי אפשר למדוד את כל 200 השרתים. **מגרילים 8 שרתים**, ושולחים לכל אחד 6 בקשות זהות
- **השאלה לא** "האם שרת 17 איטי משרת 112". השרתים שנבחרו לא מעניינים כשלעצמם
- **השאלה:** האם **באוכלוסיית השרתים** יש שונות בזמן התגובה? וכמה מהשונות הכוללת היא בין שרתים?

```
set.seed(404)
fleet <- tibble(server = sprintf("srv-%03d", 1:200), tau = rnorm(200, 0, 10))  # sd between servers: 10 ms
servers <- fleet |>
  slice_sample(n = 8) |>
  expand_grid(rep = 1:6) |>
  mutate(latency = round(120 + tau + rnorm(n(), 0, 15), 1),                    # sd within: 15 ms
         server = factor(server))
```

הנתונים

```
ggplot(servers, aes(server, latency)) +
  geom_point(colour = nanas_pal["primary"], size = 2.5, alpha = 0.8,
             position = position_jitter(width = 0.08, seed = 4)) +
  stat_summary(fun = mean, geom = "crossbar", width = 0.4, colour = nanas_pal["accent"]) +
  labels(title = "8 200 שרתים שהוגרלו מתוך",
       subtitle = "6 בקשות לכל שרת · קו כתום: הממוצע של השרת",
       x = "Server", y = "Latency (ms)")
```



המודל

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij} \qquad \tau_i \sim N(0, \sigma_\tau^2) \qquad \varepsilon_{ij} \sim N(0, \sigma^2)$$

- אותה נוסחה, אבל עכשיו τ_i הוא **משתנה מקרי**: השרת הוגרל
- τ_i ו-ε_{ij} בלתי תלויים. **אין** אילוץ $\sum \tau_i = 0$
- השונות של תצפית מתפרקת לשני **רכיבי שונות** (variance components):

$$V(y_{ij}) = \sigma_\tau^2 + \sigma^2$$

ההשערות הן על σ_τ^2, ולא על ה-τ_i עצמם:

$$H_0 : \sigma_\tau^2 = 0 \qquad H_1 : \sigma_\tau^2 > 0$$

המבחן והאומדים

סכומי הריבועים, הטבלה ו-$F_0 = MS_{Tr}/MS_E$ **זהים** למודל הקבוע. משתנה הפרשנות של התוחלות:

$$E(MS_E) = \sigma^2 \qquad E(MS_{Tr}) = \sigma^2 + n\sigma_\tau^2$$

תחת H_0 ($\sigma_\tau^2 = 0$) שניהם אומדים את σ^2, ולכן שוב $F_0 \sim F_{a-1,\,N-a}$. מכאן גם **אומדים לרכיבי השונות**:

$$\hat{\sigma}^2 = MS_E \qquad \hat{\sigma}_\tau^2 = \frac{MS_{Tr} - MS_E}{n}$$

מתאם תוך-קבוצתי (intraclass correlation, ICC): איזה חלק מהשונות הכוללת הוא בין הרמות?

$$\rho = \frac{\sigma_\tau^2}{\sigma_\tau^2 + \sigma^2}$$

בחזרה לשרתים

```r
fit_srv <- aov(latency ~ server, data = servers)
summary(fit_srv)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
server       7   5433     776    4.12 0.0017 **
Residuals   40   7535     188
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
ms <- summary(fit_srv)[[1]][["Mean Sq"]]
c(sigma2_hat = ms[2], sigma2_tau_hat = (ms[1] - ms[2]) / 6,
  icc = ((ms[1] - ms[2]) / 6) / ((ms[1] - ms[2]) / 6 + ms[2]))
```

```
    sigma2_hat sigma2_tau_hat           icc
      188.3674        97.9592        0.3421
```

- דוחים את H_0 ($p = 0.0017$)
- סטיית התקן בין שרתים נאמדת ב-$\sqrt{\hat{\sigma}^2_\tau} = 9.9$ מילישניות (האמת בסימולציה: 10), ובתוך שרת ב-13.7 (האמת: 15)
- כ-34% מהשונות בזמן התגובה נובעת מהבדלים בין שרתים. **ההחלטה:** האם שווה לאתר ולהחליף שרתים איטיים, או שרוב הבעיה היא בתוך כל שרת?

קבוע או אקראי?

	אפקטים קבועים	אפקטים אקראיים
הרמות	כל הרמות שמעניינות אותנו	מדגם מקרי מתוך הרבה רמות
דוגמאות	5 המודלים שהמוקד שקל, 3 גרסאות של מוצר, 4 נוסחים של פרומפט	שרתים מתוך צי, מוקדנים מתוך מוקד, אצוות של חומר גלם
τ_i	קבועים, $\sum \tau_i = 0$	משתנים מקריים, $N(0, \sigma_\tau^2)$
H_0	$\tau_1 = \cdots = \tau_a = 0$	$\sigma_\tau^2 = 0$
מה אומדים	μ_i והפרשים ביניהן	רכיבי שונות σ_τ^2, σ^2, ICC
המסקנה חלה על	הרמות שנבדקו	כל אוכלוסיית הרמות

שאלת מבחן: "אם נחזור על הניסוי, האם נבדוק את אותן רמות?" אם כן: קבוע. אם נגריל רמות חדשות: אקראי.

מה יכול להשתבש

חמש מלכודות

1. **אין הגרלה:** אם M1 הופעל רק בימי ראשון העמוסים, ההבדל הוא של היום ולא של המודל. ניתוח שונות לא מתקן תכנון גרוע
2. **חזרות מדומות** (pseudo-replication): 8 בקשות לאותו שרת **אינן** 8 שרתים. ב-N סופרים את היחידות שהוגרלו, לא את המדידות
3. **"לא מובהק" אינו "שווה":** אם לא דחינו, ייתכן שפשוט אין מספיק עוצמה. בודקים רווחי סמך וגודל מדגם
4. **מובהק אינו חשוב:** עם מספיק נתונים, גם הבדל של שנייה אחת יהיה מובהק. מדווחים את גודל האפקט (שקף הבא)
5. **מבחני t מרובים במקום F:** עם הרבה רמות, הבדל מקרי "יימצא" כמעט בוודאות

גודל אפקט (Effect size): η^2

$$\eta^2 = \frac{SS_{Tr}}{SS_T}$$

- החלק מהשונות הכוללת שמוסבר על ידי הפקטור. זה בדיוק R^2 של הרגרסיה המקבילה
- למודלים: $\eta^2 = 18.02/52.17 = 0.35$. המודל מסביר כשליש מהשונות במשך הטיפול

```
tab <- summary(fit_ai)[[1]]
c(eta2 = tab[1, "Sum Sq"] / sum(tab[, "Sum Sq"]), R2_lm = summary(fit_ai_lm)$r.squared)
```

```
  eta2  R2_lm 
0.3455 0.3455 
```

סיכום

מה לקחת מההרצאה

השאלה	הכלי	ב-R
האם יש הבדל בין a רמות של פקטור?	מבחן F, $F_{a-1,\,N-a}$	`summary(aov(y ~ g))`
מהי השונות של הרעש?	$\hat{\sigma}^2 = MS_E$	`Mean Sq` של `Residuals`
מהי התוחלת ברמה i?	$\bar{y}_{i\cdot} \pm t\sqrt{MS_E/n}$	
האם ההנחות מתקיימות?	Bartlett/Levene, שאריות לפי סדר, Q-Q	`resid()`, `bartlett.test()`
שונויות לא שוות?	Welch ANOVA	`oneway.test()`
כמה חזרות צריך?	ניתוח עוצמה	`power.anova.test()`
הרמות הן מדגם מאוכלוסייה?	אפקטים אקראיים, ICC, $\hat{\sigma}^2_\tau$	אותו `aov()`, פרשנות אחרת
כמה הפקטור מסביר?	$\eta^2 = SS_{Tr}/SS_T$	

- ניתוח שונות חד-כיווני הוא רגרסיה עם משתנה קטגורי אחד
- דחייה של H_0 אומרת שיש הבדל **איפשהו**. **בהרצאה הבאה:** איפה (ניגודים והשוואות מרובות), ומה עושים כשהנתונים רחוקים מנורמליות (Kruskal–Wallis)