5. ניגודים, השוואות מרובות וניתוח שונות א-פרמטרי

ניתוח נתונים סטטיסטי · הרצאה 5

ד״ר עדי שריד

2026-11-09

על מה נדבר היום

- **חזרה והשלמה מהרצאה 4:** בדיקת ההנחות, שונויות לא שוות, אפקטים אקראיים, גודל אפקט
- **ניגודים** (contrasts): שאלות ספציפיות שתכננו מראש
- **השוואות מרובות:** למה 10 מבחני t הם בעיה
  - שיטת Duncan
  - שיטת Tukey (HSD)
- **ניתוח שונות א-פרמטרי:**
  - Kruskal–Wallis: כמה מדגמים בלתי תלויים
  - ניגודים עם חציונים

חזרה: ניתוח שונות חד-כיווני

המודל וההשערות

a **רמות** של פקטור אחד, n **תצפיות** בכל רמה, $N = an$:

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij} \qquad \sum_{i=1}^{a} \tau_i = 0 \qquad \varepsilon_{ij} \overset{iid}{\sim} N(0, \sigma^2)$$

$$H_0 : \tau_1 = \cdots = \tau_a = 0 \quad (\mu_1 = \cdots = \mu_a) \qquad H_1 : \tau_i \neq 0 \text{ כלשהו } i \text{ עבור}$$

שלוש הנחות: נורמליות, אי-תלות, שונות שווה בכל הרמות.

הדוגמה: מוקד שירות בוחר את מודל השפה לעוזר AI. 5 מודלים (M1, M2 קטנים, M3 בינוני, M4, M5 גדולים), 9 ימים לכל מודל, והתגובה היא משך הטיפול הממוצע בפנייה (דקות). האם יש הבדל, ואיזה מודל להפעיל?

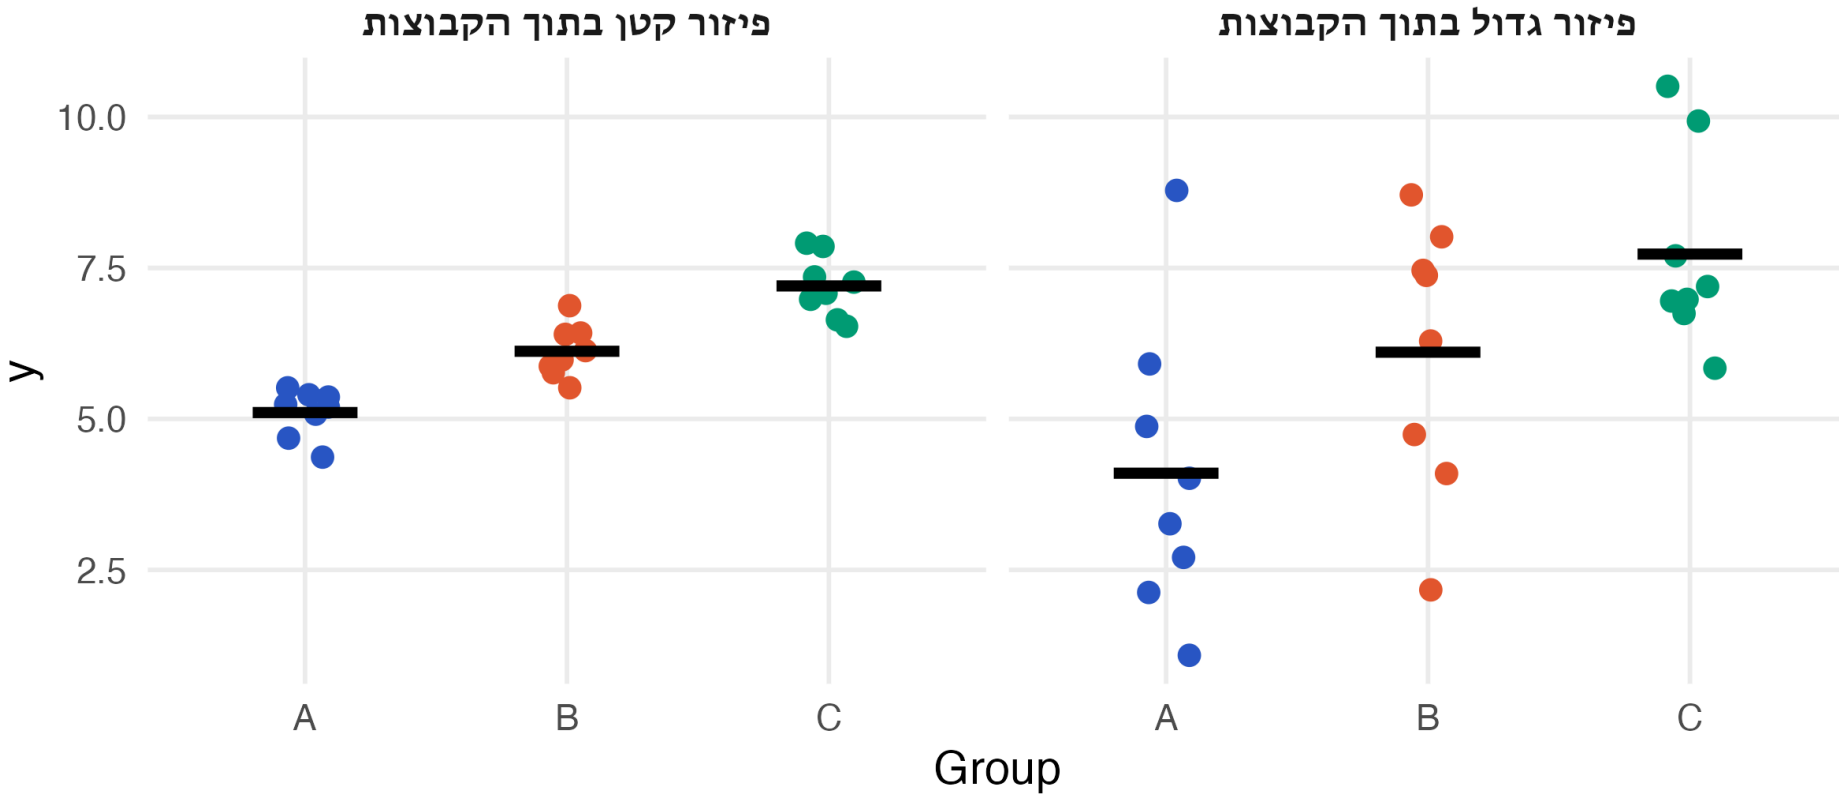
```
calls |> group_by(model) |> summarise(total = sum(aht), mean = mean(aht))
```

```
# A tibble: 5 × 3
  model total  mean
  <fct> <dbl> <dbl>
1 M1     45.0  5.00
2 M2     48.0  5.33
3 M3     36.0  3.99
4 M4     33.9  3.76
5 M5     35.6  3.96
```

הרעיון: אות מול רעש

אותם הבדלים בין הממוצעים, מסקנה שונה

השאלה היא לא אם הממוצעים שונים, אלא אם הם שונים יותר ממה שהרעש מסביר



פירוק השונות וטבלת ANOVA

$$\underbrace{\sum_{i,j}(y_{ij}-\bar{y}_{\cdot\cdot})^2}_{SS_T} = \underbrace{n\sum_{i}(\bar{y}_{i\cdot}-\bar{y}_{\cdot\cdot})^2}_{SS_{Tr}:\ \text{בין הרמות}} + \underbrace{\sum_{i,j}(y_{ij}-\bar{y}_{i\cdot})^2}_{SS_E:\ \text{בתוך הרמות}}$$

מקור	סכום ריבועים	דרגות חופש	ממוצע ריבועים	F_0
בין הרמות	SS_{Tr}	$a-1$	MS_{Tr}	MS_{Tr}/MS_E
שגיאה	SS_E	$N-a$	$MS_E=\hat{\sigma}^2$	
סך הכול	SS_T	$N-1$		

- $E(MS_E)=\sigma^2$ תמיד. $E(MS_{Tr})=\sigma^2+\frac{n\sum\tau_i^2}{a-1}$
- דוחים את H_0 אם $F_0 > F_{1-\alpha;\,a-1,\,N-a}$

בדיקת ההנחות: השאריות

$$e_{ij} = y_{ij} - \hat{y}_{ij} = y_{ij} - \bar{y}_{i\cdot}$$

השאריות הן האומדים לשגיאות ε_{ij}. כל ההנחות נבדקות דרכן:

ההנחה	בדיקה גרפית	בדיקה במבחן
נורמליות	גרף Q-Q	Shapiro–Wilk, KS
אי-תלות	שאריות לפי סדר האיסוף	
שונות שווה	boxplot, שאריות מול ממוצעי הרמות	Bartlett, Levene

```
calls_r <- calls |> mutate(fitted = fitted(fit_ai), resid = resid(fit_ai))
calls_r |> select(day, model, aht, fitted, resid) |> head(3)
```

```
# A tibble: 3 × 5
    day model   aht fitted   resid
  <dbl> <fct> <dbl>  <dbl>   <dbl>
1     1 M1     4.98   5.00 -0.0222
2     1 M2     5.29   5.33 -0.0444
3     1 M3     4.51   3.99  0.516
```

גרף Q-Q: איך בונים אותו

1. ממיינים את N השאריות מהקטנה לגדולה: $e_{(1)} \le e_{(2)} \le \cdots \le e_{(N)}$
2. לשארית ה-k בסדר מתאימים את **האחוזון** $p_k = \dfrac{k - 0.5}{N}$
3. מחשבים את **הערך התיאורטי** של $N(0,1)$ באחוזון הזה: $z_k = \Phi^{-1}(p_k)$
4. משרטטים את $e_{(k)}$ (ציר אנכי) מול z_k (ציר אופקי)

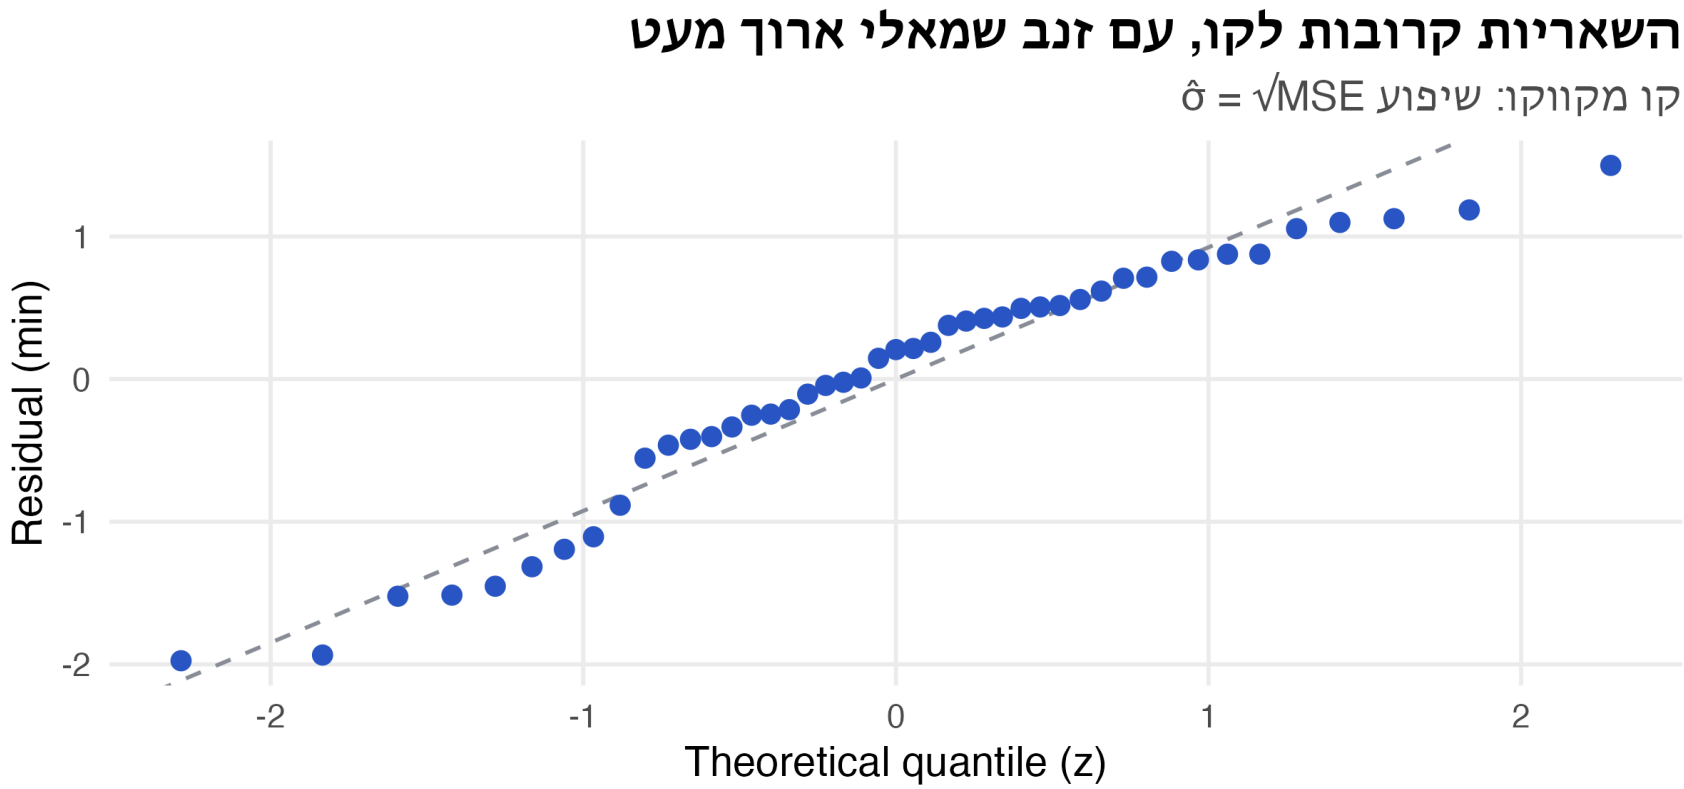
אם השאריות נורמליות, הנקודות על קו ישר (השיפוע הוא בערך $\hat{\sigma}$).

```
qq <- calls_r |>
  arrange(resid) |>
  mutate(k = row_number(), p = (k - 0.5) / n(), z = qnorm(p))
qq |> select(resid, k, p, z) |> slice(c(1, 2, 45))
```

```
# A tibble: 3 × 4
  resid     k      p     z
  <dbl> <int>  <dbl> <dbl>
1 -1.97     1 0.0111 -2.29
2 -1.93     2 0.0333 -1.83
3  1.50    45 0.989   2.29
```

גרף Q-Q למודלים

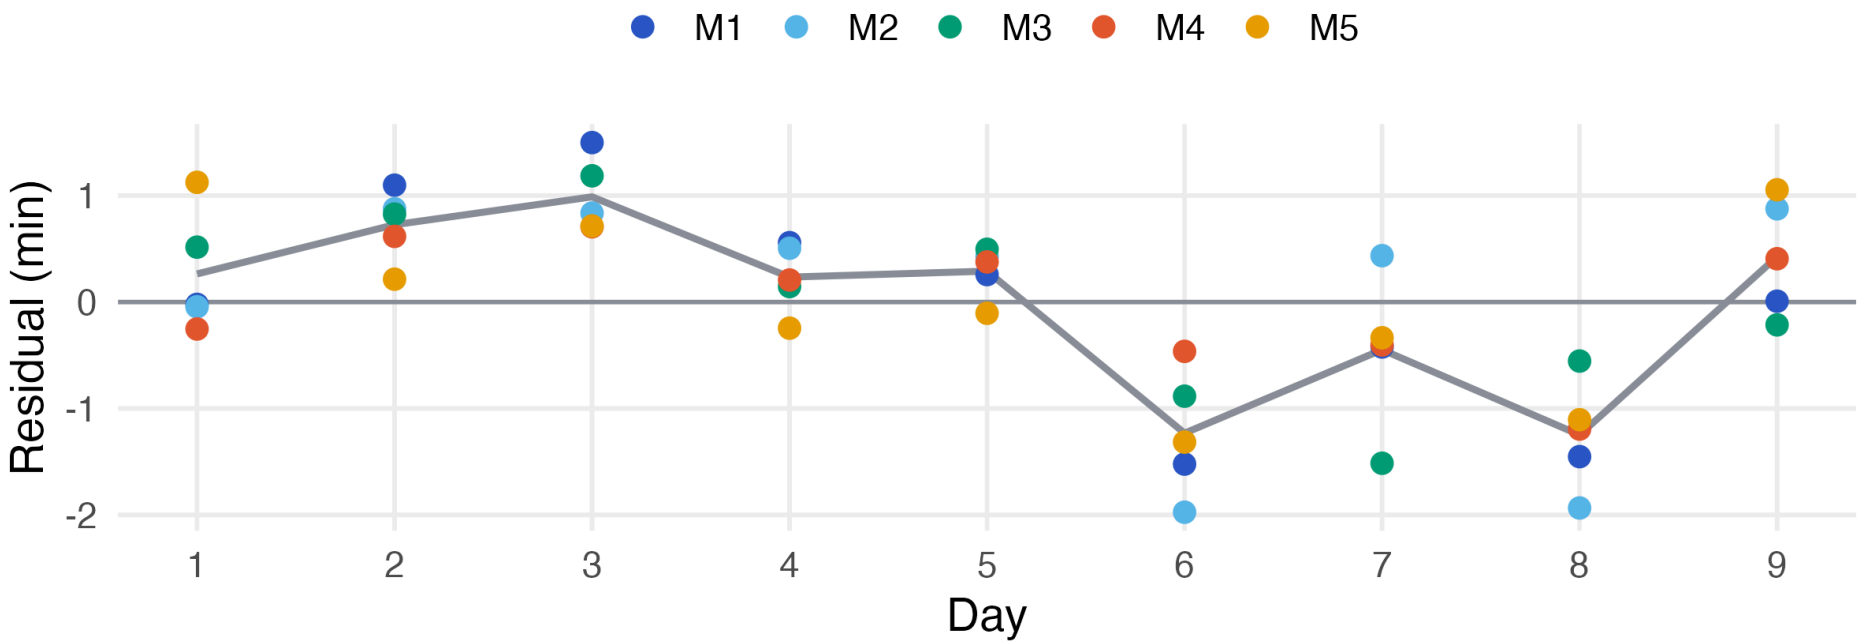
```
ggplot(qq, aes(z, resid)) +
  geom_abline(intercept = 0, slope = sqrt(mse), colour = nanas_pal[["grey"]], linetype = "dashed") +
  geom_point(size = 2.5) +
  labs(title = "השאריות קרובות לקו, עם זנב שמאלי ארוך מעט",
       subtitle = "קו מקווקו: שיפוע σ̂ = √MSE",
       x = "Theoretical quantile (z)", y = "Residual (min)")
```



אי-תלות: שאריות לפי היום

בימים 6 ו-8 הטיפול היה קצר מהממוצע בכל המודלים

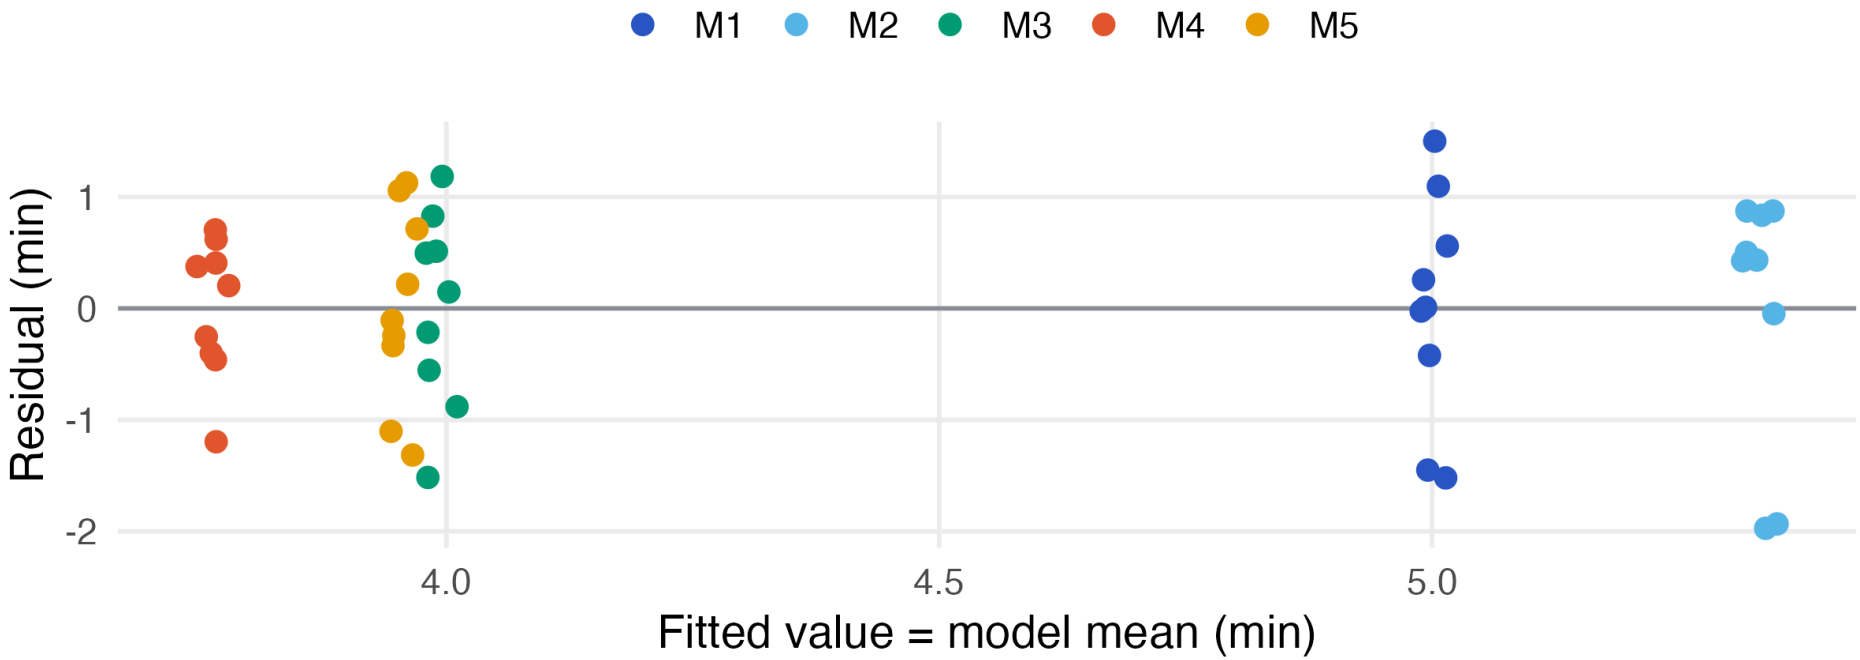
השאריות לא בלתי תלויות: יש אפקט של היום (עומס, סוג התקלות)



- אפקט היום "נכנס" ל-SS_E ומנפח את MS_E. הפתרון: היום כ**בלוק** במודל. נגיע לזה בהרצאה 6 (ניתוח שונות רב-כיווני)

שונות שווה: שאריות מול ממוצעי הרמות

הפיזור דומה בכל הרמות



- כל עמודה היא רמה אחת. מחפשים **פיזור אנכי דומה** בכל העמודות
- סימן אזהרה: "משפך", כשהפיזור גדל עם הממוצע. אצלנו M4 צפוף מעט יותר, אבל אין דפוס ברור

מבחן Bartlett

$H_0 : \sigma_1^2 = \cdots = \sigma_a^2$ מול H_1: לפחות שונות אחת שונה.

- **זהירות:** המבחן רגיש מאוד לסטייה מנורמליות. כשהשאריות לא נורמליות, משתמשים במבחן Levene

```
round(tapply(calls$aht, calls$model, var), 2)
```

```
  M1   M2   M3   M4   M5
1.05 1.31 0.76 0.39 0.76
```

```
bartlett.test(aht ~ model, data = calls)
```

```
    Bartlett test of homogeneity of variances

data:  aht by model
Bartlett's K-squared = 3, df = 4, p-value = 0.6
```

ANOVA של Welch

מבחן F הקלאסי מאחד את כל S_i^2 ל-MS_E אחד. כשהשונויות שונות, MS_E אחד לא מתאים לאף קבוצה. Welch נותן לכל קבוצה את השונות שלה:

$$w_i = \frac{n_i}{S_i^2}, \qquad \bar{y}_w = \frac{\sum_i w_i \bar{y}_{i\cdot}}{\sum_i w_i}, \qquad F_W \approx \frac{\frac{1}{a-1}\sum_i w_i(\bar{y}_{i\cdot} - \bar{y}_w)^2}{1 + (\text{small correction})}$$

- w_i הוא אחד חלקי השונות של $\bar{y}_{i\cdot}$: ממוצע **מדויק** (קבוצה גדולה, פיזור קטן) מקבל משקל גבוה, ממוצע **רועש** מקבל משקל נמוך
- $F_W \sim F_{a-1,\,\nu}$, עם פחות דרגות חופש במכנה מ-$N-a$ (ν מחושב מהנתונים). המחיר: קצת פחות עוצמה כשהשונויות באמת שוות
- ב-R זו ברירת המחדל של `oneway.test()`. במודלים (שונויות דומות) המסקנה זהה ל-F הקלאסי:

```
oneway.test(aht ~ model, data = calls)
```

```
    One-way analysis of means (not assuming equal variances)

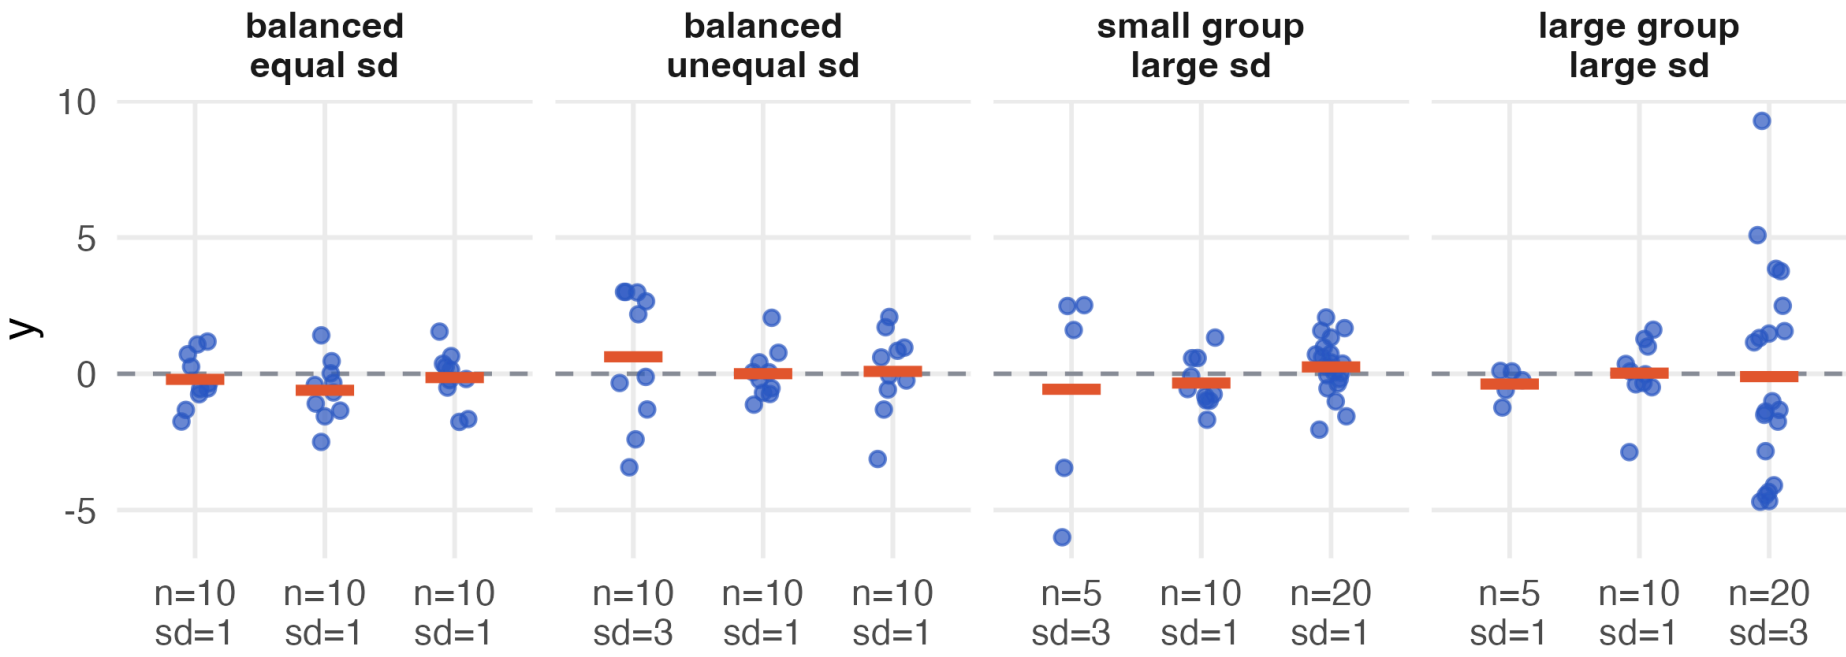
data:  aht and model
F = 4.5, num df = 4, denom df = 20, p-value = 0.009
```

סימולציה: ארבעה תרחישים

בכל התרחישים **התוחלת זהה בשלוש הקבוצות** (H_0 נכונה). משתנים רק גודל הקבוצות והפיזור בתוכן. כך נראה ניסוי אחד מכל תרחיש:

אותה תוחלת בכל הקבוצות (קו מקווקו), ממוצעים מדגמיים שונים

קו כתום: הממוצע של כל קבוצה בניסוי הזה



סימולציה: כשהשונויות לא שוות

שלוש קבוצות עם **אותה תוחלת** (H_0 נכונה). בכמה מהניסויים מבחן F דוחה ב-$\alpha = 0.05$?

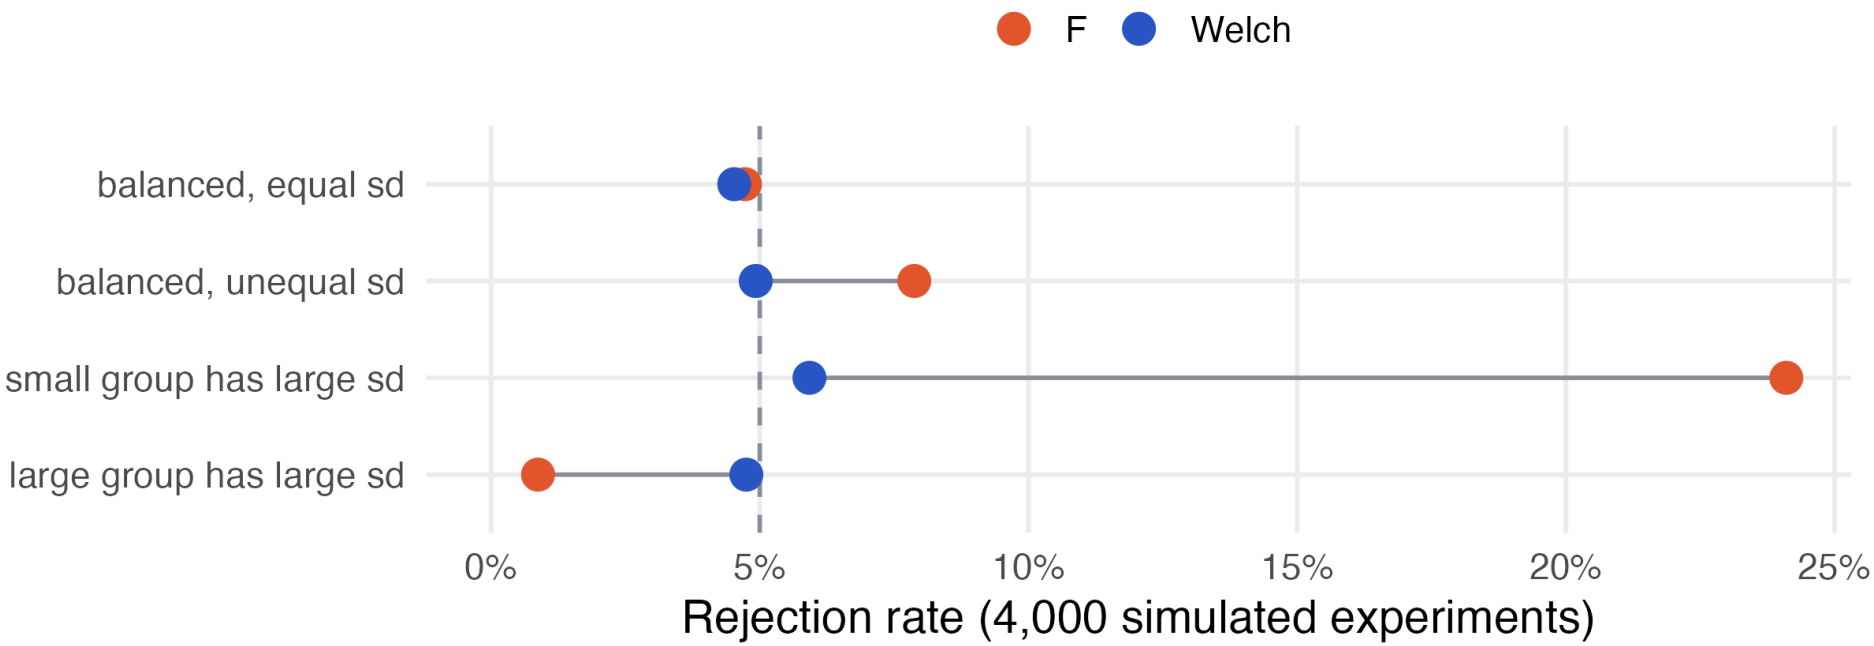
```
sim_reject <- function(n, sd, reps = 4000) {
  g <- factor(rep(seq_along(n), n))
  rejected <- replicate(reps, {
    y <- rnorm(sum(n), 0, rep(sd, n))
    c(oneway.test(y ~ g, var.equal = TRUE)$p.value, oneway.test(y ~ g)$p.value) < 0.05
  })
  rowMeans(rejected)   # rejection rate: classic F, Welch
}
set.seed(77)
sim_res <- tibble(design = c("balanced, equal sd", "balanced, unequal sd",
                             "small group has large sd", "large group has large sd"),
                  n  = list(c(10, 10, 10), c(10, 10, 10), c(5, 10, 20), c(5, 10, 20)),
                  sd = list(c(1, 1, 1),    c(3, 1, 1),    c(3, 1, 1),    c(1, 1, 3))) |>
  mutate(rate = map2(n, sd, sim_reject),
         F = map_dbl(rate, 1), Welch = map_dbl(rate, 2))
sim_res |> select(design, F, Welch)
```

```
# A tibble: 4 × 3
  design                          F  Welch
  <chr>                       <dbl>  <dbl>
1 balanced, equal sd         0.0472 0.0452
2 balanced, unequal sd       0.0788 0.0492
3 small group has large sd   0.241  0.0592
4 large group has large sd   0.00875 0.0475
```

התוצאה בתרשים

כמה פעמים המבחן דוחה H0 נכונה?

קו מקווקו: 5%, השיעור שהמבחן אמור לדחות



- **ניסוי לא מאוזן + שונויות שונות = בעיה.** כשלקבוצה הקטנה יש שונות גדולה, F דוחה הרבה יותר מ-5%. Welch (`oneway.test()`) נשאר קרוב ל-5%

השלמה מהרצאה 4: אפקטים אקראיים (Random effects)

השאלה: האם השרתים שונים זה מזה?

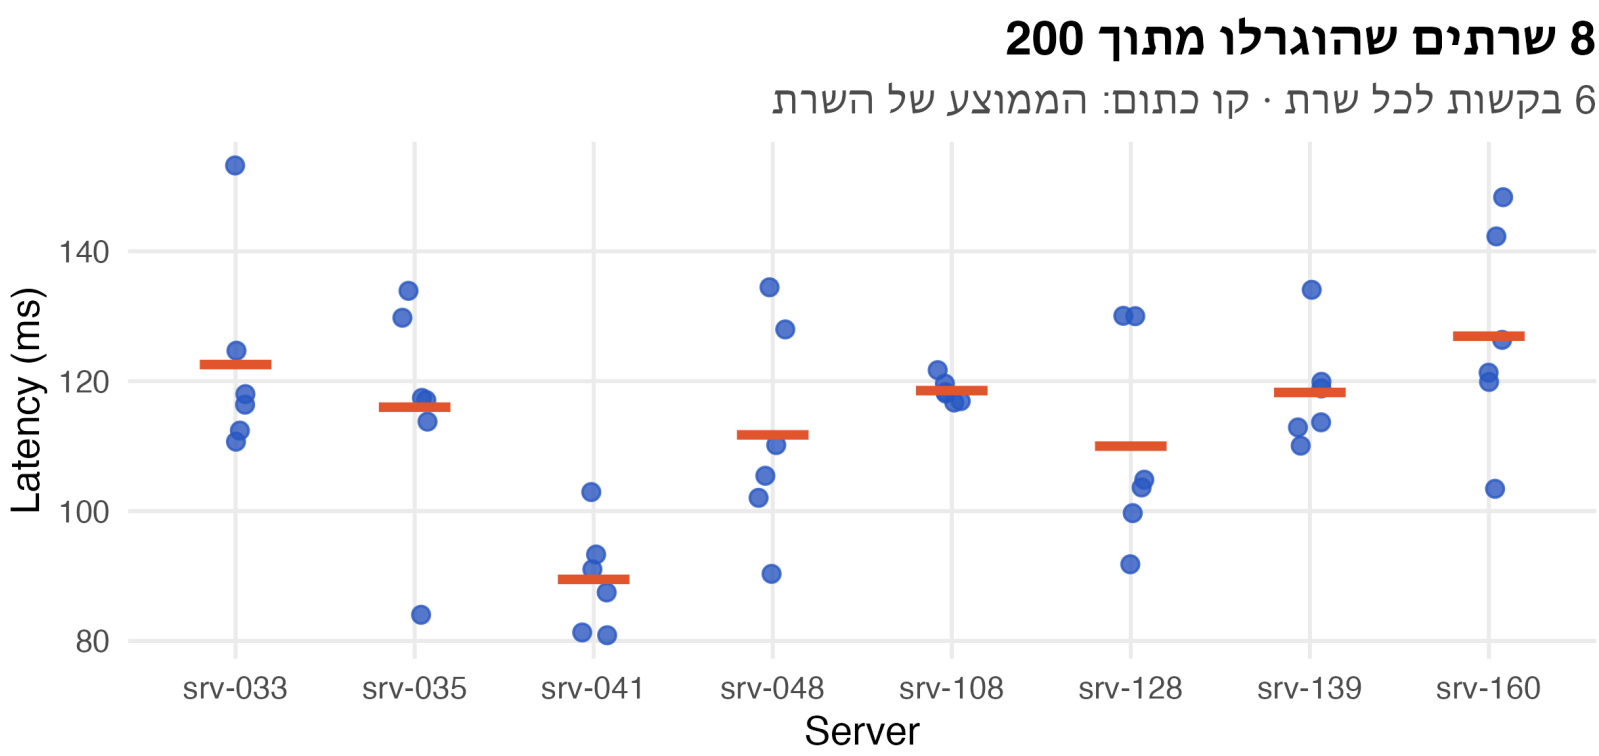
לשירות יש **200 שרתים** זהים, לכאורה. צוות התשתיות חושד שיש שרתים "איטיים" (חומרה ישנה, שכן רועש באותו מחשב פיזי).

- אי אפשר למדוד את כל 200 השרתים. **מגרילים 8 שרתים**, ושולחים לכל אחד 6 בקשות זהות
- **השאלה לא** "האם שרת 17 איטי משרת 112". השרתים שנבחרו לא מעניינים כשלעצמם
- **השאלה:** האם **באוכלוסיית השרתים** יש שונות בזמן התגובה? וכמה מהשונות הכוללת היא בין שרתים?

```
set.seed(404)
fleet <- tibble(server = sprintf("srv-%03d", 1:200), tau = rnorm(200, 0, 10))  # sd between servers: 10 ms
servers <- fleet |>
  slice_sample(n = 8) |>
  expand_grid(rep = 1:6) |>
  mutate(latency = round(120 + tau + rnorm(n(), 0, 15), 1),                    # sd within: 15 ms
         server = factor(server))
```

הנתונים

```
ggplot(servers, aes(server, latency)) +
  geom_point(colour = nanas_pal["primary"], size = 2.5, alpha = 0.8,
             position = position_jitter(width = 0.08, seed = 4)) +
  stat_summary(fun = mean, geom = "crossbar", width = 0.4, colour = nanas_pal["accent"]) +
  labels(title = "8 200 שרתים שהוגרלו מתוך",
       subtitle = "6 בקשות לכל שרת · קו כתום: הממוצע של השרת",
       x = "Server", y = "Latency (ms)")
```



המודל

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij} \qquad \tau_i \sim N(0, \sigma_\tau^2) \qquad \varepsilon_{ij} \sim N(0, \sigma^2)$$

- אותה נוסחה, אבל עכשיו τ_i הוא **משתנה מקרי**: השרת הוגרל
- τ_i ו-ε_{ij} בלתי תלויים. **אין** אילוץ $\sum \tau_i = 0$
- השונות של תצפית מתפרקת לשני **רכיבי שונות** (variance components):

$$V(y_{ij}) = \sigma_\tau^2 + \sigma^2$$

ההשערות הן על σ_τ^2, ולא על ה-τ_i עצמם:

$$H_0 : \sigma_\tau^2 = 0 \qquad H_1 : \sigma_\tau^2 > 0$$

המבחן והאומדים

סכומי הריבועים, הטבלה ו-$F_0 = MS_{Tr}/MS_E$ **זהים** למודל הקבוע. משתנה הפרשנות של התוחלות:

$$E(MS_E) = \sigma^2 \qquad E(MS_{Tr}) = \sigma^2 + n\sigma_\tau^2$$

תחת H_0 ($\sigma_\tau^2 = 0$) שניהם אומדים את σ^2, ולכן שוב $F_0 \sim F_{a-1,\,N-a}$. מכאן גם **אומדים לרכיבי השונות**:

$$\hat{\sigma}^2 = MS_E \qquad \hat{\sigma}_\tau^2 = \frac{MS_{Tr} - MS_E}{n}$$

מתאם תוך-קבוצתי (intraclass correlation, ICC): איזה חלק מהשונות הכוללת הוא בין הרמות?

$$\rho = \frac{\sigma_\tau^2}{\sigma_\tau^2 + \sigma^2}$$

למה $E(MS_{Tr}) = \sigma^2 + n\sigma_\tau^2$?

עובדה אחת: **שונות מדגמית היא אומד חסר הטיה לשונות.**

1. הממוצע של רמה i, ו-τ_i משתנה מקרי בלתי תלוי בשגיאות:

$$\bar{y}_{i\cdot} = \mu + \tau_i + \bar{\varepsilon}_{i\cdot} \quad \Rightarrow \quad V(\bar{y}_{i\cdot}) = \sigma_\tau^2 + \frac{\sigma^2}{n}$$

2. הרמות הוגרלו, ולכן $\bar{y}_{1\cdot}, \ldots, \bar{y}_{a\cdot}$ הם מדגם של a ערכים בלתי תלויים מאותה התפלגות. השונות המדגמית שלהם, $S_{\bar{y}}^2 = \frac{1}{a-1}\sum_i (\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot})^2$, חסרת הטיה: $E(S_{\bar{y}}^2) = \sigma_\tau^2 + \frac{\sigma^2}{n}$
3. ב-SS_{Tr} כל תצפית מוחלפת בממוצע הרמה שלה: $SS_{Tr} = \sum_i \sum_{j=1}^{n} (\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot})^2$. האיבר לא תלוי ב-$j$, ולכן הוא נספר n פעמים:

$$MS_{Tr} = \frac{SS_{Tr}}{a-1} = n \cdot \frac{\sum_i (\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot})^2}{a-1} = nS_{\bar{y}}^2 \quad \Rightarrow \quad E(MS_{Tr}) = n\sigma_\tau^2 + \sigma^2$$

במודל הקבוע τ_i הם קבועים. בשלב 1 נשאר רק σ^2/n, ובמקום σ_τ^2 מופיע $\frac{\sum \tau_i^2}{a-1}$: הפיזור של האפקטים שנבחרו, במקום השונות של אוכלוסיית האפקטים.

בחזרה לשרתים

```r
fit_srv <- aov(latency ~ server, data = servers)
summary(fit_srv)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
server       7   5433     776    4.12 0.0017 **
Residuals   40   7535     188
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
ms_srv <- summary(fit_srv)[[1]][["Mean Sq"]]
c(sigma2_hat = ms_srv[2], sigma2_tau_hat = (ms_srv[1] - ms_srv[2]) / 6,
  icc = ((ms_srv[1] - ms_srv[2]) / 6) / ((ms_srv[1] - ms_srv[2]) / 6 + ms_srv[2]))
```

```
    sigma2_hat sigma2_tau_hat           icc
      188.3674        97.9592        0.3421
```

- דוחים את H_0 ($p = 0.0017$)
- סטיית התקן בין שרתים נאמדת ב-$\sqrt{\hat{\sigma}_\tau^2} = 9.9$ מילישניות (האמת בסימולציה: 10), ובתוך שרת ב-13.7 (האמת: 15)
- כ-34% מהשונות בזמן התגובה נובעת מהבדלים בין שרתים. **ההחלטה:** האם שווה לאתר ולהחליף שרתים איטיים, או שרוב הבעיה היא בתוך כל שרת?

קבוע או אקראי?

	אפקטים קבועים	אפקטים אקראיים
הרמות	כל הרמות שמעניינות אותנו	מדגם מקרי מתוך הרבה רמות
דוגמאות	5 המודלים שהמוקד שקל, 3 גרסאות של מוצר, 4 נוסחים של פרומפט	שרתים מתוך צי, מוקדנים מתוך מוקד, אצוות של חומר גלם
τ_i	קבועים, $\sum \tau_i = 0$	משתנים מקריים, $N(0, \sigma_\tau^2)$
H_0	$\tau_1 = \cdots = \tau_a = 0$	$\sigma_\tau^2 = 0$
מה אומדים	μ_i והפרשים ביניהן	רכיבי שונות σ_τ^2, σ^2, ICC
המסקנה חלה על	הרמות שנבדקו	כל אוכלוסיית הרמות

שאלת מבחן: "אם נחזור על הניסוי, האם נבדוק את אותן רמות?" אם כן: קבוע. אם נגריל רמות חדשות: אקראי.

השלמה מהרצאה 4: מה יכול להשתבש

חמש מלכודות בניתוח שונות

1. **אין הגרלה:** אם M1 הופעל רק בימי ראשון העמוסים, ההבדל הוא של היום ולא של המודל. ניתוח שונות לא מתקן תכנון גרוע
2. **חזרות מדומות** (pseudo-replication): 8 בקשות לאותו שרת **אינן** 8 שרתים. ב-N סופרים את היחידות שהוגרלו, לא את המדידות
3. **"לא מובהק" אינו "שווה":** אם לא דחינו, ייתכן שפשוט אין מספיק עוצמה. בודקים רווחי סמך וגודל מדגם
4. **מובהק אינו חשוב:** עם מספיק נתונים, גם הבדל של שנייה אחת יהיה מובהק. מדווחים את גודל האפקט (שקף הבא)
5. **מבחני t מרובים במקום F:** עם הרבה רמות, הבדל מקרי "יימצא" כמעט בוודאות

גודל אפקט (Effect size): η^2

$$\eta^2 = \frac{SS_{Tr}}{SS_T}$$

- החלק מהשונות הכוללת שמוסבר על ידי הפקטור. זה בדיוק R^2 של הרגרסיה המקבילה
- למודלים: $\eta^2 = 18.02/52.17 = 0.35$. המודל מסביר כשליש מהשונות במשך הטיפול

```
aov_tab <- summary(fit_ai)[[1]]
c(eta2 = aov_tab[1, "Sum Sq"] / sum(aov_tab[, "Sum Sq"]),
  R2_lm = summary(lm(aht ~ model, data = calls))$r.squared)
```

```
  eta2  R2_lm
0.3455 0.3455
```

סיכום הרצאה 4

השאלה	הכלי	ב-R
האם יש הבדל בין a רמות של פקטור?	מבחן F, $F_{a-1,\,N-a}$	`summary(aov(y ~ g))`
מהי השונות של הרעש?	$\hat{\sigma}^2 = MS_E$	`Mean Sq` של `Residuals`
מהי התוחלת ברמה i?	$\bar{y}_{i\cdot} \pm t\sqrt{MS_E/n}$	
האם ההנחות מתקיימות?	Bartlett/Levene, שאריות לפי סדר, Q-Q	`resid()`, `bartlett.test()`
שונויות לא שוות?	Welch ANOVA	`oneway.test()`
כמה חזרות צריך?	ניתוח עוצמה	`power.anova.test()`
הרמות הן מדגם מאוכלוסייה?	אפקטים אקראיים, ICC, $\hat{\sigma}^2_\tau$	אותו `aov()`, פרשנות אחרת
כמה הפקטור מסביר?	$\eta^2 = SS_{Tr}/SS_T$	

מכאן: איפה ההבדל?

התוצאה למודלים

```
summary(fit_ai)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
model        4   18.0    4.51    5.28 0.0016 **
Residuals   40   34.1    0.85
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- $F_0 = 5.28 > F_{0.95;\,4,\,40} = 2.61$: **יש הבדל בין המודלים**
- $MS_E = 0.854$, ולכן $\hat{\sigma} = 0.92$ דקות
- **אבל** מבחן ה-F לא אומר **בין מי למי**. עם M1 ו-M2 הטיפול נראה ארוך, ועם M3, M4 ו-M5 קצר. האם זה אמיתי?

שתי דרכים לענות:

1. **ניגודים:** שאלות ספציפיות שניסחנו **לפני** שראינו את הנתונים
2. **השוואות מרובות:** כל הזוגות, עם תיקון לכך שבודקים הרבה

ניגודים (Contrasts)

שאלות ספציפיות

לפני הניסוי, ראש צוות ה-AI במוקד שאל שתי שאלות:

- **האם מודלים גדולים מקצרים את הטיפול?** M1 ו-M2 קטנים, M4 ו-M5 גדולים
- **האם M3 שונה מ-M4?** שניהם מאותה משפחת מודלים: M3 הוא הגרסה הבינונית והזולה, M4 הגרסה הגדולה

את השאלות אפשר לכתוב כהשערות על **צירוף לינארי** של התוחלות:

$$H_0 : \frac{1}{2}(\mu_1 + \mu_2) = \frac{1}{2}(\mu_4 + \mu_5) \quad \Longleftrightarrow \quad H_0 : \mu_1 + \mu_2 - \mu_4 - \mu_5 = 0$$

$$H_0 : \mu_3 = \mu_4 \quad \Longleftrightarrow \quad H_0 : \mu_3 - \mu_4 = 0$$

הגדרה

ניגוד (contrast) הוא צירוף לינארי של התוחלות, שסכום המקדמים שלו אפס:

$$\Gamma = \sum_{i=1}^{a} c_i \mu_i, \qquad \sum_{i=1}^{a} c_i = 0$$

השאלה	c_1	c_2	c_3	c_4	c_5
קטנים מול גדולים	1	1	0	−1	−1
M4 מול M3	0	0	1	−1	0

- **למה** $\sum c_i = 0$**?** כי אז $\sum c_i \mu_i = \sum c_i (\mu + \tau_i) = \sum c_i \tau_i$. ה-$\mu$ מתבטל, והניגוד מודד רק **הבדלים** בין הרמות
- כל השוואה בין שתי רמות היא ניגוד: $c = (1, -1, 0, \ldots)$

האומד והשונות שלו

האומד: מחליפים כל תוחלת בממוצע של הרמה:

$$\hat{\Gamma} = \sum_{i=1}^{a} c_i \bar{y}_{i\cdot}$$

התוחלת: $E(\hat{\Gamma}) = \sum c_i \mu_i = \Gamma$. תחת H_0 היא אפס.

השונות: הממוצעים בלתי תלויים, וכל אחד עם שונות σ^2/n:

$$V(\hat{\Gamma}) = \sum_{i=1}^{a} c_i^2 \, V(\bar{y}_{i\cdot}) = \frac{\sigma^2}{n} \sum_{i=1}^{a} c_i^2$$

מבחן t: מציבים MS_E במקום σ^2:

$$t_0 = \frac{\sum c_i \bar{y}_{i\cdot}}{\sqrt{\frac{MS_E}{n} \sum c_i^2}} \sim t_{N-a} \quad (\text{תחת } H_0)$$

מ-t ל-F: סכום הריבועים של ניגוד

מעלים את t_0 **בריבוע**, מונה ומכנה, ומציבים $\bar{y}_{i\cdot} = y_{i\cdot}/n$ (הסכומים במקום הממוצעים):

$$t_0^2 = \frac{\left(\sum c_i \bar{y}_{i\cdot}\right)^2}{\frac{MS_E}{n}\sum c_i^2} = \frac{\left(\sum c_i y_{i\cdot}\right)^2/n^2}{\frac{MS_E}{n}\sum c_i^2} = \frac{1}{MS_E}\cdot \underbrace{\frac{\left(\sum c_i y_{i\cdot}\right)^2}{n\sum c_i^2}}_{SS_C}$$

$$F_0 = t_0^2 = \frac{SS_C/1}{MS_E} \sim F_{1,\ N-a}$$

- המונה, SS_C, הוא **סכום ריבועים** עם **דרגת חופש אחת**. המכנה הוא אותו MS_E כמו במבחן t
- **זה אותו מבחן:** $t^2_{0.975,\ 40} = 2.021^2 = 4.08 = F_{0.95;\ 1,\ 40}$, ו-p-value זהה למבחן t דו-צדדי
- דוחים את $H_0 : \Gamma = 0$ אם $F_0 > F_{1-\alpha;\ 1,\ N-a}$

אז למה לעבור ל-F?

כי SS_C מדבר באותה שפה כמו טבלת ANOVA:

- SS_C הוא **חלק מ-**SS_{Tr}: כמה מההבדלים בין הרמות השאלה הספציפית הזו מסבירה. ב-t אין לזה מקבילה
- עם ניגודים **אורתוגונליים** (בעוד רגע), ה-SS_C מחלקים בדיוק את SS_{Tr}. מבחן ה-F הכללי הוא בעצם **הממוצע** של $a-1$ מבחני F של ניגודים: $MS_{Tr} = \frac{1}{a-1}\sum SS_{C_k}$
- החישוב הידני מהסכומים $y_{i\cdot}$ נוח, וזה הפורמט של שאלות הבחינה

מתי להישאר עם t?

- **השערה חד-צדדית.** t_0^2 מאבד את הסימן. "האם המודלים הגדולים **מקצרים** את הטיפול?" היא בעצם שאלה חד-צדדית: $t_0 > t_{1-\alpha,\,N-a}$
- **רווח סמך לניגוד:** $\hat{\Gamma} \pm t_{1-\alpha/2,\,N-a}\sqrt{\frac{MS_E}{n}\sum c_i^2}$. הוא אומר **כמה**, לא רק **אם**

המודלים: קטנים מול גדולים

סכומי משכי הטיפול: $y_{1\cdot} = 45.02$, $y_{2\cdot} = 48.01$, $y_{3\cdot} = 35.95$, $y_{4\cdot} = 33.87$, $y_{5\cdot} = 35.60$.

קטנים מול גדולים, $c = (1, 1, 0, -1, -1)$:

$$\sum c_i y_{i\cdot} = 45.02 + 48.01 - 33.87 - 35.60 = 23.56 \qquad SS_{C_1} = \frac{23.56^2}{9 \cdot 4} = 15.42$$

$$F_0 = \frac{15.42}{0.854} = 18.06 > F_{0.95;\,1,\,40} = 4.08$$

דוחים: עם המודלים הגדולים הטיפול קצר יותר. $\hat{\Gamma}/2 = (5.17 - 3.86) = 1.31$ דקות בממוצע.

M3 מול M4, $c = (0, 0, 1, -1, 0)$:

$$SS_{C_2} = \frac{(35.95 - 33.87)^2}{9 \cdot 2} = 0.24 \qquad F_0 = \frac{0.24}{0.854} = 0.28 < 4.08$$

לא דוחים: אין עדות להבדל בין M3 ל-M4.

אותו חישוב ב-R

ידנית, לפי הנוסחאות:

```
contrast_test <- function(c, totals, n, mse, df_e) {
  ss <- sum(c * totals)^2 / (n * sum(c^2))
  c(estimate = sum(c * totals / n), SS = ss, F = ss / mse,
    p = pf(ss / mse, 1, df_e, lower.tail = FALSE))
}
totals <- tapply(calls$aht, calls$model, sum)
rbind(small_vs_large = contrast_test(c(1, 1, 0, -1, -1), totals, 9, mse, 40),
      M3_vs_M4       = contrast_test(c(0, 0, 1, -1, 0),  totals, 9, mse, 40))
```

```
               estimate      SS       F         p
small_vs_large   2.6178 15.4187 18.0627 0.0001243
M3_vs_M4         0.2311  0.2404  0.2816 0.5986067
```

בפקודה מוכנה, חבילת emmeans:

```
emm <- emmeans::emmeans(fit_ai, ~ model)   # the 5 level means
emmeans::contrast(emm, list(small_vs_large = c(1, 1, 0, -1, -1) / 2,
                            M3_vs_M4       = c(0, 0, 1, -1, 0)))
```

```
 contrast       estimate    SE df t.ratio p.value
 small_vs_large    1.309 0.308 40   4.250  0.0001
 M3_vs_M4          0.231 0.436 40   0.531  0.5986
```

- emmeans מדווח t ולא F, אבל $t^2 = F$: $4.25^2 = 18.06$, $0.53^2 = 0.28$. אותו p.
- חילקנו את הניגוד הראשון ב-2 כדי שהאומדן יהיה $\hat{\Gamma} = 1.31$ דקות. כפל של c בקבוע לא משנה את t ואת p

ניגודים אורתוגונליים (Orthogonal contrasts)

שני ניגודים c ו-d הם **אורתוגונליים** אם

$$\sum_{i=1}^{a} c_i d_i = 0$$

- ניגודים אורתוגונליים שואלים שאלות **בלתי תלויות**: האומדים שלהם בלתי מתואמים
- אפשר למצוא לכל היותר $a-1$ ניגודים שכל זוג מהם אורתוגונלי
- **טענה:** לקבוצה של $a-1$ ניגודים אורתוגונליים בזוגות,

$$SS_{C_1} + SS_{C_2} + \cdots + SS_{C_{a-1}} = SS_{Tr}$$

כלומר: ניגודים אורתוגונליים **מפרקים** את SS_{Tr} ל-$a-1$ שאלות נפרדות, כל אחת עם דרגת חופש אחת.

דוגמה כללית: ניגודי Helmert

כל רמה מול כל הרמות שאחריה:

	רמה 1	**רמה 2**	**רמה 3**	$\cdots$	**רמה** $a-1$	**רמה** a
C_1	$-(a-1)$	1	1	$\cdots$	1	1
C_2	0	$-(a-2)$	1	$\cdots$	1	1
C_3	0	0	$-(a-3)$	$\cdots$	1	1
$\vdots$				$\ddots$		
C_{a-1}	0	0	0	$\cdots$	-1	1

- C_1: הרמה הראשונה מול כל השאר
- C_2: הרמה השנייה מול כל השאר, בלי הראשונה
- וכן הלאה. נסו לבדוק: המכפלה של כל שתי שורות היא 0

המודלים: ארבעה ניגודים אורתוגונליים

השאלה	c_1	c_2	c_3	c_4	c_5
C_1: קטנים מול גדולים	1	1	0	−1	−1
C_2: M1 מול M2	1	−1	0	0	0
C_3: M4 מול M5	0	0	0	1	−1
C_4: M3 מול כל השאר	1	1	−4	1	1

```
C <- rbind(small_vs_large = c(1, 1, 0, -1, -1), M1_vs_M2 = c(1, -1, 0, 0, 0),
           M4_vs_M5 = c(0, 0, 0, 1, -1),        M3_vs_rest = c(1, 1, -4, 1, 1))
C %*% t(C)                                       # off-diagonal zeros: pairwise orthogonal
```

```
              small_vs_large M1_vs_M2 M4_vs_M5 M3_vs_rest
small_vs_large              4        0        0          0
M1_vs_M2                    0        2        0          0
M4_vs_M5                    0        0        2          0
M3_vs_rest                  0        0        0         20
```

```
ss_c <- apply(C, 1, contrast_test, totals = totals, n = 9, mse = mse, df_e = 40)
round(ss_c, 3)
```

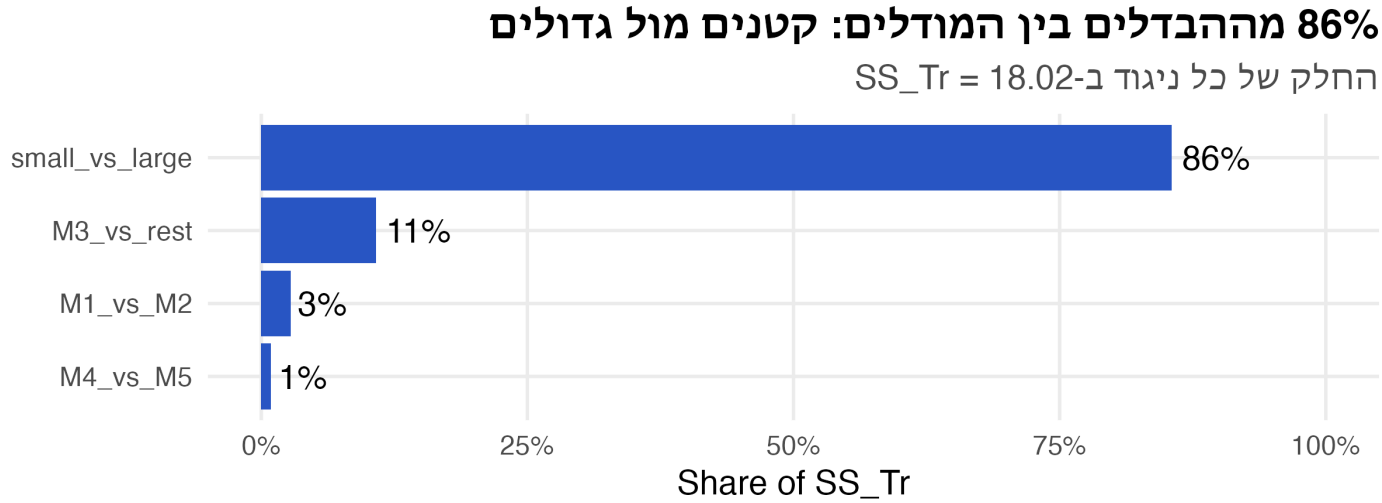
```
         small_vs_large M1_vs_M2 M4_vs_M5 M3_vs_rest
estimate          2.618   -0.332   -0.192      2.078
SS               15.419    0.497    0.166      1.943
F                18.063    0.582    0.195      2.276
p                 0.000    0.450    0.661      0.139
```

```
c(sum_SS_C = sum(ss_c["SS", ]), SS_Tr = summary(fit_ai)[[1]][1, "Sum Sq"])
```

```
sum_SS_C    SS_Tr
   18.02    18.02
```

איך קוראים את הפירוק

```
tibble(contrast = colnames(ss_c), SS = ss_c["SS", ]) |>
  mutate(share = SS / sum(SS), contrast = fct_reorder(contrast, SS)) |>
  ggplot(aes(share, contrast)) +
  geom_col(fill = nanas_pal[["primary"]]) +
  geom_text(aes(label = percent(share, 1)), hjust = -0.15) +
  scale_x_continuous(labels = percent, limits = c(0, 1)) +
  labs(title = "86% מההבדלים בין המודלים: קטנים מול גדולים",
       subtitle = "החלק של כל ניגוד ב-SS_Tr = 18.02", x = "Share of SS_Tr", y = NULL)
```



- כמעט כל ההבדל בין המודלים הוא **גודל**. בתוך כל קבוצה, המודלים דומים
- זו תשובה עסקית ברורה יותר מ"יש הבדל בין המודלים"

ניגודים בניסוי לא מאוזן

כש-n_i שונים, מגדירים את הניגוד על **הסכומים** $y_{i\cdot}$:

$$C = \sum_{i=1}^{a} c_i y_{i\cdot}$$

$y_{i\cdot}$ הוא סכום של n_i תצפיות, ולכל אחת תוחלת $\mu + \tau_i$. לכן $E(y_{i\cdot}) = n_i(\mu + \tau_i)$, ומליניאריות התוחלת:

$$E(C) = \sum_{i=1}^{a} c_i \, E(y_{i\cdot}) = \sum_{i=1}^{a} c_i n_i (\mu + \tau_i) = \mu \sum_{i=1}^{a} n_i c_i + \sum_{i=1}^{a} n_i c_i \tau_i$$

הניגוד צריך למדוד רק הבדלים בין האפקטים τ_i, ולא את הרמה הכללית μ. כדי ש-μ יתבטל, התנאי הוא:

$$\sum_{i=1}^{a} n_i c_i = 0 \qquad\qquad SS_C = \frac{\left(\sum c_i y_{i\cdot}\right)^2}{\sum n_i c_i^2}$$

- **אורתוגונליות** בניסוי לא מאוזן: $\sum n_i c_i d_i = 0$
- בניסוי מאוזן ($n_i = n$) חוזרים לתנאים הקודמים

דוגמה: מבחן בשלוש כיתות

מבחן התקיים בשלוש כיתות: 40 סטודנטים בכיתה 1, ו-30 בכל אחת מכיתות 2 ו-3. **כיתה 3 סמוכה לאתר בנייה.** הסטודנטים שלה מבקשים פקטור. **האם הטענה מוצדקת?**

```
rooms <- read_csv(file.path(data_dir, "exam_rooms.csv"), show_col_types = FALSE)
rooms |> group_by(room) |> summarise(n = n(), total = sum(grade), mean = mean(grade))
```

```
# A tibble: 3 × 4
  room      n total  mean
  <chr> <int> <dbl> <dbl>
1 room1    40  3014  75.4
2 room2    30  2258  75.3
3 room3    30  2015  67.2
```

```
fit_rooms <- aov(grade ~ room, data = rooms)
summary(fit_rooms)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
room         2   1394     697    4.08   0.02 *
Residuals   97  16573     171
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

ה-ANOVA דוחה ($p = 0.02$). אבל השאלה ספציפית: **כיתה 3 מול שתי האחרות**.

הניגוד לכיתה 3: בחירת המקדמים

השאלה: האם הממוצע בכיתה 3 נמוך מהממוצע של כיתות 1 ו-2 יחד?

1. **כיתות 1 ו-2 באותו צד של השאלה**, ולכן מקבלות **אותו** מקדם. נבחר $c_1 = c_2 = 1$
2. **את c_3 קובע התנאי לניסוי לא מאוזן,** $\sum n_i c_i = 0$, עם $n = (40, 30, 30)$:

$$40 \cdot 1 + 30 \cdot 1 + 30\, c_3 = 0 \implies c_3 = -\frac{7}{3}$$

3. **כופלים ב-3** כדי לעבוד עם מספרים שלמים: $c = (3, 3, -7)$. כפל בקבוע לא משנה את SS_C: המונה והמכנה מוכפלים שניהם ב-9

מה הניגוד מודד? כי $3 \cdot 70 = 7 \cdot 30 = 210$:

$$C = 3(y_{1\cdot} + y_{2\cdot}) - 7\, y_{3\cdot} = 210 \left(\underbrace{\frac{y_{1\cdot} + y_{2\cdot}}{70}}_{\bar{y}_{1,2}} - \underbrace{\frac{y_{3\cdot}}{30}}_{\bar{y}_{3\cdot}} \right)$$

כלומר $C/210 = \bar{y}_{1,2} - \bar{y}_{3\cdot}$: ההפרש בין הממוצע של כל 70 הסטודנטים בכיתות 1 ו-2 לבין הממוצע בכיתה 3.

הניגוד לכיתה 3: החישוב

מהשקף הקודם: $y_{1\cdot} = 3014$, $y_{2\cdot} = 2258$, $y_{3\cdot} = 2015$, ו-$MS_E = 170.9$ (ה-Mean Sq של Residuals).

$$C = 3 \cdot 3014 + 3 \cdot 2258 - 7 \cdot 2015 = 1711 \qquad \frac{C}{210} = 8.15$$

$$SS_C = \frac{C^2}{\sum n_i c_i^2} = \frac{1711^2}{40 \cdot 9 + 30 \cdot 9 + 30 \cdot 49} = \frac{1711^2}{2100} = 1394.1$$

$$F_0 = \frac{SS_C}{MS_E} = \frac{1394.1}{170.9} = 8.16 > F_{0.95;\,1,\,97} = 3.94$$

- **דוחים:** בכיתה 3 הציונים נמוכים בכ-8 נקודות מהממוצע בכיתות 1 ו-2, והפער מובהק
- $SS_C = 1394.1$ **הוא כמעט כל** $SS_{Tr} = 1394.2$. כל ההבדל בין הכיתות הוא "כיתה 3 מול השאר". בין כיתות 1 ו-2 כמעט אין הבדל

```
rt <- tapply(rooms$grade, rooms$room, sum); rn <- table(rooms$room); cc <- c(3, 3, -7)
ss_room3 <- sum(cc * rt)^2 / sum(rn * cc^2)
c(sum_n_c = sum(rn * cc), C = sum(cc * rt), diff = sum(cc * rt) / 210, SS_C = ss_room3,
  F = ss_room3 / 170.86, p = pf(ss_room3 / 170.86, 1, 97, lower.tail = FALSE))
```

```
  sum_n_c         C      diff      SS_C         F         p
0.000e+00 1.711e+03 8.148e+00 1.394e+03 8.159e+00 5.242e-03
```

ניגודים מתוכננים מול "מה שנראה מעניין"

- **ניגוד מתוכנן** (planned, a priori): השאלה נוסחה **לפני** שראינו את הנתונים. מבחן F עם α רגילה תקין
- **ניגוד שנבחר אחרי שראינו את הנתונים** (post hoc): אם בוחרים להשוות את הממוצע הגבוה לנמוך **כי** הם הכי רחוקים, ההשוואה מוטה. הפער הגדול ביותר מבין הרבה פערים גדול מטבעו
- כדי לבדוק השוואות שנבחרו אחרי שראינו את הנתונים, צריך **שיטות להשוואות מרובות** ← החלק הבא

השוואות מרובות
(Multiple comparisons)

הבעיה

עם 5 מודלים יש 10 זוגות. אם בודקים כל זוג במבחן t ב-$\alpha = 0.05$, ו-H_0 נכונה בכל הזוגות:

מספר המבחנים m	$P(\text{לפחות טעות אחת}) = 1 - 0.95^m$
1	0.05
10 (5 רמות)	0.40
45 (10 רמות)	0.90
100	0.99

- **שיעור הטעות לכל השוואה** (per-comparison): α. זה מה שמבחן t רגיל שומר עליו
- **שיעור הטעות למשפחה** (familywise error rate, FWER): ההסתברות לטעות **אחת לפחות** בכל קבוצת המבחנים

סימולציה: 10 מבחני t כשאין שום הבדל

5 מודלים זהים, 9 תצפיות לכל אחד. משווים **כל זוג** במבחן t ב-$\alpha = 0.05$. מספר הזוגות: $\binom{5}{2} = \frac{5 \cdot 4}{2} = 10$ (כל אחד מ-5 המודלים מול 4 האחרים, וכל זוג נספר פעמיים). חוזרים על הניסוי 4,000 פעמים.

```
set.seed(55)
g <- factor(rep(paste0("M", 1:5), each = 9))
n_reject <- replicate(4000, {
  p <- pairwise.t.test(rnorm(45), g, p.adjust.method = "none")$p.value
  sum(p < 0.05, na.rm = TRUE)                    # false rejections in this experiment
})
c(P_any = mean(n_reject > 0), mean_rejections = mean(n_reject))
```

```
  P_any mean_rejections
 0.2690          0.4983
```

```
table(n_reject)
```

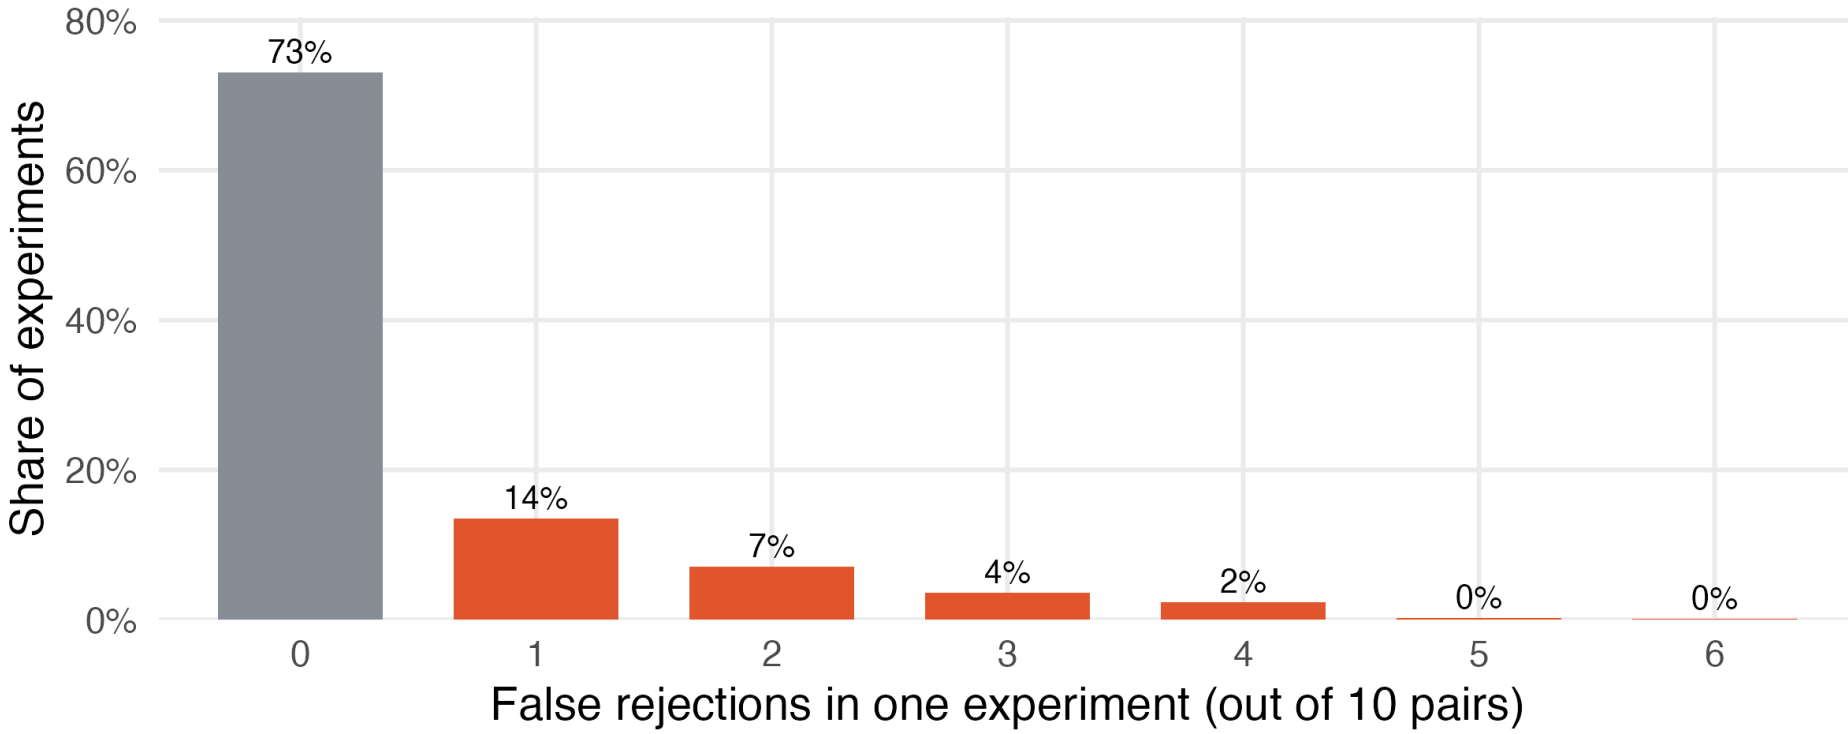
```
n_reject
   0    1    2    3    4    5    6
2924  540  284  144   92   11    5
```

- ב-27% מהניסויים "מצאנו" לפחות זוג מודלים שונים, אף שכולם זהים. הרבה יותר מ-5%

הסימולציה בתרשים

כל עמודה כתומה היא ניסוי עם תגלית שגויה

4,000 ניסויים, בכולם אין שום הבדל בין המודלים



- **אפור:** 73% מהניסויים בלי אף טעות. **כתום:** 27% עם טעות אחת לפחות. ובחלק מהם יש כמה טעויות יחד

למה פחות מ-40%?

- $1 - 0.95^{10} = 0.40$ מניח 10 מבחנים **בלתי תלויים**. כאן הם תלויים: כל ממוצע משתתף ב-4 השוואות, וכל העשר חולקות את אותו MS_E
- **הטעויות מגיעות בצרורות.** כשממוצע אחד יוצא קיצוני במקרה, הוא "מושך" כמה השוואות לדחייה **יחד**. וכש-MS_E יוצא קטן במקרה, כל עשרת המבחנים נעשים מקלים יחד
- **מספר הדחיות השגויות בממוצע לא משתנה:** $10 \times 0.05 = 0.5$ (בסימולציה: 0.5). אבל הן מתרכזות בפחות ניסויים: בניסוי שיש בו טעות, יש בממוצע 1.9 טעויות
- לכן ההסתברות ל**טעות אחת לפחות** קטנה מ-40%. **ועדיין** היא פי 5 מה-5% שרצינו

שתי שיטות, שתי משמעויות של "מובהק"

שתי השיטות משוות **הפרש בין ממוצעים** לסף. שתיהן משתמשות בשגיאת התקן של ממוצע, $s_{\bar{y}} = \sqrt{MS_E/n}$:

השיטה	הסף	שיעור הטעות למשפחה (FWER)
Duncan	$r_\alpha(p, f)\, s_{\bar{y}}$, תלוי במרחק p בין הממוצעים	גבוה מ-α, וגדל עם מספר הרמות
Tukey HSD	$q_\alpha(a, f)\, s_{\bar{y}}$, סף אחד לכל הזוגות	בדיוק α (בניסוי מאוזן)

למודלים: $s_{\bar{y}} = \sqrt{0.854/9} = 0.308$, ו-$f = N - a = 40$.

```
sqrt(mse / 9)
```

```
[1] 0.308
```

שיטת Duncan

הרעיון: הסף תלוי במרחק בדירוג

Duncan's multiple range test משווה את כל הזוגות, אחרי שמבחן ה-F דחה. החידוש: **לא כל הזוגות מקבלים אותו סף**.

למה? ננית שאין שום הבדל בין 5 המודלים. נמיין את 5 הממוצעים:

- שני ממוצעים **שכנים** בדירוג נבדלים רק ברעש של שני ממוצעים
- הממוצע **הגבוה** והממוצע **הנמוך** מבין החמישה הם הקיצוניים מתוך 5. הפער ביניהם גדול כמעט תמיד, גם בלי שום אפקט
- לכן זוג שנמצא בקצוות של הדירוג צריך לעבור סף **גבוה** יותר, וזוג של שכנים סף **נמוך** יותר

המרחק p: כמה ממוצעים נמצאים בטווח בין שני הממוצעים שמשווים, **כולל שניהם**. במודלים:

דירוג	1	2	3	4	5
מודל	M2	M1	M3	M5	M4
ממוצע	5.33	5.00	3.99	3.96	3.76

דוגמאות:

הזוג	M2, M1	M2, M3	M1, M4	M2, M4
הממוצעים בטווח	M2, M1	M2, M1, M3	M1, M3, M5, M4	כל החמישה
p	2 (שכנים)	3	4	5 (הקצוות)

השלבים

1. **מיינים** את ממוצעי הרמות בסדר יורד
2. **מחשבים סף לכל מרחק** $p = 2, \ldots, a$, **הטווח המובהק הקטן ביותר** (least significant range):

$$R_p = r_\alpha(p, f) \cdot s_{\bar{y}} \qquad s_{\bar{y}} = \sqrt{\frac{MS_E}{n}}$$

$r_\alpha(p, f)$ הם **מקדמי Duncan** מטבלה, ו-$f = N - a$ הן דרגות החופש של MS_E. המקדם גדל עם p

3. **בודקים מבחוץ פנימה:** קודם הזוג של הקצוות ($p = a$), אחר כך זוגות עם $p = a - 1$, וכן הלאה. ההפרש מובהק אם $|\bar{y}_{i\cdot} - \bar{y}_{k\cdot}| > R_p$
4. **כלל ההגנה:** אם ההפרש בין שני ממוצעים **לא** מובהק, כל הממוצעים שביניהם נחשבים שווים, ו**לא בודקים** זוגות בתוך הטווח הזה
5. **מסכמים באותיות:** רמות שחולקות אות לא שונות זו מזו באופן מובהק

מאיפה מגיעים המקדמים?

המקדמים הם ערכים של התפלגות ה-**studentized range**: ההתפלגות של $(\bar{y}_{max} - \bar{y}_{min})/s_{\bar{y}}$, הטווח של p ממוצעים מחולק בשגיאת התקן שלהם, כש-H_0 נכונה. זו אותה התפלגות שבה משתמשת שיטת Tukey. ההבדל הוא ברמת המובהקות: לטווח של p ממוצעים, Duncan משתמש ב-

$$\alpha_p = 1 - (1 - \alpha)^{p-1}$$

ככל ש-p גדל, α_p גדלה, והשיטה "סלחנית" יותר. ב-R אין צורך בטבלה:

```
p <- 2:5
r_duncan <- qtukey((1 - 0.05)^(p - 1), nmeans = p, df = 40)   # Duncan's r_alpha(p, 40)
rbind(p = p, alpha_p = 1 - 0.95^(p - 1), r = r_duncan, R_p = r_duncan * sqrt(mse / 9)) |> round(3)
```

```
        [,1]  [,2]  [,3]  [,4]
p       2.000 3.000 4.000 5.000
alpha_p 0.050 0.098 0.143 0.185
r       2.858 3.005 3.102 3.171
R_p     0.880 0.926 0.955 0.977
```

המודלים: שיטת Duncan

מיון: M2 (5.33) · M1 (5.00) · M3 (3.99) · M5 (3.96) · M4 (3.76)

```
means <- sort(tapply(calls$aht, calls$model, mean), decreasing = TRUE)
R_p   <- setNames(r_duncan * sqrt(mse / 9), 2:5)

duncan <- combn(names(means), 2, simplify = FALSE) |>
  map(\(pair) {
    pos <- match(pair, names(means))
    tibble(high = pair[1], low = pair[2], p = diff(pos) + 1,
           diff = means[pair[1]] - means[pair[2]], R_p = R_p[as.character(diff(pos) + 1)])
  }) |>
  list_rbind() |>
  mutate(significant = diff > R_p) |>
  arrange(desc(p))
duncan
```

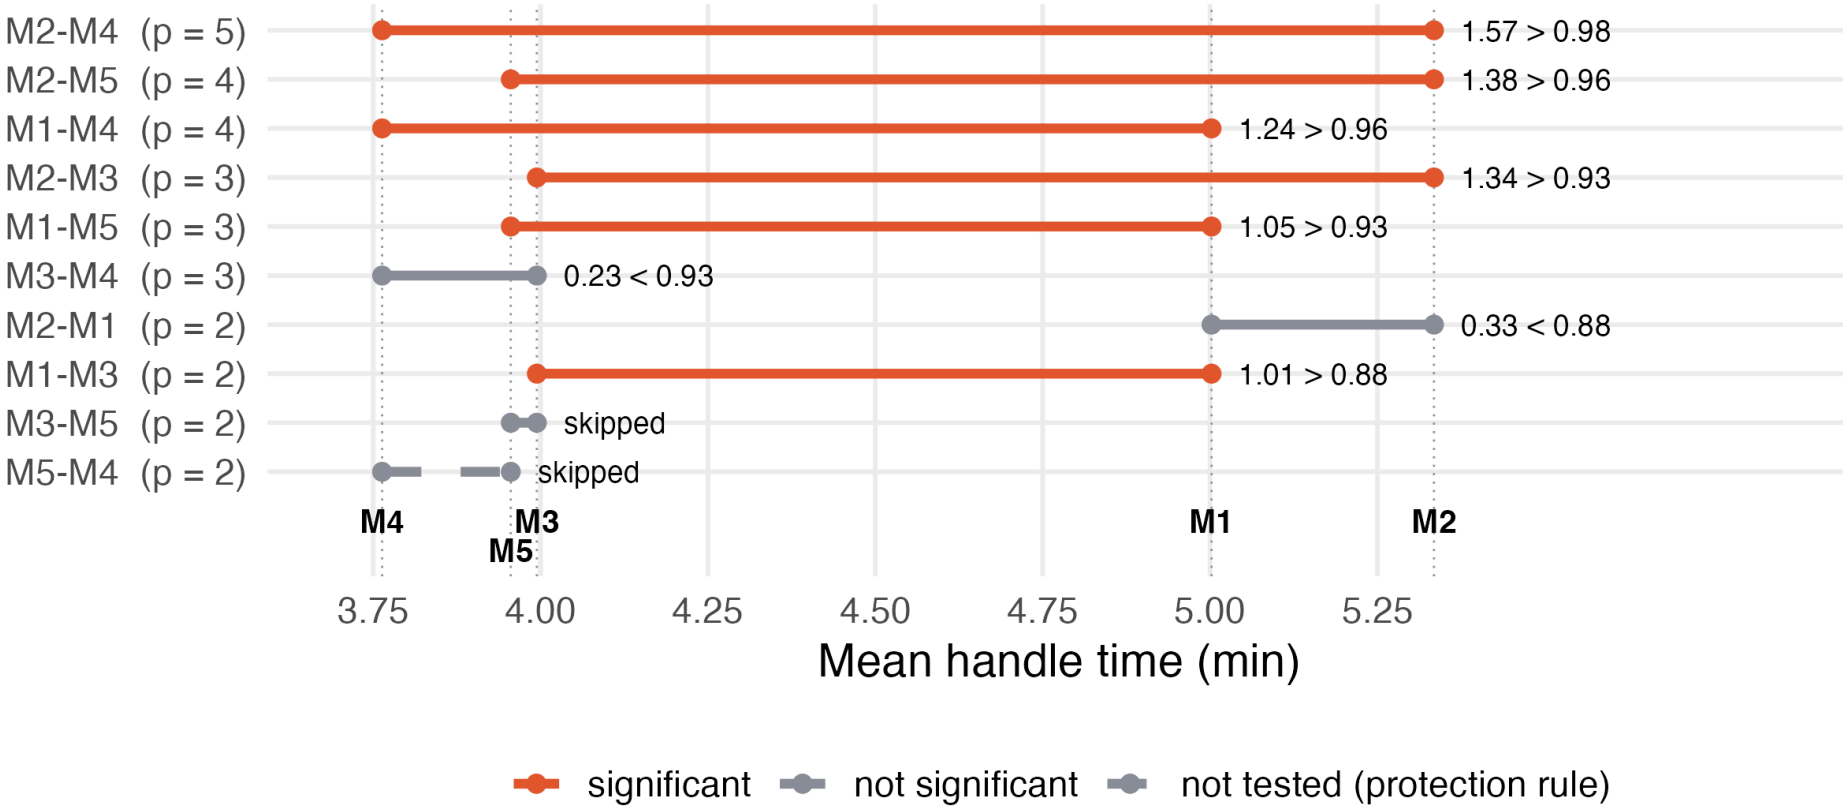
המודלים: שיטת Duncan

```
# A tibble: 10 × 6
   high  low       p   diff   R_p significant
   <chr> <chr> <dbl>  <dbl> <dbl> <lgl>
 1 M2    M4        5 1.57   0.977 TRUE
 2 M2    M5        4 1.38   0.955 TRUE
 3 M1    M4        4 1.24   0.955 TRUE
 4 M2    M3        3 1.34   0.926 TRUE
 5 M1    M5        3 1.05   0.926 TRUE
 6 M3    M4        3 0.231  0.926 FALSE
 7 M2    M1        2 0.332  0.880 FALSE
 8 M1    M3        2 1.01   0.880 TRUE
 9 M3    M5        2 0.0389 0.880 FALSE
10 M5    M4        2 0.192  0.880 FALSE
```

השלבים בתרשים

בודקים מלמעלה למטה: מהקצוות פנימה

כל קו הוא טווח בין שני ממוצעים · מובהק אם ההפרש גדול מ-Rp



התוצאה

	M2	M1	M3	M5	M4
ממוצע	5.33	5.00	3.99	3.96	3.76
קבוצה	**א**	**א**	**ב**	**ב**	**ב**

- **M2 ו-M1** לא שונים זה מזה ($0.33 < 0.88$), ושניהם שונים מכל השאר
- **M3, M5 ו-M4** לא שונים זה מזה: הטווח של שלושתם הוא $0.23 < R_3 = 0.93$. לפי כלל ההגנה, לא בודקים זוגות בתוכו
- רמות עם אותה **אות** לא שונות זו מזו באופן מובהק

ההמלצה: להפעיל את אחד מ-M3, M4 או M5. משך הטיפול לא מבדיל ביניהם, ולכן את הבחירה ביניהם קובעים שיקולים אחרים, למשל עלות: M3 הוא המודל הבינוני, ו-M4 ו-M5 הם הגדולים והיקרים.

ביקורת על Duncan

- α_p גדלה עם מספר הממוצעים: עם 5 רמות, $\alpha_5 = 1 - 0.95^4 = 0.185$
- כלומר, ה-FWER של השיטה **גבוה מ-5%**, וגדל עם מספר הרמות. עם 10 רמות, $\alpha_{10} = 0.37$
- השיטה "מוצאת" יותר הבדלים, וחלקם שגויים
- בעבודה מעשית, מקובל להשתמש ב-Tukey

שיטת Tukey (HSD)

הרעיון

Tukey's Honest Significant Difference: סף **אחד** לכל הזוגות, שמבטיח FWER $= \alpha$ בדיוק (בניסוי מאוזן).

$$HSD = q_\alpha(a, f) \cdot \sqrt{\frac{MS_E}{n}}$$

- $q_\alpha(a, f)$: הערך הקריטי של התפלגות ה-studentized range של a ממוצעים, עם $f = N - a$ דרגות חופש
- **ההיגיון:** אם הזוג **הרחוק ביותר** לא חוצה את הסף תחת H_0 בהסתברות $1 - \alpha$, אף זוג לא חוצה אותו. לכן ההסתברות לטעות אחת לפחות היא α

$$q = \frac{\bar{y}_{max} - \bar{y}_{min}}{\sqrt{MS_E / n}}$$

רווחי סמך משותפים לכל ההפרשים: $(\bar{y}_{i\cdot} - \bar{y}_{k\cdot}) \pm HSD$. **בניסוי לא מאוזן** (Tukey–Kramer):
$q_\alpha(a, f)\sqrt{\frac{MS_E}{2}\left(\frac{1}{n_i} + \frac{1}{n_k}\right)}$.

המודלים: חישוב ידני

$$HSD = q_{0.05}(5, 40) \cdot 0.308 = 4.04 \cdot 0.308 = 1.244$$

```
c(q = qtukey(0.95, nmeans = 5, df = 40), HSD = qtukey(0.95, 5, 40) * sqrt(mse / 9))
```

```
    q   HSD 
4.039 1.244 
```

```
duncan |> mutate(tukey = diff > 1.244) |> select(high, low, diff, duncan = significant, tukey)
```

```
# A tibble: 10 × 5
   high  low     diff duncan tukey
   <chr> <chr>  <dbl> <lgl>  <lgl>
 1 M2    M4    1.57   TRUE   TRUE 
 2 M2    M5    1.38   TRUE   TRUE 
 3 M1    M4    1.24   TRUE   FALSE
 4 M2    M3    1.34   TRUE   TRUE 
 5 M1    M5    1.05   TRUE   FALSE
 6 M3    M4    0.231  FALSE  FALSE
 7 M2    M1    0.332  FALSE  FALSE
 8 M1    M3    1.01   TRUE   FALSE
 9 M3    M5    0.0389 FALSE  FALSE
10 M5    M4    0.192  FALSE  FALSE
```

Tukey ב-R

```
TukeyHSD(fit_ai)
```

```
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = aht ~ model, data = calls)

$model
          diff     lwr       upr  p adj
M2-M1  0.33222 -0.9117  1.576159 0.9397
M3-M1 -1.00778 -2.2517  0.236159 0.1617
M4-M1 -1.23889 -2.4828  0.005048 0.0514
M5-M1 -1.04667 -2.2906  0.197270 0.1354
M3-M2 -1.34000 -2.5839 -0.096063 0.0292
M4-M2 -1.57111 -2.8150 -0.327174 0.0072
M5-M2 -1.37889 -2.6228 -0.134952 0.0233
M4-M3 -0.23111 -1.4750  1.012826 0.9836
M5-M3 -0.03889 -1.2828  1.205048 1.0000
M5-M4  0.19222 -1.0517  1.436159 0.9918
```

איך קוראים את הפלט

- **`diff`**: ההפרש בין הממוצעים (השורה − העמודה). `M2-M1 = 0.33`: עם M2 הטיפול ארוך מאשר עם M1 ב-0.33 דקות
- **`lwr`, `upr`**: רווח סמך **משותף** של 95%: $\text{diff} \pm 1.244$. ב-95% מהניסויים **כל** עשרת הרווחים יכילו את ההפרש האמיתי יחד
- **`p adj`**: p-value מתוקן להשוואות מרובות. מובהק אם קטן מ-0.05, כלומר אם הרווח לא כולל את 0
- **שימו לב ל-`M4-M1`:** ההפרש 1.239, וה-HSD הוא 1.244. `p adj = 0.051`. **לא** מובהק, בהפרש של חמש אלפיות דקה

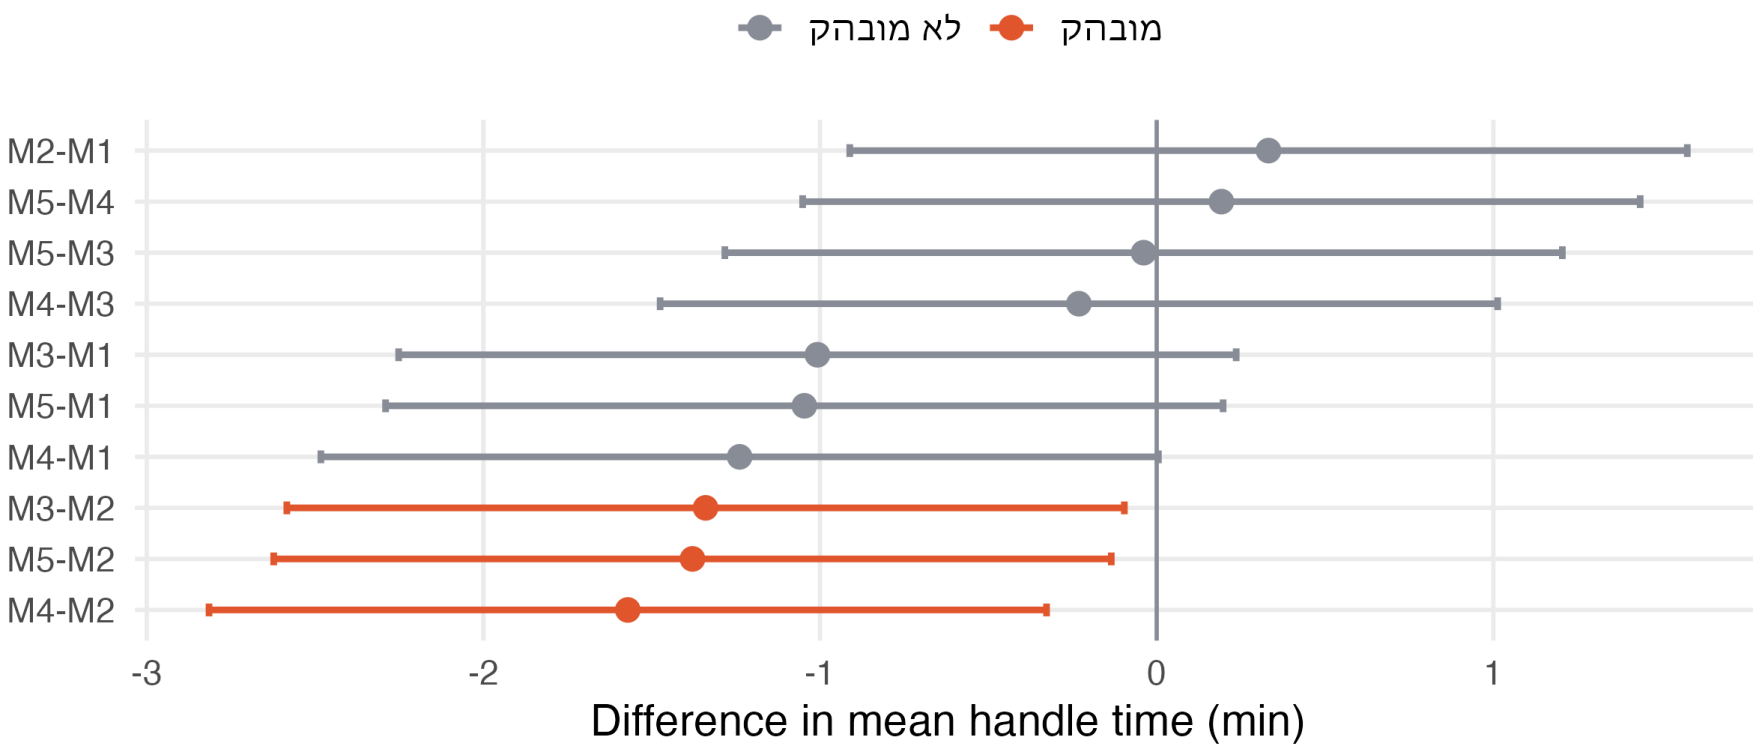
רווחי הסמך בתרשים

```
TukeyHSD(fit_ai)$model |>
  as_tibble(rownames = "pair") |>
  mutate(pair = fct_reorder(pair, diff), significant = `p adj` < 0.05) |>
  ggplot(aes(diff, pair, colour = significant)) +
  geom_vline(xintercept = 0, colour = nanas_pal[["grey"]]) +
  geom_errorbar(aes(xmin = lwr, xmax = upr), width = 0.25, linewidth = 1, orientation = "y") +
  geom_point(size = 3) +
  scale_colour_manual(values = c(`TRUE` = nanas_pal[["accent"]], `FALSE` = nanas_pal[["grey"]]),
                      labels = c(`TRUE` = "מובהק", `FALSE` = "לא מובהק")) +
  labs(title = "שלושה זוגות מובהקים לפי Tukey: M2 מול M3, M4 ו־M5",
       subtitle = "רווחי סמך משותפים 95% להפרשים · רווח שלא חוצה את 0 הוא מובהק",
       x = "Difference in mean handle time (min)", y = NULL, colour = NULL)
```

רווחי הסמך בתרשים

שלושה זוגות מובהקים לפי Tukey: M2 מול M3, M4 ו-M5

רווחי סמך משותפים 95% להפרשים · רווח שלא חוצה את 0 הוא מובהק



Duncan מול Tukey

זוג	הפרש	Duncan (R_p)	Tukey (1.244)
M2–M4	1.57	✓ (0.98)	✓
M2–M5	1.38	✓ (0.96)	✓
M2–M3	1.34	✓ (0.93)	✓
M1–M4	1.24	✓ (0.96)	✗
M1–M5	1.05	✓ (0.93)	✗
M1–M3	1.01	✓ (0.88)	✗
M2–M1, M3–M4, M3–M5, M5–M4	≤ 0.33	✗	✗

- Duncan מוצא 6 זוגות. Tukey מוצא 3
- **אין כאן "נכון" ו"לא נכון".** זו בחירה בין שתי טעויות: Tukey שומר על הסיכוי לתגלית שגויה **אחת** מתחת ל-5%, במחיר של עוצמה

איזו שיטה מתי?

המצב	השיטה	ב-R
מעט שאלות, מתוכננות מראש	ניגודים, α רגילה	ידני, `pf()`
כל הזוגות, אחרי F מובהק	Tukey HSD	`TukeyHSD()`
כל הזוגות, כשהבחינה דורשת	Duncan	`qtukey()` + טבלה

הכלל החשוב ביותר: מחליטים על השיטה **לפני** שמסתכלים על התוצאות. אם בוחרים את השיטה שנותנת את התוצאה ה"נכונה", כל התיקון לא שווה כלום.

ניתוח שונות א-פרמטרי: Kruskal–Wallis

מתי צריך מבחן א-פרמטרי?

הדוגמה: זמן התגובה של API בארבעה אזורי ענן (regions), 12 בקשות מכל אזור. זמני תגובה מוטים ימינה, עם ערכים חריגים.

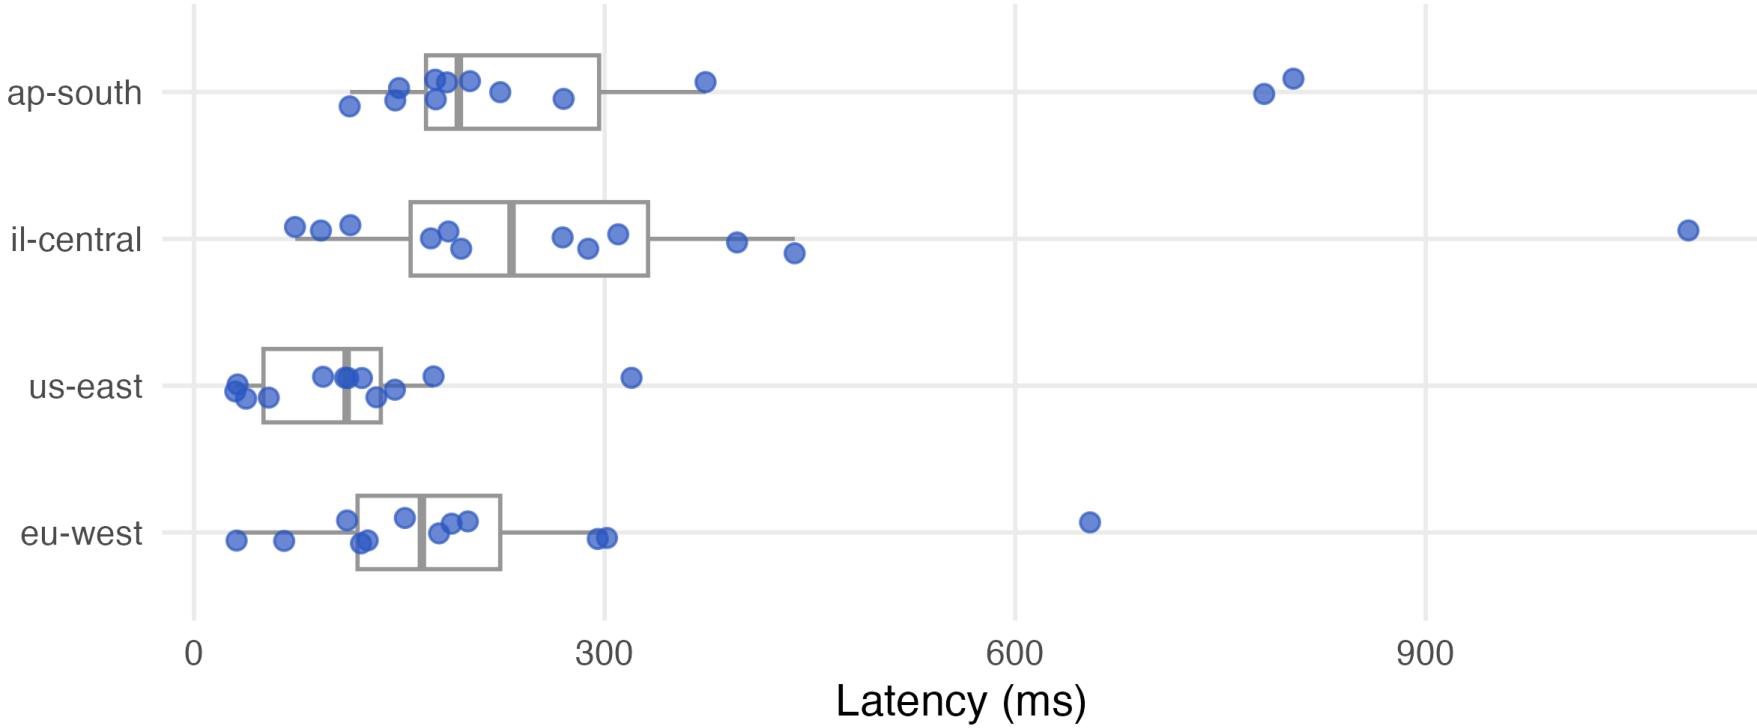
```
set.seed(162)
latency <- tibble(region = factor(rep(c("eu-west", "us-east", "il-central", "ap-south"), each = 12),
                                  levels = c("eu-west", "us-east", "il-central", "ap-south")),
                  ms = round(rlnorm(48, log(rep(c(150, 155, 210, 220), each = 12)), 0.8)))

ggplot(latency, aes(ms, region)) +
  geom_boxplot(width = 0.5, outlier.shape = NA, colour = "grey60") +
  geom_point(colour = nanas_pal[["primary"]], size = 2.5, alpha = 0.7,
             position = position_jitter(height = 0.1, seed = 3)) +
  labs(title = "זמני תגובה מוטים, עם כמה בקשות איטיות מאוד",
       subtitle = "12 בקשות מכל אזור",
       x = "Latency (ms)", y = NULL)
```

מתי צריך מבחן א-פרמטרי?

זמני תגובה מוטים, עם כמה בקשות איטיות מאוד

12 בקשות מכל אזור



ANOVA על נתונים מוטים

```r
fit_lat <- aov(ms ~ region, data = latency)
summary(fit_lat)
```

```
            Df  Sum Sq Mean Sq F value Pr(>F)
region       3  292464   97488    2.35  0.085 .
Residuals   44 1823008   41432
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
ks.test(rstandard(fit_lat), "pnorm")              # standardised residuals vs N(0, 1)
```

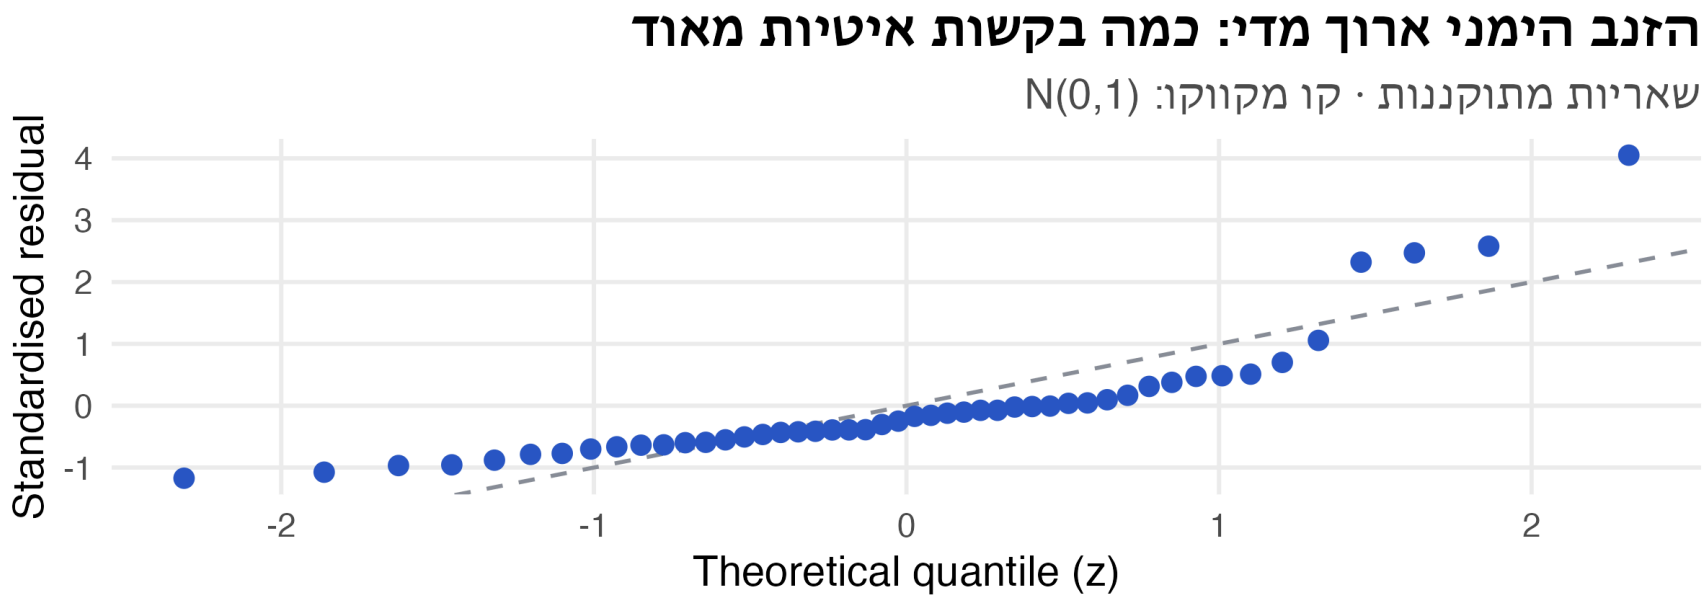
```
    Exact one-sample Kolmogorov-Smirnov test

data:  rstandard(fit_lat)
D = 0.21, p-value = 0.02
alternative hypothesis: two-sided
```

- ה-ANOVA **לא דוחה** ($p = 0.085$)
- **אבל השאריות לא נורמליות.** מבחן Kolmogorov–Smirnov על השאריות המתוקננות, כמו בהרצאה 3: $D = 0.212 > 1.36/\sqrt{48} = 0.196$, ולכן **דוחים** נורמליות

השאריות בגרף Q-Q

```
tibble(r = sort(rstandard(fit_lat))) |>
  mutate(z = qnorm((row_number() - 0.5) / n())) |>
  ggplot(aes(z, r)) +
  geom_abline(intercept = 0, slope = 1, colour = nanas_pal["grey"], linetype = "dashed") +
  geom_point(colour = nanas_pal["primary"], size = 2.5) +
  labs(title = "הזנב הימני ארוך מדי: כמה בקשות איטיות מאוד",
       subtitle = "שאריות מתוקננות · קו מקווקו: N(0,1)",
       x = "Theoretical quantile (z)", y = "Standardised residual")
```



- הבקשות האיטיות מנפחות את MS_E ו"מסתירות" את ההבדלים בין האזורים
- **שתי אפשרויות:** טרנספורמציה $(\log)$, או מבחן שלא מניח נורמליות

Kruskal–Wallis: הרעיון

הכללה של מבחן סכום הדירוגים (הרצאה 1) ליותר משני מדגמים.

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij}$$

- **לא** מניחים $\varepsilon_{ij} \sim N(0, \sigma^2)$. מניחים רק שכל ה-$\varepsilon_{ij}$ מגיעים מאותה התפלגות **רציפה**
- $H_0 : \tau_1 = \cdots = \tau_a = 0$ (כל הרמות מאותה התפלגות) מול H_1: לפחות רמה אחת מוזזת
- **השיטה:** מדרגים את כל N התצפיות יחד, מ-1 (הקטנה) עד N (הגדולה), ומריצים "ANOVA על הדרגות"

תחת H_0 הדרגות מתפזרות באקראי בין הרמות. כמו במבחן סכום הדירוגים, כל דרגה מתפלגת אחיד על $\{1, \ldots, N\}$:

$$E(R_{ij}) = \frac{N+1}{2} \qquad V(R_{ij}) = \frac{N^2 - 1}{12}$$

הסטטיסטי

ב-ANOVA (בהנחת נורמליות):

$$\frac{SS_{Tr}}{\sigma^2} = \frac{\sum_{i=1}^{a} n_i(\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot})^2}{\sigma^2} \sim \chi^2_{a-1}$$

ב-Kruskal–Wallis: אותו ביטוי, על הדרגות. $\bar{R}_{i\cdot}$ הוא ממוצע הדרגות ברמה i, ו-σ^2 מוחלף בשונות הידועה של דרגה, $\frac{N(N+1)}{12}$ (בקירוב):

$$K = \frac{12}{N(N+1)} \sum_{i=1}^{a} n_i \left(\bar{R}_{i\cdot} - \frac{N+1}{2} \right)^2 = \frac{12}{N(N+1)} \sum_{i=1}^{a} \frac{R_{i\cdot}^2}{n_i} - 3(N+1)$$

- $R_{i\cdot}$ הוא **סכום** הדרגות ברמה i
- תחת H_0, $K \sim \chi^2_{a-1}$ בקירוב (טוב כש-$n_i \geq 5$)
- דוחים את H_0 אם $K > \chi^2_{1-\alpha,\, a-1}$
- **שימו לב:** אין כאן σ^2 לאמוד. השונות של הדרגות ידועה מראש

דוגמה לחישוב ידני: חוזק בד לפי אחוז כותנה

מפעל טקסטיל בודק 5 רמות של אחוז כותנה בבד (15%–35%), 6 דגימות בכל רמה. **האם אחוז הכותנה משפיע על חוזק המתיחה?**

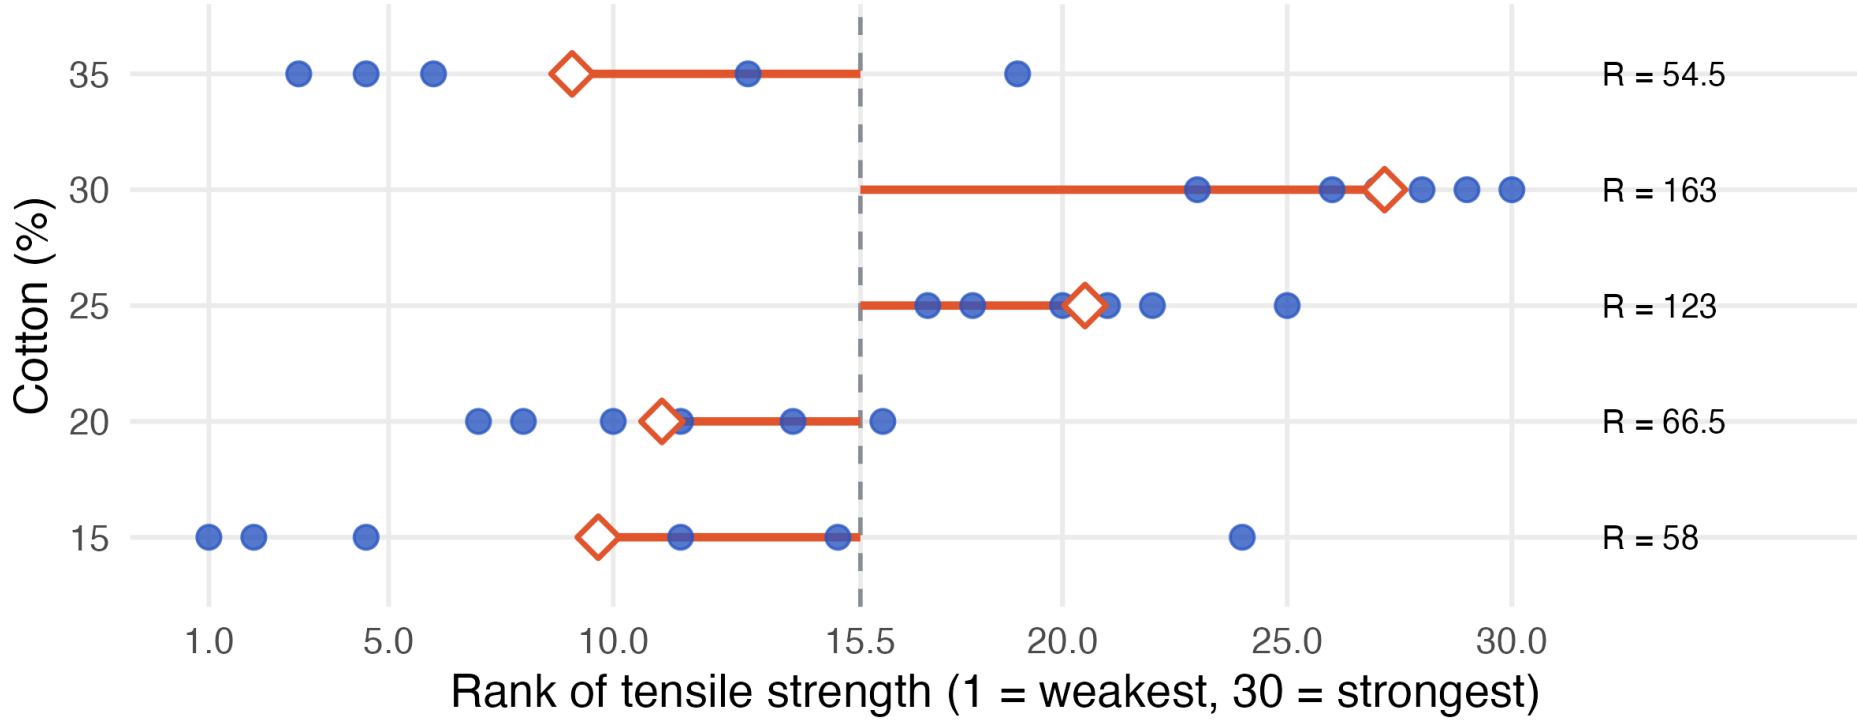
```
cotton <- read_csv(file.path(np_data_dir, "cotton_strength.csv"), show_col_types = FALSE) |>
  mutate(cotton_pct = factor(cotton_pct), rank = rank(strength))
cotton |>
  group_by(cotton_pct) |>
  summarise(n = n(), strength = paste(sort(strength), collapse = ", "),
            R = sum(rank), R_bar = mean(rank))
```

```
# A tibble: 5 × 5
  cotton_pct     n strength                                R R_bar
  <fct>      <int> <chr>                                <dbl> <dbl>
1 15             6 8.5, 9.9, 10.3, 11.6, 12.8, 15.2    58    9.67
2 20             6 10.6, 10.8, 11.3, 11.6, 12.3, 13.4  66.5 11.1
3 25             6 13.7, 14, 14.4, 14.5, 15, 15.5     123   20.5
4 30             6 15.1, 15.8, 15.9, 16, 16.2, 17     163   27.2
5 35             6 10, 10.3, 10.4, 10.9, 12.2, 14.1    54.5  9.08
```

הדרגות בתרשים

ב-25% וב-30% הדרגות גבוהות, ב-15%, 20% ו-35% נמוכות

נקודה: דרגה של דגימה · מעוין: ממוצע הדרגות · קו מקווקו: 15.5, הממוצע הצפוי תחת H0



- K מסכם את **אורכי הקווים הכתומים** (בריבוע, משוקללים ב-n_i): $K = \frac{12}{N(N+1)} \sum n_i(\bar{R}_{i\cdot} - 15.5)^2$. תחת H_0
כל המעוינים קרובים לקו המקווקו

חישוב K

$N = 30$, $a = 5$, $n_i = 6$. סכומי הדרגות: $R_{i\cdot} = 58,\ 66.5,\ 123,\ 163,\ 54.5$.

$$K = \frac{12}{30 \cdot 31} \cdot \frac{58^2 + 66.5^2 + 123^2 + 163^2 + 54.5^2}{6} - 3 \cdot 31 = 19.81$$

$$K = 19.81 > \chi^2_{0.95,\,4} = 9.49$$

דוחים את H_0: אחוז הכותנה משפיע על חוזק הבד.

```
kruskal.test(strength ~ cotton_pct, data = cotton)
```

```
    Kruskal-Wallis rank sum test

data:  strength by cotton_pct
Kruskal-Wallis chi-squared = 20, df = 4, p-value = 5e-04
```

בחזרה לזמני התגובה

```r
kruskal.test(ms ~ region, data = latency)
```

```
    Kruskal-Wallis rank sum test

data:  ms by region
Kruskal-Wallis chi-squared = 12, df = 3, p-value = 0.009
```

```r
fit_lat_log <- aov(log(ms) ~ region, data = latency)
summary(fit_lat_log)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
region       3   7.42   2.473    4.75 0.0059 **
Residuals   44  22.91   0.521
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Kruskal–Wallis דוחה** ($p = 0.0085$), במקום שה-ANOVA על הנתונים הגולמיים לא דחה
- גם ANOVA על $\log(\text{ms})$ דוחה. הלוגריתם "מכווץ" את הזנב הימני ומקרב לנורמליות (השקף הבא)
- **הדרגות לא רגישות לערכים חריגים:** בקשה של 1,000 מילישניות היא פשוט "הדרגה הגבוהה ביותר", בדיוק כמו בקשה של 400

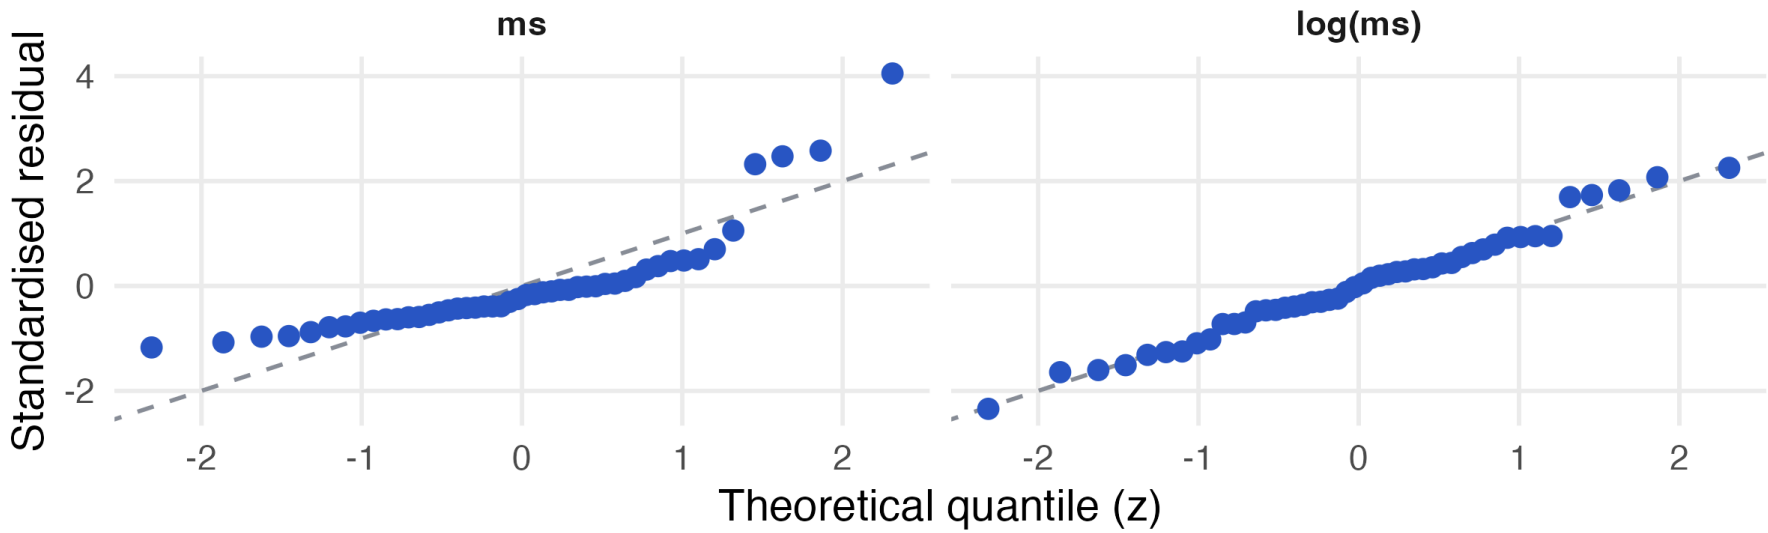
מה הלוגריתם עושה לשאריות?

```
bind_rows(tibble(scale = "ms", r = rstandard(fit_lat)),
          tibble(scale = "log(ms)", r = rstandard(fit_lat_log))) |>
  mutate(scale = fct_inorder(scale)) |>
  group_by(scale) |>
  arrange(r, .by_group = TRUE) |>
  mutate(z = qnorm((row_number() - 0.5) / n())) |>
  ggplot(aes(z, r)) +
  geom_abline(intercept = 0, slope = 1, colour = nanas_pal[["grey"]], linetype = "dashed") +
  geom_point(colour = nanas_pal[["primary"]], size = 2.5) +
  facet_wrap(~ scale) +
  labs(title = "אחרי הטרנספורמציה, השאריות יושבות על הקו",
       subtitle = "שאריות מתוקננות · קו מקווקו: N(0,1)",
       x = "Theoretical quantile (z)", y = "Standardised residual")
```

מה הלוגריתם עושה לשאריות?

אחרי הטרנספורמציה, השאריות יושבות על הקו

שאריות מתוקננות · קו מקווקו: N(0,1)




```
ks_log <- ks.test(rstandard(fit_lat_log), "pnorm")
c(D = unname(ks_log$statistic), p_value = ks_log$p.value)      # KS on log scale
```

```
      D p_value
0.06632 0.97494
```

אילו אזורים שונים? השוואות מרובות על דרגות

אחרי Kruskal–Wallis מובהק, משווים זוגות במבחן סכום הדירוגים, ומתקנים להשוואות מרובות:

```
pairwise.wilcox.test(latency$ms, latency$region, p.adjust.method = "bonferroni")
```

```
    Pairwise comparisons using Wilcoxon rank sum exact test

data:  latency$ms and latency$region

           eu-west us-east il-central
us-east    0.468   -       -
il-central 1.000   0.060   -
ap-south   1.000   0.003   1.000

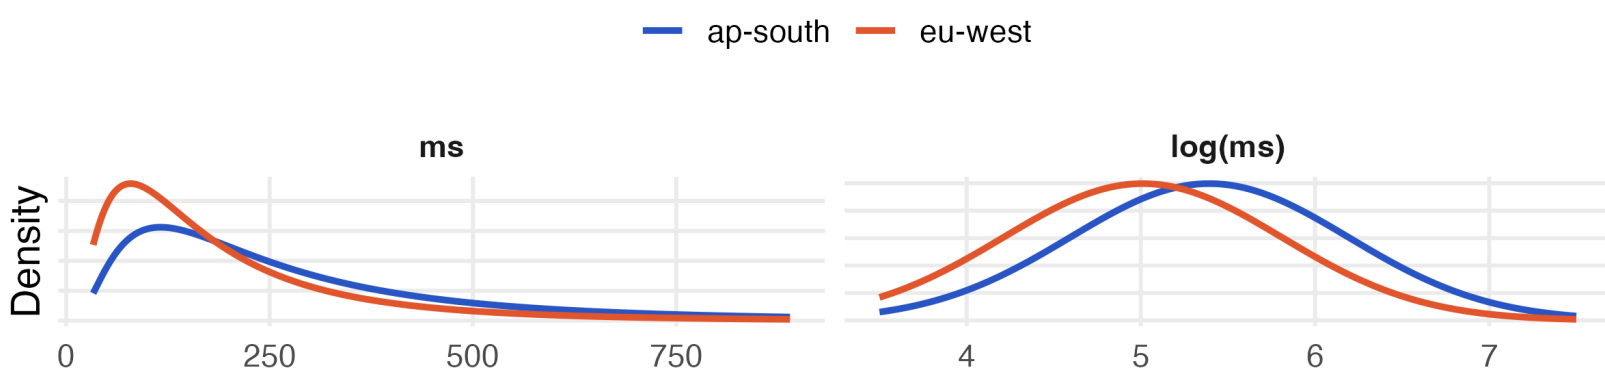
P value adjustment method: bonferroni
```

- כל תא הוא p-value של מבחן סכום הדירוגים בין שני אזורים, **מתוקן** בשיטת Bonferroni: מוכפל במספר ההשוואות (וחסום ב-1). דוחים אם הוא קטן מ-0.05
- **אבל האם זה מבחן על חציונים?** תלוי בהנחת ההזזה (השקף הבא)

מה בודק מבחן סכום הדירוגים? הנחת ההזזה

- H_0 **של המבחן:** לשתי הרמות **אותה התפלגות**. הוא דוחה כשתצפיות מרמה אחת נוטות להיות גדולות מתצפיות מהרמה השנייה
- **הנחת ההזזה** (shift): שתי ההתפלגויות זהות בצורה ובפיזור, ואחת פשוט **מוזזת** ימינה: $F_2(x) = F_1(x - \delta)$. רק תחתיה דחייה פירושה "החציונים שונים"
- **בלי ההנחה,** המבחן יכול לדחות גם כשהחציונים שווים, למשל כשלאחת הרמות פיזור גדול יותר

בסקאלה הלוגריתמית: אותה צורה, רק מוזזת



- **בדוגמה:** הנתונים סומלצו מהתפלגות **לוג-נורמלית**. ב-ms האזור האיטי גם **מפוזר** יותר, ולכן זו לא הזזה. ב-$\log(\text{ms})$ זו הזזה נקייה
- **והדרגות לא מושפעות מ-**log: הלוגריתם שומר על הסדר, ולכן המבחן על ms והמבחן על $\log(\text{ms})$ **זהים**. ההנחה מתקיימת בסקאלה הלוגריתמית, וחציון של log הוא log של החציון. לכן המסקנה על החציונים נכונה גם ב-ms

ניגודים עם חציונים

אחרי Kruskal–Wallis, איך אומדים ניגוד $\Gamma = \sum c_i \tau_i$ בלי ממוצעים?

- **הניסיון הטבעי:** $\hat{\tau}_i = \text{median}_j\{y_{ij}\} - \text{median}_{\text{all}}$
- **הבעיה:** האומדים האלה **לא** מקיימים $\sum \hat{\tau}_i = 0$

דוגמה קטנה: $y_{1j} = \{3, 7, 8\}$ ו-$y_{2j} = \{0, 1, 2\}$. החציון הכללי הוא 2.5, וחציוני הקבוצות הם 7 ו-1:

$$\hat{\tau}_1 = 7 - 2.5 = 4.5 \qquad \hat{\tau}_2 = 1 - 2.5 = -1.5 \qquad \hat{\tau}_1 + \hat{\tau}_2 = 3 \neq 0$$

הפתרון: חציונים של הפרשים

הרעיון: במקום להשוות כל רמה ל"מרכז" משותף, אומדים **בכמה כל רמה גבוהה מכל רמה אחרת**, ורק אז ממצעים.

1. **לכל זוג רמות (i, k):** מחשבים את **כל** ההפרשים בין תצפית מרמה i לתצפית מרמה k ($n_i \cdot n_k$ הפרשים), ולוקחים את החציון שלהם:

$$Z_{ik} = \underset{j,\, m}{\text{median}} \{ y_{ij} - y_{km} \}$$

Z_{ik} עונה על השאלה: **"בכמה, בדרך כלל, תצפית מרמה i גבוהה מתצפית מרמה k?"**

2. **מסדרים בטבלה** $a \times a$. על האלכסון $Z_{ii} = 0$, ו-$Z_{ki} = -Z_{ik}$: אם i גבוהה מ-k ב-6, אז k נמוכה מ-i ב-6
3. **האפקט של רמה** הוא ממוצע השורה שלה, "בכמה היא גבוהה מהרמות, בממוצע":

$$\hat{\tau}_i = \frac{1}{a} \sum_{k=1}^{a} Z_{ik}$$

4. **הסכום אפס:** כל זוג $Z_{ik} + Z_{ki} = 0$ מתבטל, ולכן $\sum_i \hat{\tau}_i = 0$. הבעיה מהשקף הקודם נפתרה
5. **הניגוד:** $\hat{\Gamma} = \sum c_i \hat{\tau}_i$

בדוגמה הקטנה

$y_{1j} = \{3, 7, 8\}$ ו-$y_{2m} = \{0, 1, 2\}$. כל 9 ההפרשים $y_{1j} - y_{2m}$:

	$y_{2m} = 0$	$y_{2m} = 1$	$y_{2m} = 2$
$y_{1j} = 3$	3	2	1
$y_{1j} = 7$	7	6	5
$y_{1j} = 8$	8	7	6

ממוינים: $1, 2, 3, 5, \mathbf{6}, 6, 7, 7, 8$. החציון: $Z_{12} = 6$, ולכן $Z_{21} = -6$.

	רמה 1	רמה 2	$\hat{\tau}_i$ (ממוצע השורה)
רמה 1	0	6	$(0 + 6)/2 = 3$
רמה 2	−6	0	$(-6 + 0)/2 = -3$

$\hat{\tau}_1 + \hat{\tau}_2 = 0$, וההפרש ביניהם, 6, הוא ההזזה האמודה בין הרמות.

ניגוד בדוגמת הכותנה

השאלה: האם הקצוות (15% ו-35%) חלשים מ-30%? $\Gamma = \frac{1}{2}(\tau_1 + \tau_5) - \tau_4$.

```
y_by_level <- split(cotton$strength, cotton$cotton_pct)
Z <- outer(seq_along(y_by_level), seq_along(y_by_level),
           Vectorize(\(i, k) median(outer(y_by_level[[i]], y_by_level[[k]], "-"))))
dimnames(Z) <- list(names(y_by_level), names(y_by_level))
round(Z, 2)                                    # Z[i, k] = median of y_i - y_k
```

```
     15    20    25   30    35
15 0.00 -0.65 -3.55 -5.0 -0.10
20 0.65  0.00 -3.00 -4.5  0.55
25 3.55  3.00  0.00 -1.5  3.60
30 5.00  4.50  1.50  0.0  5.10
35 0.10 -0.55 -3.60 -5.1  0.00
```

```
tau_hat <- rowMeans(Z)                         # row means; they sum to 0
round(c(tau_hat, sum = sum(tau_hat), Gamma = 0.5 * (tau_hat[[1]] + tau_hat[[5]]) - tau_hat[[4]]), 2)
```

```
   15    20    25    30    35   sum Gamma
-1.86 -1.26  1.73  3.22 -1.83  0.00 -5.06
```

$\hat{\Gamma} = \frac{1}{2}\big((-1.86) + (-1.83)\big) - 3.22 = -5.06$: בד עם 15% או 35% כותנה חלש בכ-5 יחידות מבד עם 30% כותנה.

מה יכול להשתבש

חמש מלכודות

1. **לבחור את ההשוואה אחרי שרואים את הנתונים**, ולבדוק אותה כאילו תוכננה מראש. ניגוד מתוכנן חייב להיות מתוכנן
2. **לבחור את שיטת התיקון לפי התוצאה:** "ב-Tukey זה לא יצא מובהק, אז ננסה Duncan". זו הגרסה המתוחכמת של p-hacking
3. **לא לתקן בכלל:** להריץ מבחן t על כל הזוגות, ולהכריז על הזוג שיצא מובהק
4. **להתעלם מבלוקים:** כשאותן יחידות (ימים, משימות, משתמשים) מופיעות בכל הרמות, מבחן שמניח מדגמים בלתי תלויים מפר את ההנחות ומאבד עוצמה. ראינו את זה עם אפקט היום במוקד. הפתרון בהרצאה 6
5. **לפרש Kruskal–Wallis כמבחן על חציונים** בלי הנחת הזזה. אם לרמות יש צורות שונות (למשל פיזור שונה), המבחן בודק משהו אחר

סיכום

מה לקחת מההרצאה

השאלה	הכלי	ב-R
שאלה ספציפית, מתוכננת מראש	ניגוד, SS_C, $F_{1,\,N-a}$	ידני, `pf()`
לפרק את SS_{Tr} לשאלות נפרדות	$a-1$ ניגודים אורתוגונליים	
כל הזוגות (גרסת הבחינה)	Duncan, $R_p = r_\alpha(p,f)\,s_{\bar{y}}$	`qtukey((1-α)^(p-1), p, f)`
כל הזוגות, FWER $= \alpha$	Tukey HSD, $q_\alpha(a,f)\,s_{\bar{y}}$	`TukeyHSD()`
נתונים מוטים, חריגים, סדר	Kruskal–Wallis, $K \sim \chi^2_{a-1}$	`kruskal.test()`
זוגות אחרי Kruskal–Wallis	סכום דירוגים + תיקון	`pairwise.wilcox.test()`
ניגוד עמיד לחריגים	חציונים של הפרשים, Z_{ik}	

בהרצאה הבאה: ניתוח שונות עם כמה פקטורים, אינטראקציות, ובלוקים כחלק מהמודל.