5. ניגודים, השוואות מרובות וניתוח שונות א-פרמטרי

ניתוח נתונים סטטיסטי · הרצאה 5

ד״ר עדי שריד

2026-11-08

על מה נדבר היום

- **חזרה קצרה** על ניתוח שונות חד-כיווני (למי שלא היה ביום ראשון)
- **ניגודים** (contrasts): שאלות ספציפיות שתכננו מראש
- **השוואות מרובות:** למה 10 מבחני t הם בעיה
  - שיטת Duncan
  - שיטת Tukey (HSD)
- **ניתוח שונות א-פרמטרי:**
  - Kruskal–Wallis: כמה מדגמים בלתי תלויים
  - ניגודים עם חציונים
  - Friedman: טיפולים בתוך בלוקים

חזרה: ניתוח שונות חד-כיווני

המודל וההשערות

a **רמות** של פקטור אחד, n **תצפיות** בכל רמה, $N = an$:

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij} \qquad \sum_{i=1}^{a} \tau_i = 0 \qquad \varepsilon_{ij} \overset{iid}{\sim} N(0, \sigma^2)$$

$$H_0 : \tau_1 = \cdots = \tau_a = 0 \quad (\mu_1 = \cdots = \mu_a) \qquad H_1 : \tau_i \neq 0 \text{ כלשהו } i \text{ עבור}$$

שלוש הנחות: נורמליות, אי-תלות, שונות שווה בכל הרמות.

הדוגמה: מוקד שירות בוחר את מודל השפה לעוזר AI. 5 מודלים (M1, M2 קטנים, M3 בינוני, M4, M5 גדולים), 9 ימים לכל מודל, והתגובה היא משך הטיפול הממוצע בפנייה (דקות). האם יש הבדל, ואיזה מודל להפעיל?

```
calls |> group_by(model) |> summarise(total = sum(aht), mean = mean(aht))
```

```
# A tibble: 5 × 3
  model total  mean
  <fct> <dbl> <dbl>
1 M1     45.0  5.00
2 M2     48.0  5.33
3 M3     36.0  3.99
4 M4     33.9  3.76
5 M5     35.6  3.96
```

פירוק השונות וטבלת ANOVA

$$\underbrace{\sum_{i,j}(y_{ij}-\bar{y}_{\cdot\cdot})^2}_{SS_T} = \underbrace{n\sum_{i}(\bar{y}_{i\cdot}-\bar{y}_{\cdot\cdot})^2}_{SS_{Tr}\text{: בין הרמות}} + \underbrace{\sum_{i,j}(y_{ij}-\bar{y}_{i\cdot})^2}_{SS_E\text{: בתוך הרמות}}$$

מקור	סכום ריבועים	דרגות חופש	ממוצע ריבועים	F_0
בין הרמות	SS_{Tr}	$a-1$	MS_{Tr}	MS_{Tr}/MS_E
שגיאה	SS_E	$N-a$	$MS_E=\hat{\sigma}^2$	
סך הכול	SS_T	$N-1$		

- $E(MS_E)=\sigma^2$ תמיד. $E(MS_{Tr})=\sigma^2+\frac{n\sum\tau_i^2}{a-1}$
- דוחים את H_0 אם $F_0 > F_{1-\alpha;\,a-1,\,N-a}$

התוצאה למודלים

```
summary(fit_ai)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
model        4   18.0    4.51    5.28 0.0016 **
Residuals   40   34.1    0.85
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- $F_0 = 5.28 > F_{0.95;\,4,\,40} = 2.61$: **יש הבדל בין המודלים**
- $MS_E = 0.854$, ולכן $\hat{\sigma} = 0.92$ דקות
- **אבל** מבחן ה-F לא אומר **בין מי למי**. עם M1 ו-M2 הטיפול נראה ארוך, ועם M3, M4 ו-M5 קצר. האם זה אמיתי?

שתי דרכים לענות:

1. **ניגודים:** שאלות ספציפיות שניסחנו **לפני** שראינו את הנתונים
2. **השוואות מרובות:** כל הזוגות, עם תיקון לכך שבודקים הרבה

ניגודים (Contrasts)

שאלות ספציפיות

לפני הניסוי, ראש צוות ה-AI במוקד שאל שתי שאלות:

- **האם מודלים גדולים מקצרים את הטיפול?** M1 ו-M2 קטנים, M4 ו-M5 גדולים
- **האם M3 שונה מ-M4?** שניהם מאותה משפחת מודלים: M3 הוא הגרסה הבינונית והזולה, M4 הגרסה הגדולה

את השאלות אפשר לכתוב כהשערות על **צירוף לינארי** של התוחלות:

$$H_0 : \frac{1}{2}(\mu_1 + \mu_2) = \frac{1}{2}(\mu_4 + \mu_5) \quad \Longleftrightarrow \quad H_0 : \mu_1 + \mu_2 - \mu_4 - \mu_5 = 0$$

$$H_0 : \mu_3 = \mu_4 \quad \Longleftrightarrow \quad H_0 : \mu_3 - \mu_4 = 0$$

הגדרה

ניגוד (contrast) הוא צירוף לינארי של התוחלות

$$\Gamma = \sum_{i=1}^{a} c_i \mu_i \qquad \text{כאשר} \qquad 0 = c_i \sum_{i=1}^{a}$$

השאלה	c_1	c_2	c_3	c_4	c_5
קטנים מול גדולים	1	1	0	–1	–1
M4 מול M3	0	0	1	–1	0

- **למה** $\sum c_i = 0$**?** כי אז $\sum c_i \mu_i = \sum c_i (\mu + \tau_i) = \sum c_i \tau_i$. ה-$\mu$ מתבטל, והניגוד מודד רק **הבדלים** בין הרמות
- כל השוואה בין שתי רמות היא ניגוד: $c = (1, -1, 0, \ldots)$

האומד והשונות שלו

האומד: מחליפים כל תוחלת בממוצע של הרמה:

$$\hat{\Gamma} = \sum_{i=1}^{a} c_i \bar{y}_{i\cdot}$$

התוחלת: $E(\hat{\Gamma}) = \sum c_i \mu_i = \Gamma$. תחת H_0 היא אפס.

השונות: הממוצעים בלתי תלויים, וכל אחד עם שונות σ^2/n:

$$V(\hat{\Gamma}) = \sum_{i=1}^{a} c_i^2 \, V(\bar{y}_{i\cdot}) = \frac{\sigma^2}{n} \sum_{i=1}^{a} c_i^2$$

מבחן t: מציבים MS_E במקום σ^2:

$$t_0 = \frac{\sum c_i \bar{y}_{i\cdot}}{\sqrt{\frac{MS_E}{n} \sum c_i^2}} \sim t_{N-a} \quad (\text{תחת } H_0)$$

סכום הריבועים של ניגוד

אפשר לכתוב את אותו מבחן כמבחן F, עם $t_0^2 = F_0$. בעזרת הסכומים $y_{i\cdot} = n\bar{y}_{i\cdot}$:

$$SS_C = \frac{\left(\sum_{i=1}^{a} c_i y_{i\cdot}\right)^2}{n\sum_{i=1}^{a} c_i^2} \qquad F_0 = \frac{SS_C/1}{MS_E} \sim F_{1,\ N-a}$$

- לכל ניגוד **דרגת חופש אחת**
- SS_C הוא החלק של SS_{Tr} ש"מוסבר" על ידי השאלה הספציפית הזו
- דוחים את $H_0 : \Gamma = 0$ אם $F_0 > F_{1-\alpha;\,1,\,N-a}$

המודלים: קטנים מול גדולים

סכומי משכי הטיפול: $y_{1\cdot} = 45.02$, $y_{2\cdot} = 48.01$, $y_{3\cdot} = 35.95$, $y_{4\cdot} = 33.87$, $y_{5\cdot} = 35.60$.

קטנים מול גדולים, $c = (1, 1, 0, -1, -1)$:

$$\sum c_i y_{i\cdot} = 45.02 + 48.01 - 33.87 - 35.60 = 23.56 \qquad SS_{C_1} = \frac{23.56^2}{9 \cdot 4} = 15.42$$

$$F_0 = \frac{15.42}{0.854} = 18.06 > F_{0.95;\,1,\,40} = 4.08$$

דוחים: עם המודלים הגדולים הטיפול קצר יותר. $\hat{\Gamma}/2 = (5.17 - 3.86) = 1.31$ דקות בממוצע.

M3 מול M4, $c = (0, 0, 1, -1, 0)$:

$$SS_{C_2} = \frac{(35.95 - 33.87)^2}{9 \cdot 2} = 0.24 \qquad F_0 = \frac{0.24}{0.854} = 0.28 < 4.08$$

לא דוחים: אין עדות להבדל בין M3 ל-M4.

אותו חישוב ב-R

```r
contrast_test <- function(c, totals, n, mse, df_e) {
  ss <- sum(c * totals)^2 / (n * sum(c^2))
  c(estimate = sum(c * totals / n), SS = ss, F = ss / mse,
    p = pf(ss / mse, 1, df_e, lower.tail = FALSE))
}
totals <- tapply(calls$aht, calls$model, sum)
rbind(small_vs_large = contrast_test(c(1, 1, 0, -1, -1), totals, 9, mse, 40),
      M3_vs_M4       = contrast_test(c(0, 0, 1, -1, 0),  totals, 9, mse, 40))
```

```
               estimate      SS       F         p
small_vs_large   2.6178 15.4187 18.0627 0.0001243
M3_vs_M4         0.2311  0.2404  0.2816 0.5986067
```

ניגודים אורתוגונליים (Orthogonal contrasts)

שני ניגודים c ו-d הם **אורתוגונליים** אם

$$\sum_{i=1}^{a} c_i d_i = 0$$

- ניגודים אורתוגונליים שואלים שאלות **בלתי תלויות**: האומדים שלהם בלתי מתואמים
- אפשר למצוא לכל היותר $a-1$ ניגודים שכל זוג מהם אורתוגונלי
- **טענה:** לקבוצה של $a-1$ ניגודים אורתוגונליים בזוגות,

$$SS_{C_1} + SS_{C_2} + \cdots + SS_{C_{a-1}} = SS_{Tr}$$

כלומר: ניגודים אורתוגונליים **מפרקים** את SS_{Tr} ל-$a-1$ שאלות נפרדות, כל אחת עם דרגת חופש אחת.

דוגמה כללית: ניגודי Helmert

כל רמה מול כל הרמות שאחריה:

	רמה 1	**רמה 2**	**רמה 3**	$\cdots$	**רמה** $a-1$	**רמה** a
C_1	$-(a-1)$	1	1	$\cdots$	1	1
C_2	0	$-(a-2)$	1	$\cdots$	1	1
C_3	0	0	$-(a-3)$	$\cdots$	1	1
$\vdots$				$\ddots$		
C_{a-1}	0	0	0	$\cdots$	-1	1

- C_1: הרמה הראשונה מול כל השאר
- C_2: הרמה השנייה מול כל השאר, בלי הראשונה
- וכן הלאה. נסו לבדוק: המכפלה של כל שתי שורות היא 0

המודלים: ארבעה ניגודים אורתוגונליים

השאלה	c_1	c_2	c_3	c_4	c_5
C_1: קטנים מול גדולים	1	1	0	−1	−1
C_2: M1 מול M2	1	−1	0	0	0
C_3: M4 מול M5	0	0	0	1	−1
C_4: M3 מול כל השאר	1	1	−4	1	1

```
C <- rbind(small_vs_large = c(1, 1, 0, -1, -1), M1_vs_M2 = c(1, -1, 0, 0, 0),
           M4_vs_M5 = c(0, 0, 0, 1, -1),        M3_vs_rest = c(1, 1, -4, 1, 1))
C %*% t(C)                                       # off-diagonal zeros: pairwise orthogonal
```

```
              small_vs_large M1_vs_M2 M4_vs_M5 M3_vs_rest
small_vs_large              4        0        0          0
M1_vs_M2                    0        2        0          0
M4_vs_M5                    0        0        2          0
M3_vs_rest                  0        0        0         20
```

```
ss_c <- apply(C, 1, contrast_test, totals = totals, n = 9, mse = mse, df_e = 40)
round(ss_c, 3)
```

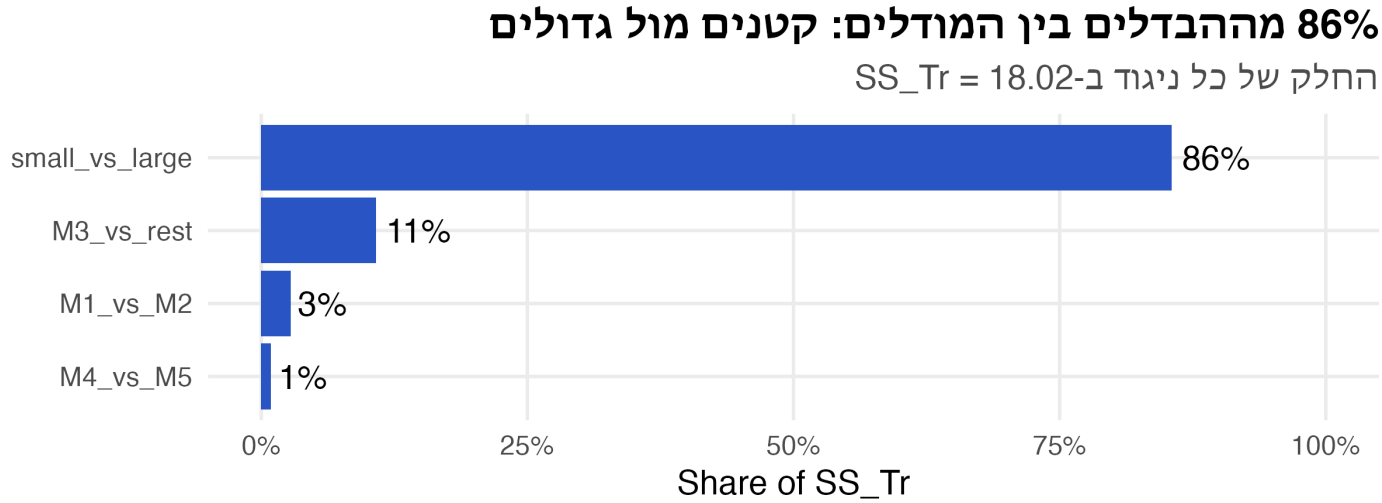
```
         small_vs_large M1_vs_M2 M4_vs_M5 M3_vs_rest
estimate          2.618   -0.332   -0.192      2.078
SS               15.419    0.497    0.166      1.943
F                18.063    0.582    0.195      2.276
p                 0.000    0.450    0.661      0.139
```

```
c(sum_SS_C = sum(ss_c["SS", ]), SS_Tr = summary(fit_ai)[[1]][1, "Sum Sq"])
```

```
sum_SS_C    SS_Tr
   18.02    18.02
```

איך קוראים את הפירוק

```
tibble(contrast = colnames(ss_c), SS = ss_c["SS", ]) |>
  mutate(share = SS / sum(SS), contrast = fct_reorder(contrast, SS)) |>
  ggplot(aes(share, contrast)) +
  geom_col(fill = nanas_pal[["primary"]]) +
  geom_text(aes(label = percent(share, 1)), hjust = -0.15) +
  scale_x_continuous(labels = percent, limits = c(0, 1)) +
  labs(title = "86% מההבדלים בין המודלים: קטנים מול גדולים",
       subtitle = "החלק של כל ניגוד ב-SS_Tr = 18.02", x = "Share of SS_Tr", y = NULL)
```



- כמעט כל ההבדל בין המודלים הוא **גודל**. בתוך כל קבוצה, המודלים דומים
- זו תשובה עסקית ברורה יותר מ"יש הבדל בין המודלים"

ניגודים בניסוי לא מאוזן

כש-n_i שונים, מגדירים את הניגוד על **הסכומים** $y_{i\cdot}$:

$$C = \sum_{i=1}^{a} c_i y_{i\cdot} \qquad E(C) = \sum_{i=1}^{a} c_i n_i (\mu + \tau_i) = \mu \sum_{i=1}^{a} n_i c_i + \sum_{i=1}^{a} n_i c_i \tau_i$$

כדי ש-μ יתבטל, התנאי הוא:

$$\sum_{i=1}^{a} n_i c_i = 0 \qquad SS_C = \frac{\left(\sum c_i y_{i\cdot}\right)^2}{\sum n_i c_i^2}$$

- **אורתוגונליות** בניסוי לא מאוזן: $\sum n_i c_i d_i = 0$
- בניסוי מאוזן ($n_i = n$) חוזרים לתנאים הקודמים

דוגמה: מבחן בשלוש כיתות

מבחן התקיים בשלוש כיתות: 40 סטודנטים בכיתה 1, ו-30 בכל אחת מכיתות 2 ו-3. **כיתה 3 סמוכה לאתר בנייה.** הסטודנטים שלה מבקשים פקטור. **האם הטענה מוצדקת?**

```
rooms <- read_csv(file.path(data_dir, "exam_rooms.csv"), show_col_types = FALSE)
rooms |> group_by(room) |> summarise(n = n(), total = sum(grade), mean = mean(grade))
```

```
# A tibble: 3 × 4
  room      n total  mean
  <chr> <int> <dbl> <dbl>
1 room1    40  3014  75.4
2 room2    30  2258  75.3
3 room3    30  2015  67.2
```

```
fit_rooms <- aov(grade ~ room, data = rooms)
summary(fit_rooms)
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
room         2   1394     697    4.08   0.02 *
Residuals   97  16573     171
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

ה-ANOVA דוחה ($p = 0.02$). אבל השאלה ספציפית: **כיתה 3 מול שתי האחרות**.

הניגוד לכיתה 3

צריך $\sum n_i c_i = 0$ עם $n = (40, 30, 30)$. ננסה $c = (1, 1, c_3)$:

$$40 + 30 + 30c_3 = 0 \implies c_3 = -\tfrac{7}{3} \implies c = (3, 3, -7)$$

$$C = 3 \cdot 3014 + 3 \cdot 2258 - 7 \cdot 2015 = 1711 \qquad \sum n_i c_i^2 = 40 \cdot 9 + 30 \cdot 9 + 30 \cdot 49 = 2100$$

$$SS_C = \frac{1711^2}{2100} = 1394.1 \qquad F_0 = \frac{1394.1}{170.9} = 8.16 > F_{0.95;\,1,\,97} = 3.94$$

דוחים: בכיתה 3 הציונים נמוכים באופן מובהק משתי הכיתות האחרות, בכ-8 נקודות. **ו-SS_C הוא כמעט כל** $SS_{Tr} = 1394.2$**:** בין כיתות 1 ו-2 כמעט אין הבדל.

```
rt <- tapply(rooms$grade, rooms$room, sum); rn <- table(rooms$room); cc <- c(3, 3, -7)
ss_room3 <- sum(cc * rt)^2 / sum(rn * cc^2)
c(sum_n_c = sum(rn * cc), SS_C = ss_room3, F = ss_room3 / 170.86,
  p = pf(ss_room3 / 170.86, 1, 97, lower.tail = FALSE))
```

```
  sum_n_c      SS_C         F         p
0.000e+00 1.394e+03 8.159e+00 5.242e-03
```

ניגודים מתוכננים מול "מה שנראה מעניין"

- **ניגוד מתוכנן** (planned, a priori): השאלה נוסחה **לפני** שראינו את הנתונים. מבחן F עם α רגילה תקין
- **ניגוד שנבחר אחרי שראינו את הנתונים** (post hoc): אם בוחרים להשוות את הממוצע הגבוה לנמוך **כי** הם הכי רחוקים, ההשוואה מוטה. הפער הגדול ביותר מבין הרבה פערים גדול מטבעו
- כדי לבדוק השוואות שנבחרו אחרי שראינו את הנתונים, צריך **שיטות להשוואות מרובות** ← החלק הבא

השוואות מרובות
(Multiple comparisons)

הבעיה

עם 5 מודלים יש 10 זוגות. אם בודקים כל זוג במבחן t ב-$\alpha = 0.05$, ו-H_0 נכונה בכל הזוגות:

מספר המבחנים m	$P(\text{לפחות טעות אחת}) = 1 - 0.95^m$
1	0.05
10 (5 רמות)	0.40
45 (10 רמות)	0.90
100	0.99

- **שיעור הטעות לכל השוואה** (per-comparison): α. זה מה שמבחן t רגיל שומר עליו
- **שיעור הטעות למשפחה** (familywise error rate, FWER): ההסתברות לטעות **אחת לפחות** בכל קבוצת המבחנים

סימולציה: 10 מבחני t כשאין שום הבדל

```r
set.seed(55)
g <- factor(rep(paste0("M", 1:5), each = 9))
any_reject <- replicate(4000, {
  p <- pairwise.t.test(rnorm(45), g, p.adjust.method = "none")$p.value
  any(p < 0.05, na.rm = TRUE)
})
mean(any_reject)
```

```
[1] 0.269
```

- ב-27% מהניסויים "מצאנו" לפחות זוג מודלים שונים, אף שכולם זהים
- פחות מ-40% בגלל התלות בין המבחנים, אבל הרבה יותר מ-5%

שלוש שיטות, שלוש משמעויות של "מובהק"

כל השיטות משוות **הפרש בין ממוצעים** לסף. כולן משתמשות בשגיאת התקן של ממוצע, $s_{\bar{y}} = \sqrt{MS_E/n}$:

השיטה	הסף	שולטת ב-
LSD של Fisher	$t_{1-\alpha/2,\,N-a}\sqrt{2MS_E/n}$	שיעור הטעות לכל השוואה. רק אחרי F מובהק
Duncan	$r_\alpha(p, f)\, s_{\bar{y}}$, תלוי במרחק p בין הממוצעים	ביניים
Tukey HSD	$q_\alpha(a, f)\, s_{\bar{y}}$, סף אחד לכל הזוגות	שיעור הטעות למשפחה (FWER)

למודלים: $s_{\bar{y}} = \sqrt{0.854/9} = 0.308$, ו-$f = N - a = 40$.

```
c(s_ybar = sqrt(mse / 9), LSD = qt(0.975, 40) * sqrt(2 * mse / 9))
```

```
s_ybar    LSD
0.3080 0.8803
```

שיטת Duncan

הרעיון

Duncan's multiple range test משווה את כל הזוגות, אבל הסף תלוי **כמה ממוצעים** נמצאים בין שני הממוצעים שמשווים.

1. ממיינים את ממוצעי הרמות בסדר יורד
2. לזוג שמרוחק p מקומות (כולל שניהם, $p = 2, \ldots, a$) מחשבים את **הטווח המובהק הקטן ביותר**:

$$R_p = r_\alpha(p, f) \cdot \sqrt{\frac{MS_E}{n}}$$

3. אם $|\bar{y}_{i\cdot} - \bar{y}_{k\cdot}| > R_p$, ההפרש מובהק

- $r_\alpha(p, f)$ הם **מקדמי Duncan**, מטבלה. $f = N - a$ הן דרגות החופש של MS_E
- זוג רחוק (p גדול) צריך הפרש גדול יותר כדי להיות מובהק
- **כלל ההגנה:** אם טווח לא מובהק, לא בודקים זוגות **בתוכו**

מאיפה מגיעים המקדמים?

המקדמים הם ערכים של **התפלגות הטווח המסוטנדרט** (studentized range), אותה התפלגות שבה משתמשת שיטת Tukey. ההבדל הוא ברמת המובהקות: לטווח של p ממוצעים, Duncan משתמש ב-

$$\alpha_p = 1 - (1 - \alpha)^{p-1}$$

ככל ש-p גדל, α_p גדלה, והשיטה "סלחנית" יותר. ב-R אין צורך בטבלה:

```
p <- 2:5
r_duncan <- qtukey((1 - 0.05)^(p - 1), nmeans = p, df = 40)   # Duncan's r_alpha(p, 40)
rbind(p = p, alpha_p = 1 - 0.95^(p - 1), r = r_duncan, R_p = r_duncan * sqrt(mse / 9)) |> round(3)
```

```
         [,1]  [,2]  [,3]  [,4]
p       2.000 3.000 4.000 5.000
alpha_p 0.050 0.098 0.143 0.185
r       2.858 3.005 3.102 3.171
R_p     0.880 0.926 0.955 0.977
```

המודלים: שיטת Duncan

מיון: M2 (5.33) · M1 (5.00) · M3 (3.99) · M5 (3.96) · M4 (3.76)

```
means <- sort(tapply(calls$aht, calls$model, mean), decreasing = TRUE)
R_p   <- setNames(r_duncan * sqrt(mse / 9), 2:5)

duncan <- combn(names(means), 2, simplify = FALSE) |>
  map(\(pair) {
    pos <- match(pair, names(means))
    tibble(high = pair[1], low = pair[2], p = diff(pos) + 1,
           diff = means[pair[1]] - means[pair[2]], R_p = R_p[as.character(diff(pos) + 1)])
  }) |>
  list_rbind() |>
  mutate(significant = diff > R_p) |>
  arrange(desc(p))
duncan
```

המודלים: שיטת Duncan

```
# A tibble: 10 × 6
   high  low       p   diff   R_p significant
   <chr> <chr> <dbl>  <dbl> <dbl> <lgl>
 1 M2    M4        5 1.57   0.977 TRUE
 2 M2    M5        4 1.38   0.955 TRUE
 3 M1    M4        4 1.24   0.955 TRUE
 4 M2    M3        3 1.34   0.926 TRUE
 5 M1    M5        3 1.05   0.926 TRUE
 6 M3    M4        3 0.231  0.926 FALSE
 7 M2    M1        2 0.332  0.880 FALSE
 8 M1    M3        2 1.01   0.880 TRUE
 9 M3    M5        2 0.0389 0.880 FALSE
10 M5    M4        2 0.192  0.880 FALSE
```

התוצאה

	M2	M1	M3	M5	M4
ממוצע	5.33	5.00	3.99	3.96	3.76
קבוצה	**א**	**א**	**ב**	**ב**	**ב**

- **M2 ו-M1** לא שונים זה מזה ($0.33 < 0.88$), ושניהם שונים מכל השאר
- **M3, M5 ו-M4** לא שונים זה מזה: הטווח של שלושתם הוא $R_3 = 0.93 > 0.23$. לפי כלל ההגנה, לא בודקים זוגות בתוכו
- רמות עם אותה **אות** לא שונות זו מזו באופן מובהק

ההמלצה: להפעיל את אחד מ-M3, M4 או M5. הנתונים לא מבדילים ביניהם, ולכן M3, הזול שבהם, הוא בחירה סבירה.

ביקורת על Duncan

- α_p גדלה עם מספר הממוצעים: עם 5 רמות, $\alpha_5 = 1 - 0.95^4 = 0.185$
- כלומר, ה-FWER של השיטה **גבוה מ-5%**, וגדל עם מספר הרמות. עם 10 רמות, $\alpha_{10} = 0.37$
- השיטה "מוצאת" יותר הבדלים, וחלקם שגויים
- Duncan נפוצה בספרות החקלאית וההנדסית הישנה, ותפגשו אותה בבחינה. בעבודה מעשית, מקובל היום להשתמש ב-Tukey

שיטת Tukey (HSD)

הרעיון

Tukey's Honest Significant Difference: סף **אחד** לכל הזוגות, שמבטיח FWER $= \alpha$ בדיוק (בניסוי מאוזן).

$$HSD = q_\alpha(a, f) \cdot \sqrt{\frac{MS_E}{n}}$$

- $q_\alpha(a, f)$: הערך הקריטי של **התפלגות הטווח המסוטנדרט** של a ממוצעים, עם $f = N - a$ דרגות חופש
- **ההיגיון:** אם הזוג **הרחוק ביותר** לא חוצה את הסף תחת H_0 בהסתברות $1 - \alpha$, אף זוג לא חוצה אותו. לכן ההסתברות לטעות אחת לפחות היא α

$$q = \frac{\bar{y}_{max} - \bar{y}_{min}}{\sqrt{MS_E / n}}$$

רווחי סמך משותפים לכל ההפרשים: $(\bar{y}_{i\cdot} - \bar{y}_{k\cdot}) \pm HSD$. **בניסוי לא מאוזן** (Tukey–Kramer):
$q_\alpha(a, f)\sqrt{\frac{MS_E}{2}\left(\frac{1}{n_i} + \frac{1}{n_k}\right)}$.

המודלים: חישוב ידני

$$HSD = q_{0.05}(5, 40) \cdot 0.308 = 4.04 \cdot 0.308 = 1.244$$

```
c(q = qtukey(0.95, nmeans = 5, df = 40), HSD = qtukey(0.95, 5, 40) * sqrt(mse / 9))
```

```
    q   HSD 
4.039 1.244 
```

```
duncan |> mutate(tukey = diff > 1.244) |> select(high, low, diff, duncan = significant, tukey)
```

```
# A tibble: 10 × 5
   high  low     diff duncan tukey
   <chr> <chr>  <dbl> <lgl>  <lgl>
 1 M2    M4    1.57   TRUE   TRUE 
 2 M2    M5    1.38   TRUE   TRUE 
 3 M1    M4    1.24   TRUE   FALSE
 4 M2    M3    1.34   TRUE   TRUE 
 5 M1    M5    1.05   TRUE   FALSE
 6 M3    M4    0.231  FALSE  FALSE
 7 M2    M1    0.332  FALSE  FALSE
 8 M1    M3    1.01   TRUE   FALSE
 9 M3    M5    0.0389 FALSE  FALSE
10 M5    M4    0.192  FALSE  FALSE
```

Tukey ב-R

```
TukeyHSD(fit_ai)
```

```
  Tukey multiple comparisons of means
    95% family-wise confidence level

Fit: aov(formula = aht ~ model, data = calls)

$model
          diff     lwr       upr  p adj
M2-M1  0.33222 -0.9117  1.576159 0.9397
M3-M1 -1.00778 -2.2517  0.236159 0.1617
M4-M1 -1.23889 -2.4828  0.005048 0.0514
M5-M1 -1.04667 -2.2906  0.197270 0.1354
M3-M2 -1.34000 -2.5839 -0.096063 0.0292
M4-M2 -1.57111 -2.8150 -0.327174 0.0072
M5-M2 -1.37889 -2.6228 -0.134952 0.0233
M4-M3 -0.23111 -1.4750  1.012826 0.9836
M5-M3 -0.03889 -1.2828  1.205048 1.0000
M5-M4  0.19222 -1.0517  1.436159 0.9918
```

איך קוראים את הפלט

- **`diff`**: ההפרש בין הממוצעים (השורה − העמודה). `M2-M1 = 0.33`: עם M2 הטיפול ארוך מאשר עם M1 ב-0.33 דקות
- **`lwr`, `upr`**: רווח סמך **משותף** של 95%: $\text{diff} \pm 1.244$. ב-95% מהניסויים **כל** עשרת הרווחים יכילו את ההפרש האמיתי יחד
- **`p adj`**: p-value מתוקן להשוואות מרובות. מובהק אם קטן מ-0.05, כלומר אם הרווח לא כולל את 0
- **שימו לב ל-`M4-M1`:** ההפרש 1.239, וה-HSD הוא 1.244. `p adj = 0.051`. **לא** מובהק, בהפרש של חמש אלפיות דקה

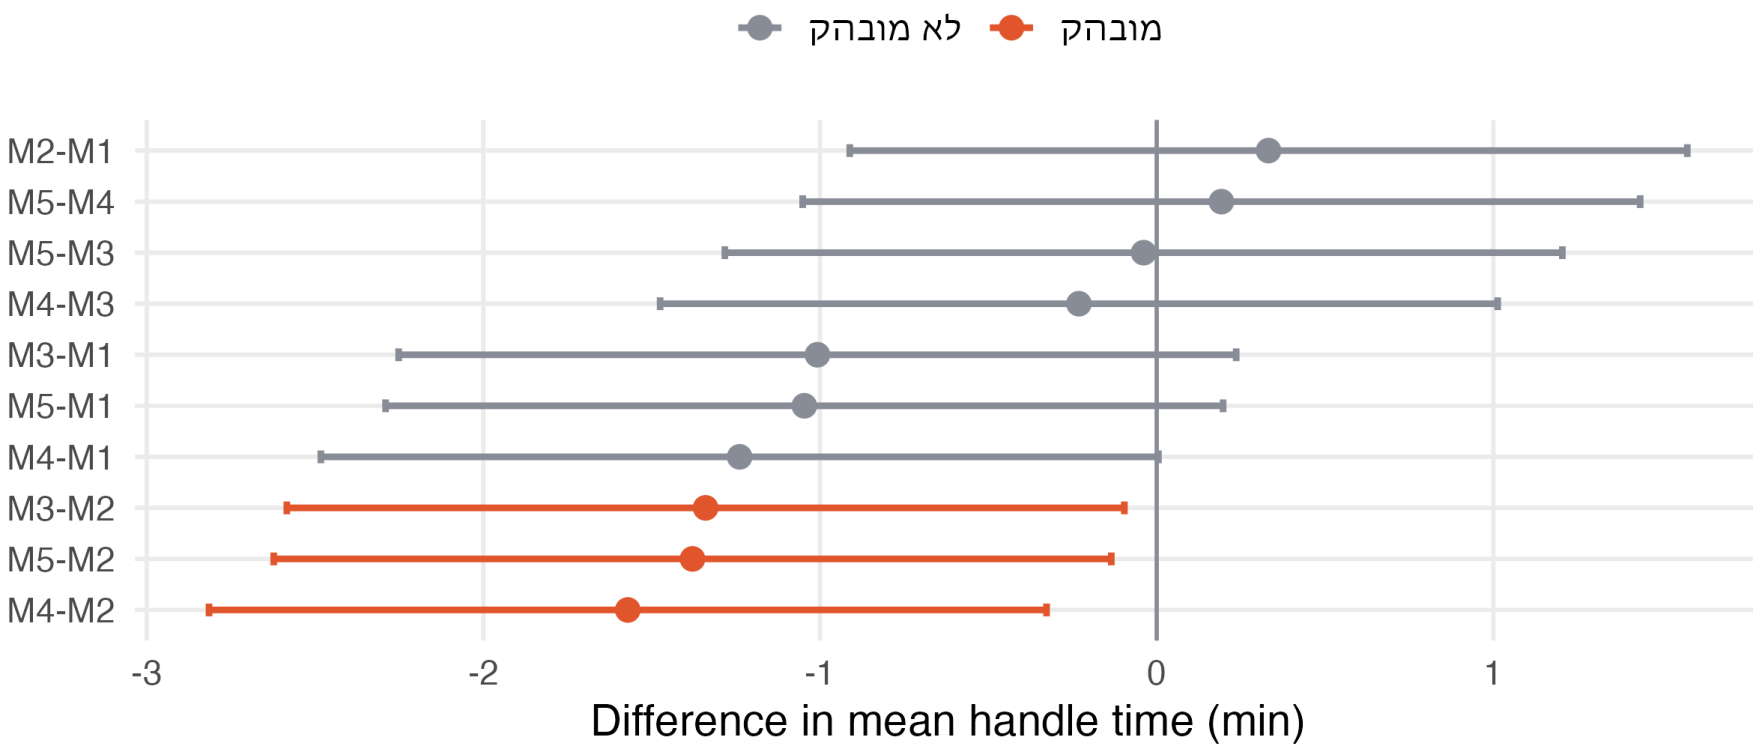
רווחי הסמך בתרשים

```
TukeyHSD(fit_ai)$model |>
  as_tibble(rownames = "pair") |>
  mutate(pair = fct_reorder(pair, diff), significant = `p adj` < 0.05) |>
  ggplot(aes(diff, pair, colour = significant)) +
  geom_vline(xintercept = 0, colour = nanas_pal[["grey"]]) +
  geom_errorbar(aes(xmin = lwr, xmax = upr), width = 0.25, linewidth = 1, orientation = "y") +
  geom_point(size = 3) +
  scale_colour_manual(values = c(`TRUE` = nanas_pal[["accent"]], `FALSE` = nanas_pal[["grey"]]),
                      labels = c(`TRUE` = "מובהק", `FALSE` = "לא מובהק")) +
  labs(title = "שלושה זוגות מובהקים לפי Tukey: M2 מול M3, M4 ו־M5",
       subtitle = "רווחי סמך משותפים 95% להפרשים · רווח שלא חוצה את 0 הוא מובהק",
       x = "Difference in mean handle time (min)", y = NULL, colour = NULL)
```

רווחי הסמך בתרשים

שלושה זוגות מובהקים לפי Tukey: M2 מול M3, M4 ו-M5

רווחי סמך משותפים 95% להפרשים · רווח שלא חוצה את 0 הוא מובהק



Duncan מול Tukey

זוג	הפרש	LSD (0.88)	Duncan (R_p)	Tukey (1.244)
M2–M4	1.57	✓	✓ (0.98)	✓
M2–M5	1.38	✓	✓ (0.96)	✓
M2–M3	1.34	✓	✓ (0.93)	✓
M1–M4	1.24	✓	✓ (0.96)	✗
M1–M5	1.05	✓	✓ (0.93)	✗
M1–M3	1.01	✓	✓ (0.88)	✗
M2–M1, M3–M4, M3–M5, M5–M4	≤ 0.33	✗	✗	✗

- LSD ו-Duncan מוצאים 6 זוגות. Tukey מוצא 3
- **אין כאן "נכון" ו"לא נכון".** זו בחירה בין שתי טעויות: Tukey שומר על הסיכוי לתגלית שגויה **אחת** מתחת ל-5%, במחיר של עוצמה

איזו שיטה מתי?

המצב	השיטה	ב-R
מעט שאלות, מתוכננות מראש	ניגודים, α רגילה	ידני, `pf()`
כל הזוגות, אחרי F מובהק	Tukey HSD	`TukeyHSD()`
כל הזוגות, כשהבחינה דורשת	Duncan	`qtukey()` + טבלה

הכלל החשוב ביותר: מחליטים על השיטה **לפני** שמסתכלים על התוצאות. אם בוחרים את השיטה שנותנת את התוצאה ה"נכונה", כל התיקון לא שווה כלום.

ניתוח שונות א-פרמטרי: Kruskal–Wallis

מתי צריך מבחן א-פרמטרי?

הדוגמה: זמן התגובה של API בארבעה אזורי ענן (regions), 12 בקשות מכל אזור. זמני תגובה מוטים ימינה, עם ערכים חריגים.

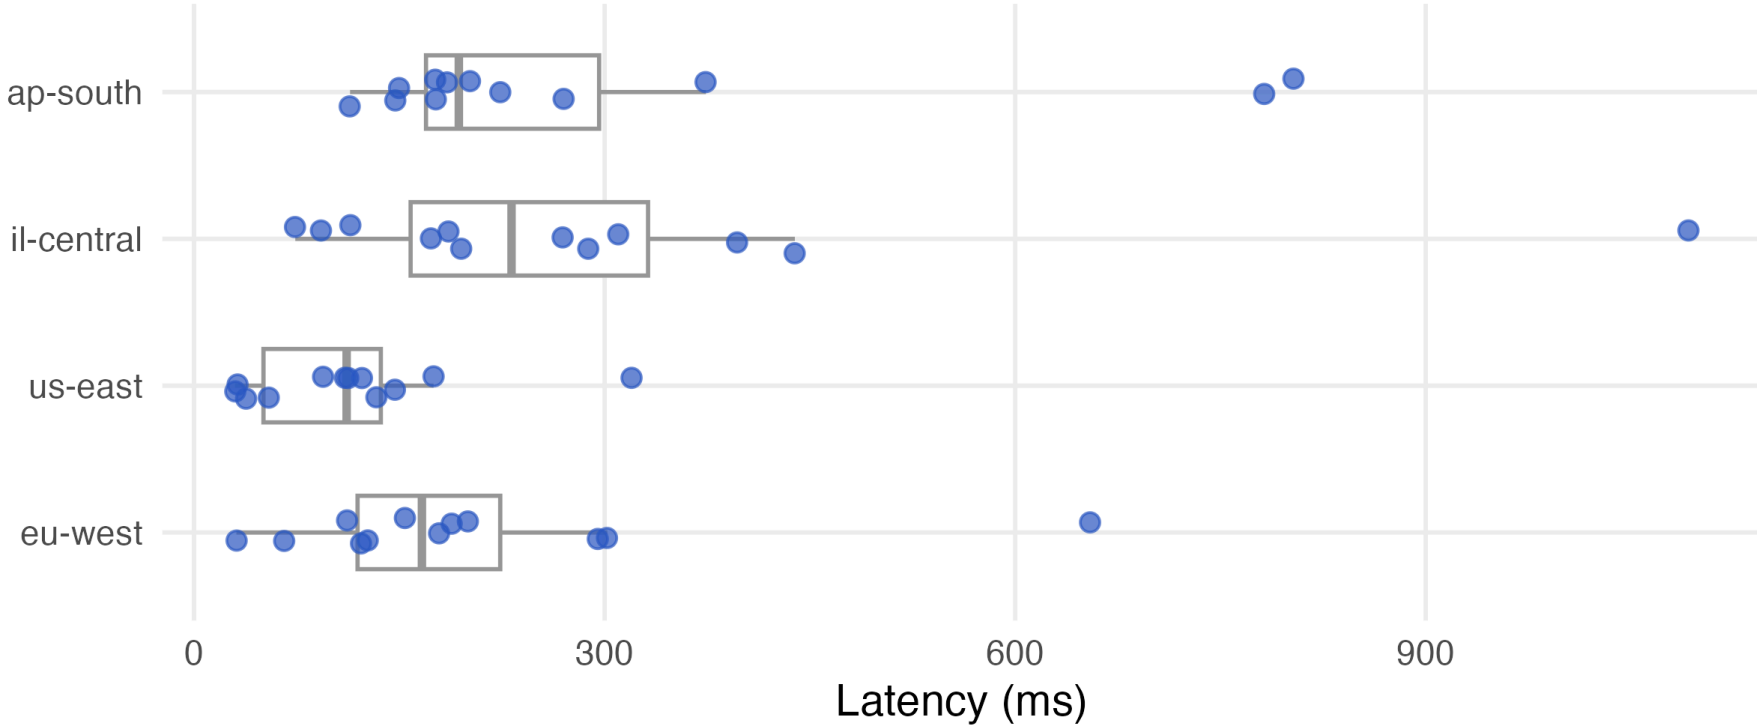
```
set.seed(162)
latency <- tibble(region = factor(rep(c("eu-west", "us-east", "il-central", "ap-south"), each = 12),
                                  levels = c("eu-west", "us-east", "il-central", "ap-south")),
                  ms = round(rlnorm(48, log(rep(c(150, 155, 210, 220), each = 12)), 0.8)))

ggplot(latency, aes(ms, region)) +
  geom_boxplot(width = 0.5, outlier.shape = NA, colour = "grey60") +
  geom_point(colour = nanas_pal[["primary"]], size = 2.5, alpha = 0.7,
             position = position_jitter(height = 0.1, seed = 3)) +
  labs(title = "זמני תגובה מוטים, עם כמה בקשות איטיות מאוד",
       subtitle = "12 בקשות מכל אזור",
       x = "Latency (ms)", y = NULL)
```

מתי צריך מבחן א-פרמטרי?

זמני תגובה מוטים, עם כמה בקשות איטיות מאוד

12 בקשות מכל אזור



ANOVA על נתונים מוטים

```r
fit_lat <- aov(ms ~ region, data = latency)
summary(fit_lat)
```

```
            Df  Sum Sq Mean Sq F value Pr(>F)
region       3  292464   97488    2.35  0.085 .
Residuals   44 1823008   41432
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
shapiro.test(resid(fit_lat))
```

```
    Shapiro-Wilk normality test

data:  resid(fit_lat)
W = 0.76, p-value = 2e-07
```

- ה-ANOVA **לא דוחה** ($p = 0.085$)
- אבל השאריות רחוקות מנורמליות. הבקשות האיטיות מנפחות את MS_E ו"מסתירות" את ההבדלים
- **שתי אפשרויות:** טרנספורמציה ($\log$), או מבחן שלא מניח נורמליות

Kruskal–Wallis: הרעיון

הכללה של מבחן סכום הדירוגים (הרצאה 1) ליותר משני מדגמים.

$$y_{ij} = \mu + \tau_i + \varepsilon_{ij}$$

- **לא** מניחים $\varepsilon_{ij} \sim N(0, \sigma^2)$. מניחים רק שכל ה-$\varepsilon_{ij}$ מגיעים מאותה התפלגות **רציפה**
- $H_0 : \tau_1 = \cdots = \tau_a = 0$ (כל הרמות מאותה התפלגות) מול H_1: לפחות רמה אחת מוזזת
- **השיטה:** מדרגים את כל N התצפיות יחד, מ-1 (הקטנה) עד N (הגדולה), ומריצים "ANOVA על הדרגות"

תחת H_0 הדרגות מתפזרות באקראי בין הרמות. כמו במבחן סכום הדירוגים, כל דרגה מתפלגת אחיד על $\{1, \ldots, N\}$:

$$E(R_{ij}) = \frac{N+1}{2} \qquad V(R_{ij}) = \frac{N^2 - 1}{12}$$

הסטטיסטי

ב-ANOVA (בהנחת נורמליות):

$$\frac{SS_{Tr}}{\sigma^2} = \frac{\sum_{i=1}^{a} n_i(\bar{y}_{i\cdot} - \bar{y}_{\cdot\cdot})^2}{\sigma^2} \sim \chi^2_{a-1}$$

ב-Kruskal–Wallis: אותו ביטוי, על הדרגות. $\bar{R}_{i\cdot}$ הוא ממוצע הדרגות ברמה i, ו-σ^2 מוחלף בשונות הידועה של דרגה, $\frac{N(N+1)}{12}$ (בקירוב):

$$K = \frac{12}{N(N+1)} \sum_{i=1}^{a} n_i \left(\bar{R}_{i\cdot} - \frac{N+1}{2} \right)^2 = \frac{12}{N(N+1)} \sum_{i=1}^{a} \frac{R_{i\cdot}^2}{n_i} - 3(N+1)$$

- $R_{i\cdot}$ הוא **סכום** הדרגות ברמה i
- תחת H_0, $K \sim \chi^2_{a-1}$ בקירוב (טוב כש-$n_i \geq 5$)
- דוחים את H_0 אם $K > \chi^2_{1-\alpha,\, a-1}$
- **שימו לב:** אין כאן σ^2 לאמוד. השונות של הדרגות ידועה מראש

דוגמה לחישוב ידני: חוזק בד לפי אחוז כותנה

מפעל טקסטיל בודק 5 רמות של אחוז כותנה בבד (15%–35%), 6 דגימות בכל רמה. **האם אחוז הכותנה משפיע על חוזק המתיחה?**

```
cotton <- read_csv(file.path(np_data_dir, "cotton_strength.csv"), show_col_types = FALSE) |>
  mutate(cotton_pct = factor(cotton_pct), rank = rank(strength))
cotton |>
  group_by(cotton_pct) |>
  summarise(n = n(), strength = paste(sort(strength), collapse = ", "),
            R = sum(rank), R_bar = mean(rank))
```

```
# A tibble: 5 × 5
  cotton_pct     n strength                                R R_bar
  <fct>      <int> <chr>                                <dbl> <dbl>
1 15             6 8.5, 9.9, 10.3, 11.6, 12.8, 15.2    58    9.67
2 20             6 10.6, 10.8, 11.3, 11.6, 12.3, 13.4  66.5 11.1
3 25             6 13.7, 14, 14.4, 14.5, 15, 15.5     123   20.5
4 30             6 15.1, 15.8, 15.9, 16, 16.2, 17     163   27.2
5 35             6 10, 10.3, 10.4, 10.9, 12.2, 14.1    54.5  9.08
```

חישוב K

$N = 30$, $a = 5$, $n_i = 6$. סכומי הדרגות: $R_{i\cdot} = 58,\ 66.5,\ 123,\ 163,\ 54.5$.

$$K = \frac{12}{30 \cdot 31} \cdot \frac{58^2 + 66.5^2 + 123^2 + 163^2 + 54.5^2}{6} - 3 \cdot 31 = 19.81$$

$$K = 19.81 > \chi^2_{0.95,\,4} = 9.49$$

דוחים את H_0: אחוז הכותנה משפיע על חוזק הבד.

```
kruskal.test(strength ~ cotton_pct, data = cotton)
```

```
    Kruskal-Wallis rank sum test

data:  strength by cotton_pct
Kruskal-Wallis chi-squared = 20, df = 4, p-value = 5e-04
```

בחזרה לזמני התגובה

```r
kruskal.test(ms ~ region, data = latency)
```

```
    Kruskal-Wallis rank sum test

data:  ms by region
Kruskal-Wallis chi-squared = 12, df = 3, p-value = 0.009
```

```r
summary(aov(log(ms) ~ region, data = latency))
```

```
            Df Sum Sq Mean Sq F value Pr(>F)
region       3   7.42   2.473    4.75 0.0059 **
Residuals   44  22.91   0.521
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

- **Kruskal–Wallis דוחה** ($p = 0.0085$), במקום שה-ANOVA על הנתונים הגולמיים לא דחה
- גם ANOVA על $\log(\text{ms})$ דוחה. הלוגריתם "מכווץ" את הזנב הימני ומקרב לנורמליות
- **הדרגות לא רגישות לערכים חריגים:** בקשה של 1,000 מילישניות היא פשוט "הדרגה הגבוהה ביותר", בדיוק כמו בקשה של 400

אילו אזורים שונים? השוואות מרובות על דרגות

אחרי Kruskal–Wallis מובהק, משווים זוגות במבחן סכום הדירוגים, ומתקנים להשוואות מרובות:

```
pairwise.wilcox.test(latency$ms, latency$region, p.adjust.method = "bonferroni")
```

```
    Pairwise comparisons using Wilcoxon rank sum exact test

data:  latency$ms and latency$region

           eu-west us-east il-central
us-east    0.468   -       -
il-central 1.000   0.060   -
ap-south   1.000   0.003   1.000

P value adjustment method: bonferroni
```

- כל תא הוא p-value של מבחן סכום הדירוגים בין שני אזורים, **מתוקן** בשיטת Bonferroni: מוכפל במספר ההשוואות (וחסום ב-1). דוחים אם הוא קטן מ-0.05
- **הסתייגות:** כמו בהרצאה 1, מבחן סכום הדירוגים בודק **חצינים** רק תחת הנחת הזזה. כאן, עם התפלגויות לוג-נורמליות עם אותה צורה, ההנחה סבירה בסקאלה הלוגריתמית

ניגודים עם חציונים

אחרי Kruskal–Wallis, איך אומדים ניגוד $\Gamma = \sum c_i \tau_i$ בלי ממוצעים?

- **הניסיון הטבעי:** $\hat{\tau}_i = \text{median}_j\{y_{ij}\} - \text{median}_{\text{all}}$
- **הבעיה:** האומדים האלה **לא** מקיימים $\sum \hat{\tau}_i = 0$

דוגמה קטנה: $y_{1j} = \{3, 7, 8\}$ ו-$y_{2j} = \{0, 1, 2\}$. החציון הכללי הוא 2.5, וחציוני הקבוצות הם 7 ו-1:

$$\hat{\tau}_1 = 7 - 2.5 = 4.5 \qquad \hat{\tau}_2 = 1 - 2.5 = -1.5 \qquad \hat{\tau}_1 + \hat{\tau}_2 = 3 \neq 0$$

הפתרון: חציונים של הפרשים

לכל זוג רמות (i,k), מחשבים את החציון של **כל ההפרשים** בין תצפית מרמה i לתצפית מרמה k:

$$Z_{ik} = \underset{j,\,m}{\text{median}}\{y_{ij} - y_{km}\} \qquad Z_{ii} = 0 \qquad \hat{\tau}_i = \frac{1}{a}\sum_{k=1}^{a} Z_{ik}$$

מכיוון ש-$Z_{ik} = -Z_{ki}$, הסכום $\sum_i \hat{\tau}_i = \frac{1}{a}\sum_i\sum_k Z_{ik} = 0$.

בדוגמה הקטנה: 9 ההפרשים $y_{1j} - y_{2m}$ הם $\{3,2,1,7,6,5,8,7,6\}$, והחציון שלהם $Z_{12} = 6$. לכן $Z_{21} = -6$, ו-

$$\hat{\tau}_1 = \frac{0+6}{2} = 3 \qquad \hat{\tau}_2 = \frac{-6+0}{2} = -3 \qquad \hat{\tau}_1 + \hat{\tau}_2 = 0 \ \checkmark$$

ניגוד בדוגמת הכותנה

השאלה: האם הקצוות (15% ו-35%) חלשים מ-30%? $\Gamma = \frac{1}{2}(\tau_1 + \tau_5) - \tau_4$.

```
y_by_level <- split(cotton$strength, cotton$cotton_pct)
Z <- outer(seq_along(y_by_level), seq_along(y_by_level),
           Vectorize(\(i, k) median(outer(y_by_level[[i]], y_by_level[[k]], "-"))))
tau_hat <- rowMeans(Z)
round(tau_hat, 2)
```

```
[1] -1.86 -1.26  1.73  3.22 -1.83
```

```
sum(tau_hat)                                  # 0 by construction
```

```
[1] 2.22e-16
```

```
0.5 * (tau_hat[1] + tau_hat[5]) - tau_hat[4]
```

```
[1] -5.065
```

$$\hat{\Gamma} = \tfrac{1}{2}(-1.86 + -1.83) - 3.22 = -5.06$$

בד עם 15% או 35% כותנה חלש בכ-5 יחידות מבד עם 30% כותנה.

מבחן Friedman: טיפולים בתוך בלוקים

כשכל יחידה מקבלת את כל הטיפולים

דוגמה: צוות AI בודק שלוש גרסאות של פרומפט על 8 משימות מבחן (eval set). כל תשובה מקבלת ציון 0–100.

- **כל משימה נבדקת עם כל שלושת הפרומפטים.** המשימה היא **בלוק** (block)
- המשימות שונות מאוד בקושי. ההבדל בין משימה קלה לקשה גדול מההבדל בין פרומפטים
- Kruskal–Wallis מניח מדגמים **בלתי תלויים**. כאן הם לא: אותה משימה מופיעה בכל הרמות
- **הפתרון:** משווים את הפרומפטים **בתוך** כל משימה

זה גם המצב של המודלים במוקד: כל המודלים עבדו באותם 9 ימים, והיום הוא בלוק.

הנתונים

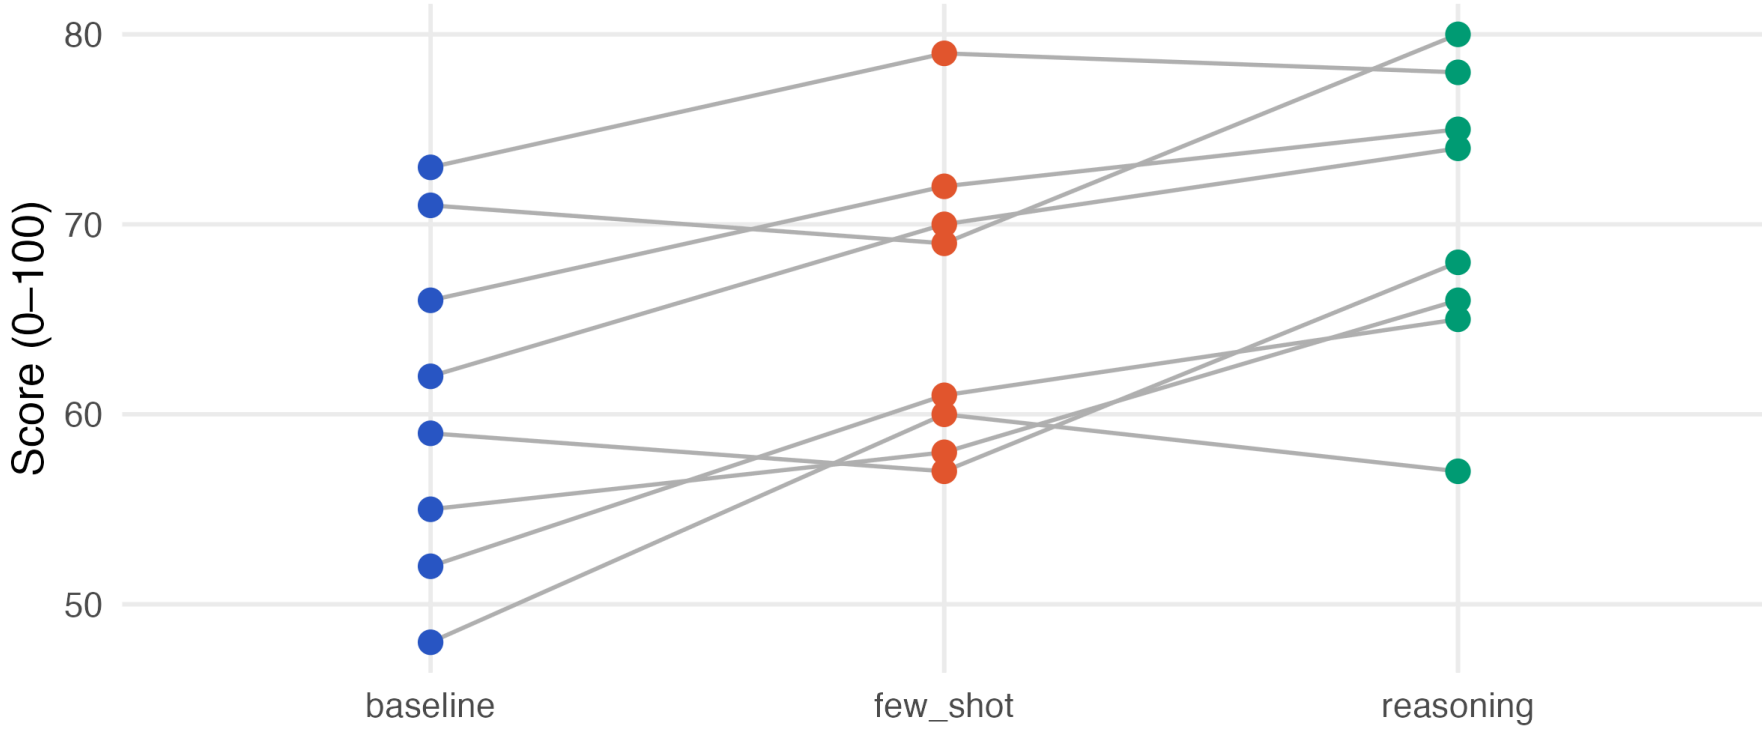
```
llm <- read_csv(file.path(np_data_dir, "llm_prompt_eval.csv"), show_col_types = FALSE) |>
  mutate(prompt = factor(prompt, levels = c("baseline", "few_shot", "reasoning")),
         task = factor(task))

ggplot(llm, aes(prompt, score, group = task)) +
  geom_line(colour = "grey70") +
  geom_point(aes(colour = prompt), size = 3, show.legend = FALSE) +
  labs(title = "ברוב המשימות, הפרומפט עם ההנמקה מנצח",
       subtitle = "כל קו הוא משימה אחת · ההבדלים בין המשימות גדולים מההבדלים בין הפרומפטים",
       x = NULL, y = "Score (0–100)")
```

הנתונים

ברוב המשימות, הפרומפט עם ההנמקה מנצח

כל קו הוא משימה אחת · ההבדלים בין המשימות גדולים מההבדלים בין הפרומפטים



הסטטיסטי

- b בלוקים ו-k טיפולים
- מדרגים את הטיפולים **בתוך כל בלוק** בנפרד, מ-1 עד k
- R_j הוא **סכום הדרגות** של טיפול j על פני כל הבלוקים

תחת H_0 (אין הבדל בין הטיפולים), בכל בלוק כל סידור של הדרגות סביר באותה מידה, ולכן $E(R_j) = \frac{b(k+1)}{2}$:

$$Q = \frac{12}{b\,k\,(k+1)} \sum_{j=1}^{k} \left(R_j - \frac{b(k+1)}{2} \right)^2 = \frac{12}{b\,k\,(k+1)} \sum_{j=1}^{k} R_j^2 - 3\,b\,(k+1)$$

תחת H_0, $Q \sim \chi^2_{k-1}$ בקירוב. דוחים את H_0 אם $Q > \chi^2_{1-\alpha,\,k-1}$.

חישוב

```
llm_ranked <- llm |> group_by(task) |> mutate(rank = rank(score)) |> ungroup()
llm_ranked |> select(task, prompt, rank) |> pivot_wider(names_from = prompt, values_from = rank)
```

```
# A tibble: 8 × 4
  task  baseline few_shot reasoning
  <fct>    <dbl>    <dbl>     <dbl>
1 1            1        2         3
2 2            1        2         3
3 3            2        1         3
4 4            1        3         2
5 5            1        2         3
6 6            2        1         3
7 7            1        3         2
8 8            1        2         3
```

```
llm_ranked |> group_by(prompt) |> summarise(R = sum(rank))
```

```
# A tibble: 3 × 2
  prompt        R
  <fct>     <dbl>
1 baseline     10
2 few_shot     16
3 reasoning    22
```

$$Q = \frac{12}{8 \cdot 3 \cdot 4}\left(10^2 + 16^2 + 22^2\right) - 3 \cdot 8 \cdot 4 = 105 - 96 = 9 > \chi^2_{0.95,\,2} = 5.99$$

דוחים: יש הבדל בין הפרומפטים.

Friedman ב-R, ומה קורה בלי בלוקים

```r
friedman.test(score ~ prompt | task, data = llm)
```

```
    Friedman rank sum test

data:  score and prompt and task
Friedman chi-squared = 9, df = 2, p-value = 0.01
```

```r
kruskal.test(score ~ prompt, data = llm)          # ignores the blocks
```

```
    Kruskal-Wallis rank sum test

data:  score by prompt
Kruskal-Wallis chi-squared = 4.1, df = 2, p-value = 0.1
```

- Friedman **דוחה**. Kruskal–Wallis, שמתעלם מהבלוקים, **לא**
- השונות הגדולה **בין המשימות** "מטביעה" את ההבדל בין הפרומפטים, כמו שאפקט היום ניפח את MS_E במוקד
- **אותו עיקרון במוקד:**

```r
friedman.test(aht ~ model | day, data = calls)
```

```
    Friedman rank sum test

data:  aht and model and day
Friedman chi-squared = 23, df = 4, p-value = 1e-04
```

מה יכול להשתבש

חמש מלכודות

1. **לבחור את ההשוואה אחרי שרואים את הנתונים**, ולבדוק אותה כאילו תוכננה מראש. ניגוד מתוכנן חייב להיות מתוכנן
2. **לבחור את שיטת התיקון לפי התוצאה:** "ב-Tukey זה לא יצא מובהק, אז ננסה Duncan". זו הגרסה המתוחכמת של p-hacking
3. **לא לתקן בכלל:** להריץ מבחן t על כל הזוגות, ולהכריז על הזוג שיצא מובהק
4. **להתעלם מבלוקים:** כשאותן יחידות (משימות, ימים, משתמשים) מופיעות בכל הרמות, מבחן למדגמים בלתי תלויים מאבד עוצמה ומפר את ההנחות
5. **לפרש Kruskal–Wallis כמבחן על חציונים** בלי הנחת הזזה. אם לרמות יש צורות שונות (למשל פיזור שונה), המבחן בודק משהו אחר

סיכום

מה לקחת מההרצאה

השאלה	הכלי	ב-R
שאלה ספציפית, מתוכננת מראש	ניגוד, SS_C, $F_{1,\,N-a}$	ידני, `pf()`
לפרק את SS_{Tr} לשאלות נפרדות	$a-1$ ניגודים אורתוגונליים	
כל הזוגות (גרסת הבחינה)	Duncan, $R_p = r_\alpha(p,f)\,s_{\bar{y}}$	`qtukey((1-α)^(p-1), p, f)`
כל הזוגות, FWER $= \alpha$	Tukey HSD, $q_\alpha(a,f)\,s_{\bar{y}}$	`TukeyHSD()`
נתונים מוטים, חריגים, סדר	Kruskal–Wallis, $K \sim \chi^2_{a-1}$	`kruskal.test()`
זוגות אחרי Kruskal–Wallis	סכום דירוגים + תיקון	`pairwise.wilcox.test()`
ניגוד עמיד לחריגים	חציונים של הפרשים, Z_{ik}	
טיפולים בתוך בלוקים	Friedman, $Q \sim \chi^2_{k-1}$	`friedman.test()`

בהרצאה הבאה: ניתוח שונות עם כמה פקטורים, אינטראקציות, ובלוקים כחלק מהמודל.